

Podstawy eksploracyjnej analizy danych

Wskaźniki sumaryczne i wykresy

Adam Zagdański

Wydział Matematyki, Politechnika Wrocławska,
e-mail: Adam.Zagdanski@pwr.edu.pl

Wrocław
13 marca 2026

Wprowadzenie
Rodzaje cech statystycznych
Graficzna prezentacja danych – podstawowe wykresy
Wskaźniki sumaryczne (statystyki opisowe)
Dodatek: Analiza opisowa w R

Plan wykładu

- Dane i rodzaje cech
- Graficzna prezentacja danych (wykresy dla danych jakościowych/ilościowych i ich interpretacja)
- Wskaźniki sumaryczne i ich własności
 - miary położenia
 - miary rozproszenia
 - miary asymetrii i koncentracji
 - miary zależności (współczynnik korelacji)
- Dodatek: Analiza opisowa w R

Czym są dane?

Niezbędna terminologia

- **Dane** $\equiv$ zbiór obiektów i ich atrybutów.
- Atrybut jest charakterystyką lub cechą danego obiektu.
- Zbiór (wektor) atrybutów opisuje obiekt.
- Różna terminologia
 - **atrybut** = zmienna, cecha, predyktor, charakterystyka, pole;
 - **obiekt** = rekord, punkt, przypadek, próbka, jednostka.


atrybuty

Tid	Refund	Marital Status	Taxable Income	Cheat
1	Yes	Single	125K	No
2	No	Married	100K	No
3	No	Single	70K	No
4	Yes	Married	120K	No
5	No	Divorced	95K	Yes
6	No	Married	60K	No
7	Yes	Divorced	220K	No
8	No	Single	85K	Yes
9	No	Married	75K	No
10	No	Single	90K	Yes

obiekty

Dane

Przykład 1 – Dane o 93 samochodach sprzedawanych w USA w roku 1993. (źródło: R-pakiet MASS)



Showing 1 to 17 of 93 entries


```

> library(MASS)
> data(Cars93)
> view(Cars93)

```

Dane

Przykład 2 – fragment danych socjodemograficznych (źródło: R-pakiet *Przewodnik*)



	wiek	wykształcenie	st.cywilny	plec	praca	cisnienie.skurczowe	cisnienie.rozkurczowe
1	70	zawodowe	w związku	mezczyzna	uczen lub pracuje	143	83
2	66	zawodowe	w związku	kobieta	uczen lub pracuje	123	80
3	71	zawodowe	singiel	uczen lub pracuje	167	80	
4	57	srednie	w związku	mezczyzna	uczen lub pracuje	150	87
5	45	srednie	w związku	kobieta	uczen lub pracuje	130	83
6	48	srednie	w związku	mezczyzna	nie pracuje	138	75
7	53	srednie	w związku	mezczyzna	uczen lub pracuje	149	80
8	61	wyzsze	w związku	mezczyzna	uczen lub pracuje	103	63
9	63	srednie	w związku	kobieta	uczen lub pracuje	125	78
10	47	wyzsze	w związku	mezczyzna	uczen lub pracuje	158	89
11	71	zawodowe	singiel	kobieta	uczen lub pracuje	148	86
12	71	wyzsze	w związku	kobieta	uczen lub pracuje	127	80
13	49	srednie	w związku	mezczyzna	uczen lub pracuje	138	80


```
> library(Przewodnik)
> data(daneSoc)
> View(daneSoc)
```

Podstawy eksploracyjnej analizy danych

5/90

Dane

Przykład 3 – fragment danych zawierających informacje nt. pasażerów Titanica (źródło: R-pakiet *titanic*)



	Passengerid	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	1	0	3	Braund, Mr. Owen Harris	male	22.00	1	0	A/5 21171	7.2500	S	
2	2	1	1	Cummings, Mrs. John Bradley (Florence Briggs Thayer)	female	38.00	1	0	PC 17599	71.2833	C85	C
3	3	1	3	Heikkinen, Miss. Laina	female	26.00	0	0	STON/O2. 3101282	7.9250	S	
4	4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35.00	1	0	113803	53.1000	C123	S
5	5	0	3	Allen, Mr. William Henry	male	35.00	0	0	373450	8.0500	S	
6	6	0	3	Moran, Mr. James	male	NA	0	0	330877	8.4583	Q	
7	7	0	1	McCarthy, Mr. Timothy J	male	54.00	0	0	17463	51.8625	E46	S
8	8	0	3	Palsson, Master. Gosta Leonard	male	2.00	3	1	349909	21.0750	S	
9	9	1	3	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female	27.00	0	2	347742	11.1333	S	
10	10	1	2	Nasser, Mrs. Nicholas (Adele Achem)	female	14.00	1	0	237736	30.0708	C	
11	11	1	3	Sandstrom, Miss. Marguerite Rut	female	4.00	1	1	PP 9549	16.7000	G6	S
12	12	1	1	Bonnell, Miss. Elizabeth	female	58.00	0	0	113783	26.5500	C103	S
13	13	0	3	Saunderscock, Mr. William Henry	male	20.00	0	0	A/S. 2151	8.0500	S	
14	14	0	3	Andersson, Mr. Anders Johan	male	39.00	1	5	347082	31.2750	S	
15	15	0	3	Vestrom, Miss. Hulda Amanda Adolfina	female	14.00	0	0	350406	7.8542	S	
16	16	1	2	Hewlett, Mrs. (Mary D Kingcome)	female	55.00	0	0	248706	16.0000	S	
17	17	0	3	Rice, Master. Eugene	male	2.00	4	1	382652	29.1250	Q	
18	18	1	2	Williams, Mr. Charles Eugene	male	NA	0	0	244373	13.0000	S	
19	19	0	3	Vander Planke, Mrs. Julius (Emelia Maria Vandemo...	female	31.00	1	0	345763	18.0000	S	
20	20	1	3	Massei, Mrs. Fatima	female	NA	0	0	2649	7.2250	C	
21	21	0	2	Fynney, Mr. Joseph J	male	35.00	0	0	239865	26.0000	S	

```
> library(titanic)
> data(titanic_train)
> View(titanic_train)
```

Podstawy eksploracyjnej analizy danych

6/90

Analiza opisowa danych

Główne cele

- Zwięzły opis danych za pomocą **statystyk opisowych**, w szczególności:
 - miar położenia (średnia, mediana, moda itp.),
 - miar rozproszenia (wariancja, odchylenie standardowe itp.).
- Przedstawienie struktury danych za pomocą **wykresów** (np. histogramów, diagramów słupkowych, wykresów rozrzutu).
- **Porównywanie** różnych zbiorów danych.

Uwaga

W analizie opisowej nie odwołujemy się do mechanizmów losowych (modeli probabilistycznych)!

Analiza opisowa i rodzaje cech statystycznych

- Spotykamy się z nowymi danymi po raz pierwszy.
- Naszym zadaniem jest opis podstawowych własności danych.
- **Pierwszy krok:** musimy ustalić jaki jest typ danych (rodzaj cech/zmiennych).

Rodzaje cech statystycznych

- **Cechy ilościowe (mieralne)** – takie cechy, które dadzą się wyrazić za pomocą jednostek miary w pewnej skali (np. wzrost (w cm), waga (w kg), wiek (w latach)).
- **Cechy jakościowe (niemieralne)** – cechy, które nie mogą być w sposób jednoznaczny scharakteryzowane przy pomocy liczb (np. płeć, grupa krwi, kolor włosów).

Uwaga

Z podziałem cech na jakościowe i ilościowe wiąże się stosowanie różnych metod/narzędzi opisowej analizy danych!

Podkategorie cech ilościowych

- **Cechy ciągłe** – mogą przyjmować w zasadzie każdą wartość z określonego przedziału liczbowego (np. wzrost, ciężar ciała, temperatura).
- **Cechy dyskretne** – mogą przyjmować wartości ze zbioru skończonego lub przeliczalnego (np. liczba pracowników, liczba wyprodukowanych elementów).

Podkategorie cech jakościowych

- **Cechy porządkowe** – możliwe wartości (kategorie) są uporządkowane np.: odpowiedź na pytanie ankietowe dot. palenia papierosów: 'nigdy', 'rzadko', 'często';
 $wzrost \in \{niski, sredni, wysoki\}$.
- **Cechy nominalne** – cechy jakościowe, które nie są porządkowe, np.: kolor oczu, płeć itp.

Rodzaje cech statystycznych - podsumowanie

Rodzaj cechy	Podkategoria	Przykłady
Ilościowe	ciągłe	wzrost, masa ciała, temperatura
	dyskretne	liczba pracowników, liczba wyprodukowanych elementów
Jakościowe	nominalne	płeć, kolor oczu, kraj pochodzenia
	porządkowe	częstość palenia papierosów, poziom wykształcenia

Tabela: Taksonomia rodzajów cech

Graficzna prezentacja danych

Motywacja

- Surowe wyniki eksperymentów, pomiarów czy badań ankietowych są często trudne do analizy.
- Konieczne jest odpowiednie przekształcenie danych i ich uproszczenie ułatwiające analizę, które wiąże się jednak z pewną utratą informacji.
- Wykresy zazwyczaj przekazują więcej informacji niż kilka wskaźników liczbowych (redukcja informacji jest mniejsza).
- Możemy także otrzymać identyczne wartości wskaźników dla dwóch istotnie różnych wykresów!

Graficzna prezentacja danych – podstawowe wykresy

Wybór odpowiednich narzędzi graficznych (wykresów) zależy od rodzaju danych (cech):

- ① wykresy dla danych (zmiennych/cech) jakościowych,
- ② wykresy dla danych (zmiennych/cech) ilościowych.

Wykresy dla danych jakościowych

Przykład: dane Cars93 – zmienna Type (typ samochodu)


Kategoria	Licznosci	Częstości (w%)
Compact	16	17.20%
Large	11	11.80%
Midsize	22	23.70%
Small	21	22.60%
Sporty	14	15.10%
Van	9	9.68%

Inne cechy jakościowe w danych Cars93: Manufacturer, Origin, DriveTrain, AirBags.

Wykresy dla danych jakościowych

Przykład: dane Cars93 – wykres słupkowy (ang. barplot) dla zmiennej Type (typ samochodu)

Wykres słupkowy (barplot) dla zmiennej Type



Wykresy dla danych jakościowych

Wykres słupkowy (ang. barplot) w R

R-kod

```
# tabela licznosci
licznosci.Type <- table(Type)

# Wykres slupkowy
barplot(licznosci.Type, col=1:length(levels(Type)))

# Dodajemy tytul
title("Wykres slupkowy (barplot) dla zmiennej Type")
```

Wykresy dla danych jakościowych

Wykres słupkowy (ang. barplot) w R

R-kod


```
# tabela częstości
czestosci.Type <- table(Type) / length(Type)

> czestosci.Type
Type
Compact      Large      Midsize      Small      Sporty      Van
0.17204301 0.11827957 0.23655914 0.22580645 0.15053763 0.09677419

# Wykres slupkowy
barplot(czestosci.Type, col=1:length(levels(Type)), ylab='czestosci')
```

Wykresy dla danych jakościowych

Przykład: dane Cars93 – wykres słupkowy (ang. barplot) dla zmiennej Type (typ samochodu)



Wykresy dla danych jakościowych

Wykres słupkowy (ang. barplot)

- Wysokości słupków są równe odpowiednim liczebnościom.
- Wspólna szerokość słupków jest dowolna.
- Kolejność kategorii dla zmiennej nie-porządkowej jest nieistotna.

Wykresy dla danych jakościowych


Przykład: Wykres słupkowy zmiennej Type dla grup wyznaczonych przez zmienną Origin

Origin	Type					
	Compact	Large	Midsize	Small	Sporty	Van
USA	7	11	10	7	8	5
non-USA	9	0	12	14	6	4

```
R> tabela.dwudzielcza <- table(Origin,Type)
```

Wykresy dla danych jakościowych

Przykład: Wykres słupkowy zmiennej Type dla grup wyznaczonych przez zmienną Origin



Wykresy dla danych jakościowych

Przykład: Wykres słupkowy zmiennej Type dla grup wyznaczonych przez zmienną Origin

R-kod


```
# tabela liczebności
tabela.dwudzielcza <- table(Origin, Type)

# Wykres słupkowy
barplot(tabela.dwudzielcza, beside=TRUE,
        names=names(tabela.dwudzielcza), col=c("blue", "red"))

# Dodajemy legendę
legend(x="topright", legend=rownames(tabela.dwudzielcza),
       fill=c("blue", "red"))
```

Wykresy dla danych jakościowych

Przykład: Znormalizowany wykres słupkowy (wykres mozaikowy)




```
R> plot(Origin~Type, col=c("red", "blue"))
```

Wykresy dla danych jakościowych

Diagramy kołowe – przykład

Diagram kołowy dla zmiennej Type



```
R> pie(table(Type))
```

Wykresy dla danych jakościowych

Diagramy kołowe

- Alternatywa dla wykresów słupkowych.
- **Ograniczenie:** Możemy przedstawić tylko dane procentowe.
- Wszystkie kategorie łącznie muszą sumować się do 100%.
- Mało czytelne, gdy występuje więcej kategorii.
- Porównanie dwóch wykresów jest bardziej kłopotliwe niż dla wykresów słupkowych.

Wykresy dla danych ilościowych

Dwa przypadki:

- 1 Mała liczba wartości (rozkłady dyskretne o małej liczbie wartości),
- 2 Duża liczba wartości (rozkłady ciągłe; rozkłady dyskretne o dużej liczbie wartości).

Wykresy dla danych ilościowych


Mała liczba wartości (rozkłady dyskretne o małej liczbie wartości)

- **Przykład:** wynik rzutów kostką.
- Wynik przedstawiamy jako diagram licznosci lub diagram częstości.
- Oznaczenia:
 $x_1, x_2, \dots, x_k$ – zaobserwowane (różne) wartości cechy ilościowej (zakładamy uporządkowanie)
 $n_1, n_2, \dots, n_k$ – liczba powtórzeń (gdzie:
 $n_1 + n_2 + \dots + n_k = n$)
- diagram liczebności: $\{(x_1, n_1), (x_2, n_2), \dots, (x_k, n_k)\}$
- diagram częstości: $\{(x_1, n_1/n), (x_2, n_2/n), \dots, (x_k, n_k/n)\}$

Wykresy dla danych ilościowych

Mała liczba wartości (rozkłady dyskretne o małej liczbie wartości)

Przykład: wynik rzutów kostką



Wykresy dla danych ilościowych

Duża liczba wartości

- **Zastosowanie:** rozkłady ciągłe oraz rozkłady dyskretne o dużej liczbie wartości.
- Podstawowe wykresy
 - histogram,
 - wykres pudełkowy (boxplot),
 - wykresy rozrzutu (scatterplot).

Wykresy dla danych ilościowych

Histogram


- Idea konstrukcji histogramu: grupujemy obserwacje w klasy, tworząc tzw. **szereg rozdzielczy**.
- Przykład:** zmienna Price (średnia cena samochodu). Liczba obserwacji: $n = 93$.

klasa	(7.35,18.3]	(18.3,29.2]	(29.2,40.1]	(40.1,51]	(51,62]
liczebność	48	31	12	1	1
częstość	48/93 51.6%	31/93 33.3%	12/93 12.9%	1/93 1.1%	1/93 1.1%


Wykresy dla danych ilościowych

Histogram w pakiecie R – dwa warianty

histogram liczebności



histogram unormowany



- histogram liczebności:
`R> hist(Price, breaks=klasy, probability=FALSE, ylab="liczebnosci")`
- histogram unormowany (pole=1):
`R> hist(Price, breaks=klasy, probability=TRUE, ylab="czestosci")`

Wykresy dla danych ilościowych


Jakie informacje można odczytać z histogramu?

Typowe pytania:

- Czy rozkład jest **jedno-** czy **wielomodalny**, tzn. ma jedno maksimum czy kilka maksimów lokalnych?
(moda $\equiv$ przedział, do którego wpada najwięcej wartości w próbie)
- Czy rozkład jest **symetryczny**?
- Czy rozkład jest **prawostronnie skośny** (dodatnio skośny lub prawostronnie asymetryczny)?
(prawy ogon histogramu jest znacznie dłuższy i maleje wolniej niż jego lewy ogon)
- Czy rozkład jest **lewostronnie skośny** (ujemnie skośny lub lewostronnie asymetryczny)?
(lewy ogon histogramu jest znacznie dłuższy i maleje wolniej niż jego prawy ogon)
- Czy rozkład jest **wyostrzony** czy raczej **spłaszczony**?


Wykresy dla danych ilościowych

Jakie informacje można odczytać z histogramu?



Wykresy dla danych ilościowych

Jakie informacje można odczytać z histogramu?



Wykresy dla danych ilościowych


Co wpływa na postać histogramu?

- Wybór początku histogramu i szerokości przedziału klasowego (parametr h) może mieć duży wpływ na kształt histogramu.
- Zwiększenie szerokości przedziału histogramu prowadzi do coraz większego wygładzenia (coraz większa redukcja informacji).
- Zmniejszenie szerokości przedziału histogramu prowadzi do zwiększenia stopnia zmienności histogramu (histogram staje się coraz bardziej nieregularny).
- **Uwaga:** wybór szerokości przedziału klasowego jest równoważny wyborowi liczby przedziałów klasowych.

Wykresy dla danych ilościowych

Histogram – wybór liczby klas (szerokości przedziałów)

Uwaga 1: Istnieją różne reguły wyboru liczby i szerokości klas histogramu. Liczba klas ma bardzo duży wpływ na kształt histogramu.



A) `R> hist(Price, breaks=c(7.35,18.3,29.2,40.1,51,62), col="lightblue")`

B) `R> hist(Price, breaks=5, col="lightgreen")`

C) `R> hist(Price, breaks=20, col="lightyellow")`

Uwaga 2: wskazana w breaks liczba przedziałów jest traktowana przez R jedynie jako sugestia, ostateczna liczba przedziałów może być inna!

Wykresy dla danych ilościowych

Histogram – pozostałe zagadnienia/problemy

● Wybór początku histogramu


- problem nie ma jednoznacznego rozwiązania,
- często stosuje się wybór początku tak, aby najmniejsza wartość była środkiem pierwszego przedziału histogramu.

● Brak ciągłości

- histogram jest funkcją nieciągłą i może niezbyt dobrze przybliżać gęstość rozkładu,
- rozwiązaniem może być konstrukcja tzw. łamanej częstości, tzn. połączenie środków górnych odcinków jego słupków,
- inne metody: zastosowanie wygładzonych oszacowań, np. jądrowy estymator gęstości (`R:> density(X)`).

Wykresy dla danych ilościowych

Alternatywa dla histogramu: łamana częstości, estymator jądrowy




Wykresy dla danych ilościowych

Wykresy rozrzutu (scatterplots)


- **Cel:** Analiza zależności pomiędzy zmiennymi.
- Standardowy wykres rozrzutu jest dwuwymiarowym wykresem par $\{(x_i, y_i)\}_{i=1, \dots, n}$
- Jest wykorzystywany do badania charakteru zależności pomiędzy dwiema zmiennymi ciągłymi.
- W przypadku, kiedy interesuje nas zbadanie zależności pomiędzy większą liczbą zmiennych konstruuje się również trójwymiarowe wykresy rozrzutu (x, y, z) .

Wykresy dla danych ilościowych

Wykres rozrzutu (scatterplot) – przykład



a) Wykres rozrzutu 2D



b) Wykres rozrzutu 3D

Wskaźniki sumaryczne

Ogólna idea

- Agregujemy informacje o rozkładzie cech za pomocą odpowiednich wskaźników sumarycznych (statystyk opisowych).
- Dzięki temu redukujemy ilość danych, wydobywając tylko te własności, które są dla nas istotne.

Podstawowe rodzaje wskaźników (statystyk opisowych)

- **Miary położenia** (Gdzie leży „centrum” próby?)
- **Miary rozrzutu (rozproszenia)** (Jak duże jest rozproszenie/rozrzut?)
- **Miary asymetrii rozkładu** (Czy rozkład badanej cechy jest symetryczny?)
- **Miary koncentracji/spłaszczenia rozkładu** (Jaki jest stopień wyostżenia rozkładu?)
- **Miary zależności** (Czy występuje i jak silna jest zależność (korelacja) pomiędzy dwiema cechami?)

Podstawowe rodzaje wskaźników (statystyk opisowych)

Przykłady wskaźników sumarycznych

- **Miary położenia:** średnia, mediana, średnia ucinana, moda (dominanta).
- **Miary rozproszenia:** wariancja, odchylenie standardowe, rozstęp próby, rozstęp międzykwartyłowy.
- **Miary asymetrii i spłaszczenia:** skośność, kurtoza.
- **Miary zależności:** współczynnik korelacji Pearsona.

Miary położenia (miary tendencji centralnej)

Średnia próbkowa (mean)

Oznaczenia: $X_1, X_2, \dots, X_n$ – obserwowane dane (próba o liczności n).

Definicja (Wartość średnia z próby (średnia próbkowa))


Jest to średnia arytmetyczna wartości cechy w próbie:

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$$

Miary położenia (miary tendencji centralnej)




Średnia próbkowa – przykład

Histogram zmiennej X



Miary położenia (miara tendencji centralnej)

Przykłady: różne rozkłady i jednakowa średnia próbkowa ($\bar{X} = 0$)



Miary/wskaźniki położenia (miary tendencji centralnej)

Średnia próbkowa – własności

- Średnia próbkowa charakteryzuje się brakiem odporności w sytuacji występowania tzw. obserwacji odstających (ang. outliers).
- Jest dobrą miarą położenia, gdy rozkład badanej zmiennej jest (przynajmniej w przybliżeniu) symetryczny.
- Gdy nie jest jednak symetryczny potrzebujemy innej miary.

Miary położenia (miary tendencji centralnej)

Średnia próbkowa – wrażliwość na obserwacje odstające

Przykład: Obserwujemy zarobki pracowników pewnej firmy.


wysokość zarobków	liczba pracowników
2500	6
3000	8
4000	4
6000	3
8000	2
16000	1

$$\text{Średnia płaca} = \frac{1}{24}(2500 * 6 + \dots + 16000 * 1) = 4375$$

Miary położenia (miary tendencji centralnej)

Średnia próbkowa – wrażliwość na obserwacje odstające

Przykład cd.: Obserwujemy zarobki pracowników pewnej firmy.



Miary położenia (miary tendencji centralnej)

Średnia próbkowa – wady

- **Pytanie:** Czy średnia próbkowa daje dobrą informację o przeciętnych zarobkach?
- Osoba ubiegająca się o pracę otrzymuje informację, że średnie zarobki w firmie wynoszą 4375, a tymczasem 18 osób (75%) zarabia mniej niż wynosi średnia!
- Jaki inny wskaźnik położenia byłby dobry w tej sytuacji?
- **Propozycja:** możemy wyznaczyć wartość środkową (medianę), tzn. taką liczbę, żeby na lewo i na prawo od niej było tyle samo obserwacji.

Miary położenia (miary tendencji centralnej)

Mediana próbkowa (median)

Mediana (wartość środkowa) jest liczbą, od której 50% (połowa) obserwowanych wartości zmiennej jest mniejsza, a tym samym pozostała połowa jest większa.

Definicja (Mediana próbkowa (wartość środkowa))

Porządkujemy elementy próby: $X_{(1)} \leq X_{(2)} \leq X_{(3)} \dots \leq X_{(n)}$

Mediana z próby jest definiowana wówczas jako:

- $x_{med} = X_{(n+1)/2}$, gdy n -nieparzyste
- $x_{med} = (X_{(n/2)} + X_{(n/2+1)})/2$, gdy n -parzyste

Miary położenia (miary tendencji centralnej)

Mediana – poprzedni przykład (zarobki)

- W tym przypadku otrzymujemy:
$$\text{mediana} = (X_{(12)} + X_{(13)})/2 = (3000 + 3000)/2 = 3000$$
- **Wniosek:** mediana lepiej niż średnia oddaje perspektywę zarobków w firmie!

Miary położenia (miary tendencji centralnej)

Mediana – własności

- **Zalety:** mediana charakteryzuje się brakiem wrażliwości (odpornością) w sytuacji występowania tzw. obserwacji odstających (nietypowych).
- **Wady:** Jeżeli liczność próby jest mała i kolejne elementy próby są dość odległe, to mediana jest niestabilnym wskaźnikiem położenia.
- Pomocne w uniknięciu niestabilności może być wprowadzenie tzw. średniej ucinanej (wewnętrznej).

Miary położenia (miary tendencji centralnej)

Średnia ucinana (trimmed mean)

Definicja (Średnia ucinana (z parametrem k))

$$\bar{X}_{tk} = \frac{1}{n - 2k} \sum_{i=k+1}^{n-k} X_{(i)}$$


Miary położenia (miary tendencji centralnej)

Kwantyle empiryczne

- Kwantylem empirycznym rzędu p nazywamy liczbę, od której jest mniejsze $p \cdot 100\%$ wszystkich obserwowanych wartości zmiennej.
- Kwantyle rzędu: 0.25, 0.5, 0.75 dzielą dane na 4 równe części i dlatego są nazywane **kwartylami**
- Q1 - dolny kwartył (= kwantyl rzędu 25%)
- mediana - środkowy kwartył (= kwantyl rzędu 50%)
- Q3 - górny kwartył (= kwantyl rzędu 75%)

Miary położenia (miary tendencji centralnej)

Kwartyle



Uwaga

Kwartył pierwszy Q_1 i trzeci Q_3 wyznaczamy następująco:

- W dwóch częściach danych, które powstały po wyznaczeniu mediany, ponownie wyznaczamy medianę.
- Wówczas mediana w pierwszej części odpowiada kwartyłowi pierwszemu Q_1 , a mediana w drugiej części – kwartyłowi trzeciemu Q_3 .


Miary położenia (miary tendencji centralnej)

Inne miary

- modalna (dominanta, moda, wartość najczęstsza) – wartość najczęściej występująca w próbie.
- średnia geometryczna
- średnia harmoniczna
- ...

Miary rozproszenia/rozzutu

Przykład: Dwie cechy o równych średnich i różnych wariacjach



Miary rozproszenia/rozzutu

Ogólna idea

- Analizujemy rozrzut zaobserwowanych wartości zmiennej.
- Rozrzut jest tym większy, im bardziej wartości zmiennej odchylają się od tendencji centralnej (np. wartości średniej).

Przykładowe zastosowania

- Chcemy porównać dwie technologie i stwierdzić, która jest lepsza.
- Porównujemy dwie inwestycje finansowe i chcemy ocenić, która jest mniej ryzykowna.

Miary rozproszenia/rozrzutu

Rozstęp próby

Definicja (Rozstęp próby (range))

$$R = X_{(n)} - X_{(1)},$$

gdzie $X_{(n)} = \max(X_1, X_2, \dots, X_n)$ i $X_{(1)} = \min(X_1, X_2, \dots, X_n)$

Miary rozproszenia/rozrzutu

Rozstęp próby – wady i ograniczenia

- Rozstęp jest niewrażliwy na kształt rozkładu.
- Zależy tylko od dwóch skrajnych wartości.
- Rozstęp charakteryzuje się brakiem odporności (dużą wrażliwością) na obserwacje odstające.

Miary rozproszenia/rozrzutu

Wariancja próbkowa

Definicja (Wariancja próbkowa)

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$$

Miary rozproszenia/rozrzutu

Wariancja próbkowa – uwagi

- Czasami zastępuje się ułamek $\frac{1}{n-1}$ przez $\frac{1}{n}$ (ma to związek z własnością nieobciążoności).
- Wariancja bazuje na kwadratach odchyłeń czyli kwadratach jednostki pomiarowej.
- Ponownie, wadą tego wskaźnika jest brak odporności na obserwacje odstające.

Miary rozproszenia/rozrzutu

Odchylenie standardowe (sd)

Definicja (Odchylenie standardowe cechy)

$$S = \sqrt{S^2}$$

Miary rozproszenia/rozrzutu

Obserwacje odstające

Problem

- Wskaźniki rozproszenia (rozstęp z próby, wariancja, odchylenie standardowe) nie są odporne na obserwacje odstające.
- Potrzebujemy innych miar!

Miary rozproszenia/rozrzutu

Rozstęp międzykwartylowy (IQR)


Rozstęp międzykwartylowy (ang. inter quartile range) jest odległością pomiędzy Q_1 (dolnym kwartylem) a Q_3 (górnym kwartylem).

Definicja (Rozstęp międzykwartylowy (IQR))

$$IQR = Q_3 - Q_1$$

Wykres pudełkowy (boxplot)

Idea: przedstawiamy kilka podstawowych wskaźników na jednym wykresie



Obserwacje odstające:

$\{X_i : X_i > Q_3 + 1.5 \cdot IQR \text{ lub } X_i < Q_1 - 1.5 \cdot IQR\}$


Wąsy: minimum i maksimum dla obserwacji nieodstających

Wykres pudełkowy (boxplot)

Jak to zrobić w R?

R-kod


```
boxplot(Price, col="blue")  
title("Wykres pudełkowy (boxplot) - zmienna Price")
```



Wykres pudełkowy (boxplot)

Wersja z podziałem na grupy/kategorie

Zroznicowanie ceny dla samochodów różnych typów



```
R> boxplot(Price~Type, col=rainbow(6))
```

Miary asymetrii i koncentracji

Współczynnik skośności (asymetrii) rozkładu


$$skewness = \frac{\sqrt{n} \sum_{i=1}^n (X_i - \bar{X})^3}{(\sum_{i=1}^n (X_i - \bar{X})^2)^{3/2}}$$

Interpretacja:

- $skewness > 0$ – cecha ma rozkład z asymetrycznym ogonem z prawej strony (tzw. rozkład prawostronnie skośny),
- $skewness < 0$ – cecha ma rozkład z asymetrycznym ogonem z lewej strony (tzw. rozkład lewostronnie skośny),
- $skewness \approx 0$ – cecha ma rozkład symetryczny.

Miary asymetrii i koncentracji

Współczynnik skośności (asymetrii) rozkładu



Miary asymetrii i koncentracji

Współczynnik skośności (asymetrii) rozkładu

Alternatywny sposób analizy symetrii rozkładu: porównujemy średnią, medianę i wartość modalną. Najczęściej obserwujemy, że:

- dla rozkładu **symetrycznego**:
średnia $\approx$ mediana $\approx$ modalna
- dla rozkładu o **asymetrii prawostronnej**:
średnia $>$ mediana $>$ modalna
- dla rozkładu o **asymetrii lewostronnej**:
średnia $<$ mediana $<$ modalna

Miary asymetrii i koncentracji


Współczynnik kurtozy (współczynnik wyostrenia rozkładu)

$$kurtosis = \frac{n \sum_{i=1}^n (X_i - \bar{X})^4}{(\sum_{i=1}^n (X_i - \bar{X})^2)^2} - 3$$

- Oceniamy stopień spłaszczenia rozkładu.
- **Interpretacja:**
 - $kurtosis \approx 0$ – rozkład zbliżony do rozkładu normalnego (tzw. rozkład mezokurtyczny),
 - $kurtosis > 0$ – rozkład wyostrzony (tzw. rozkład leptokurtyczny),
 - $kurtosis < 0$ – rozkład spłaszczony (tzw. rozkład platykurtyczny).

Miary asymetrii i koncentracji

Współczynnik kurtozy (współczynnik wyostrenia rozkładu)



Miary zależności

Współczynnik korelacji próbkowej

$$r_{XY} = \frac{\sum_{i=1}^n (X_i - \bar{X})(Y_i - \bar{Y})}{\sqrt{\sum_{i=1}^n (X_i - \bar{X})^2} \sqrt{\sum_{i=1}^n (Y_i - \bar{Y})^2}},$$

gdzie:

- $X_1, X_2, \dots, X_n$ – wartości pierwszej zmiennej,
- $Y_1, Y_2, \dots, Y_n$ – wartości drugiej zmiennej,
- $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$,
- $\bar{Y} = \frac{1}{n} \sum_{i=1}^n Y_i$,

Miary zależności

Współczynnik korelacji próbkowej - własności

- **Zakres wartości:** $-1 \leq r_{XY} \leq 1$
- Jeżeli wykres rozrzutu ma charakter monotoniczny (rośnie lub maleje), to wartość współczynnika r_{XY} będzie informowała o kierunku zależności (dodatnim lub ujemnym).
- Jeżeli nie wiemy czy zależność jest monotoniczna, nie możemy tego kryterium stosować!


Miary zależności

Współczynnik korelacji próbkowej - własności

- Wartości bliskie -1 lub 1 wskazują, że wykres rozrzutu będzie skupiony wokół prostej.
- Gdy wykres rozrzutu ma charakter liniowy, r_{XY} mierzy siłę zależności między zmiennymi.
- Nie jest odporny na obserwacje odstające (jest oparty na średnich i odch. stand.).
- Nie może być wykorzystany do ustalenia relacji przyczynowej między zmiennymi (tzn. stwierdzenia, które zmienna jest zależna, a które niezależna). Zamiana X i Y nie ma wpływu na wartość r_{XY} .

Miary zależności

Współczynnik korelacji próbkowej - przykład



Dodatek: Analiza opisowa w R

Podstawowe wskaźniki sumaryczne

wskaźnik	R-funkcja
średnia próbkowa	mean
mediana	median
średnia ucięta	mean(..., trim= α)
kwantyle próbkowe	quantile
minimum	min
maksimum	max
wariancja próbkowa	var
odchylenie standardowe	sd
rozstęp z próby	range
rozstęp międzykwartyłowy	IQR
skośność	skewness {e1071}
kurtoza	kurtosis {e1071}
wsp. korelacji	cor(X,Y)

Dodatek: Analiza opisowa w R

Wskaźniki sumaryczne – funkcja `summary(...)`

R-kod

```
> summary(Price)
      Min.   1st Qu.   Median     Mean   3rd Qu.    Max.
  7.40    12.20    17.70    19.51    23.30    61.90

> summary(Type)
 Compact   Large Midsize Small   Sporty   Van
      16       11      22     21     14      9
```

Dodatek: Analiza opisowa w R

Wskaźniki sumaryczne w grupach – funkcja `by(...)`

Przykład: Wyznaczamy wskaźniki opisowe dla zmiennej `Price` (cena samochodu), osobno dla poszczególnych typów samochodów (tzn. w grupach wyznaczonych przez zmienną `Type`)

R-kod

```
> by(data=Price, INDICES=Type, FUN=summary)
```

INDICES: Compact

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
11.10	13.38	16.15	18.21	20.68	31.90

INDICES: Large

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
18.40	20.00	20.90	24.30	26.95	36.10

INDICES: Midsize

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
13.90	16.78	26.20	27.22	34.20	61.90

INDICES: Small

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
7.40	8.60	10.00	10.17	11.30	15.90

INDICES: Sporty

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
------	---------	--------	------	---------	------

INDICES: Van

Dodatek: Analiza opisowa w R


Wykresy - podstawowe funkcje graficzne

wykres	R-funkcja
wykres słupkowy	barplot
diagram kołowy	pie
histogram	hist
wykres pudełkowy	boxplot
wykres rozrzutu	plot(x,y)

Dodatek: Analiza opisowa w R

Wykresy – grafika z wykorzystaniem ggplot2


Przykład 1



Dodatek: Analiza opisowa w R

Wykresy – grafika z wykorzystaniem ggplot2

Przykład 2





Podstawy eksploracyjnej analizy danych

85/90

Dodatek: Analiza opisowa w R

Wykresy – grafika z wykorzystaniem ggplot2

Ściągowka z najważniejszymi poleceniami:




(źródło: <https://github.com/rstudio/cheatsheets/blob/master/data-visualization-2.1.pdf>)

Dodatek: Analiza opisowa w R

Wykresy – metody zaawansowane

Przykład: wykres typu *heatmap* (mapa ciepła).



(pakiet `gplots`, funkcja `heatmap.2`)

Podstawy eksploracyjnej analizy danych

87/90

Dodatek: Analiza opisowa w R

Wykresy – gdzie szukać dodatkowych informacji?

- **ggplot2_przyklady.R** - R-skrypt z przykładami wykresów na bazie ggplot2 (⇒ ePortal PWr)
- <http://www.statmethods.net/graphs/index.html>
- http://zoonek2.free.fr/UNIX/48_R/all.html
- <https://shiny.srvanderplas.com/r-graph-catalog/>
- <https://r-graph-gallery.com/>
- <https://ggplot2.tidyverse.org/>
- <https://ggobi.github.io/ggally/>
- ...

Pytania?

Dziękuję za uwagę!