

Przygotowanie danych do analiz

Adam Zagdański

Wydział Matematyki, Politechnika Wrocławska,
e-mail: Adam.Zagdanski@pwr.edu.pl

Wrocław
20 marca 2026

Wstępne przetwarzanie danych – wprowadzenie
Obserwacje brakujące
Obserwacje odstające/nietypowe
Podstawowe transformacje danych
Pozostałe transformacje

Plan wykładu

- Problem jakości danych.
- Wartości brakujące (ang. missing values).
- Obserwacje nietypowe/odstające (ang. outliers).
- Podstawowe przekształcenia (transformacje) danych.

Problem jakości danych

Eksploracja danych vs. statystyka

● Statystyka

- Planujemy eksperymenty i badania od podstaw.
- Dane zbierane są zgodnie z określonymi wymaganiami dotyczącymi ich jakości.
- Dzięki temu mamy możliwość zapewnienia wysokiej jakości danych już na etapie ich pozyskiwania.

● Eksploracja danych

- Często analizowane są wcześniej zebrane dane, pierwotnie pozyskane w innym lub bliżej nieokreślonym celu.
- Zazwyczaj nie mamy możliwości kontrolowania procesu zbierania danych.
- W konsekwencji możliwość poprawy jakości danych „u źródła” jest ograniczona.

Problem jakości danych

Uwaga

Ponieważ w przypadku eksploracji danych zapewnienie odpowiednio wysokiej jakości danych zazwyczaj nie jest możliwe, koncentrujemy się na:

- ① *wykrywaniu i korygowaniu problemów związanych z jakością danych (tzw. czyszczeniu danych),*
- ② *stosowaniu algorytmów odpornych na niską jakość danych.*


Problem jakości danych

Konieczność wstępnego przetwarzania danych

- Surowe dane często charakteryzują się:
 - błędami pomiarowymi (wynikającymi z ograniczeń urządzeń pomiarowych),
 - brakującymi wartościami (ang. missing values),
 - pomyłkami w procesie zbierania i przetwarzania danych.
- Dane mogą także nie spełniać założeń lub wymagań danej metody czy modelu; przed ich wykorzystaniem konieczne jest zastosowanie odpowiednich transformacji.
- **Wniosek:** Zebrane dane często wymagają odpowiedniego przetwarzania wstępnego (ang. preprocessing), które ułatwia ich analizę.

Konieczność wstępnego przetwarzania danych

Ogólny schemat eksploracji danych



(źródło: Introduction to Data Mining, Tan, Steinbach, Karpatne, Kumar)

Wstępne przetwarzanie danych


Podstawowe zagadnienia

- 1 Sprawdzenie poprawności danych, usunięcie zduplikowanych obiektów, usunięcie cech nieprzydatnych w analizie (np. cech typu identyfikator), usunięcie cech nadmiarowych (np. te same wielkości dla różnych skal pomiarowych).
- 2 Obsługa wartości brakujących (ang. missing values).
- 3 Identyfikacja i interpretacja obserwacji odstających / nietypowych (ang. outliers).
- 4 Odpowiednie transformacje danych ułatwiające analizę.

Wstępne przetwarzanie danych

Pozostałe uwagi

- **Obciążenie związane z pozyskiwaniem danych (ang. sampling bias):** dane, na bazie których przeprowadzamy analizy powinny być reprezentatywne. W szczególności, ważne jest aby dobrze odzwierciedlały rzeczywistą strukturę wyjściowej populacji.
- **Przykład:** utrata struktury danych związana z próbkowaniem



(źródło: Introduction to Data Mining, Tan, Steinbach, Karpatne, Kumar)

Wstępne przetwarzanie danych

Pozostałe uwagi

- **Usunięcie ewentualnych niezgodności występujących w danych:** niektóre formy niezgodności są łatwe do wykrycia (np. wzrost czy wiek nie może być < 0). W innym przypadku konieczna może być konsultacja z ekspertem z danej dziedziny.

Uwaga

Rozumienie danych jest kluczowe dla poprawności wykonanych analiz i prawidłowej interpretacji wyników!

Wstępne przetwarzanie danych

Pozostałe uwagi

- **Poprawna reprezentacja danych w programach komputerowych:** Po wczytaniu danych powinniśmy upewnić się czy wszystkie typy zmiennych zostały prawidłowo rozpoznane (np. w pakiecie R: typ `numeric` – cecha ilościowa i typ `factor` – cecha jakościowa).
- Dobrze jest także upewnić się czy nie zastosowany został niestandardowy sposób kodowania wartości brakujących (w R: `NA`).

Obserwacje brakujące (ang. missing values)

Przyczyny występowania obserwacji (wartości) brakujących

- Niekompletne wyniki pomiarów.
- Informacja nie została zebrana (np. mogła nie być podana przez ankietowanego).
- Pewna cecha nie miała sensu ale występuje np. w uniwersalnej ankiecie (np. dane medyczne dot. pacjentów: cecha może dotyczyć tylko kobiet albo tylko mężczyzn).
- Błędy w przetwarzaniu danych.

Uwaga

Wczytując dane musimy uważać na sposób kodowania wartości brakujących! Często zdarzają się niestandardowe sposoby kodowania braków, np. wartość '0' lub '-99999'.

Obserwacje brakujące (ang. missing values)

Przykład: brakujące wartości w danych Cars93.

ID	Manufacturer	Model	Type	Rear.seat.room	Luggage.room
16	Chevrolet	Lumina_APV	Van	30.50	NA
17	Chevrolet	Astro	Van	33.50	NA
19	Chevrolet	Corvette	Sporty	NA	NA
26	Dodge	Caravan	Van	26.50	NA
36	Ford	Aerostar	Van	30.00	NA
56	Mazda	MPV	Van	27.50	NA
57	Mazda	RX-7	Sporty	NA	NA
66	Nissan	Quest	Van	27.00	NA
70	Oldsmobile	Silhouette	Van	30.50	NA
87	Toyota	Previa	Van	35.00	NA
89	Volkswagen	Eurovan	Van	34.00	NA

NA $\equiv$ **Not Available** – kod brakujących wartości w pakiecie R.

Pytanie: Jaka jest przyczyna występowania wartości brakujących (NA) w tych danych?

Sposoby radzenia sobie z brakującymi obserwacjami

- Usuwanie obiektów (rekordów/wierszy), dla których są braki – najprostsze rozwiązanie ale nie najlepsze. Potencjalne problemy: utrata informacji, pogorszenie efektywności stosowanych metod eksploracji danych.
- Usuwanie zmiennych (cech/kolumn), dla których są braki.
- Uzupełnianie (imputacja) brakujących wartości - różne sposoby:
 - proste metody: średnia, mediana, moda itp.
 - zaawansowane metody: k-nearest neighbors (k-NN), joint modeling (JM), fully conditional specification (FCS) itp.
- Ignorowanie brakujących wartości – niektóre algorytmy eksploracji danych mogą być zastosowane pomimo występowania braków.

Obsługa wartości brakujących w pakiecie R

- NA – specjalny symbol używany w R do oznaczenia wartości brakujących (NA $\equiv$ Not Available),
- `is.na()` – sprawdzenie czy dane zawierają brakujące wartości (wynikiem jest wektor/tablica wartości logicznych TRUE/FALSE),
- `na.omit()` – usunięcie brakujących wartości z wektora,
- `complete.cases()` – wektor logiczny wskazujący, które przypadki są kompletne, tj. nie mają brakujących wartości.

R-kod (Przykład obsługi wartości brakujących w środowisku R)

```
# ile jest braków danych dla zmiennej Rear.seat.room?  
> sum(is.na(Cars93$Rear.seat.room))  
# które to auta?  
> Cars93$Model[is.na(Cars93$Rear.seat.room)]  
# wybieramy tylko kompletne rekordy  
> Cars93[complete.cases(Cars93),]
```

Obserwacje odstające (outliers)

- Obserwacja odstająca (ang. outlier) to:
 - ① **Nietypowy obiekt**, którego charakterystyki różnią się od innych obiektów w zbiorze danych,
 - ② **Nietypowe wartości cechy (atrybutu)**.
- Obserwacje odstające nie zawsze są wynikiem błędów!
- Obserwacje takie mogą być całkowicie poprawne.
- W przeciwieństwie do szumu, obserwacje odstające są często przedmiotem zainteresowania (np. oszustwa przy użyciu karty kredytowej, detekcja intruzów w sieciach komputerowych, wykrywanie awarii systemów technicznych itp.).
- Znanych jest wiele metod wykrywania (identyfikacji) obserwacji odstających.
- **Podstawowy problem:** brak precyzyjnej definicji i subiektywizm metod.

Sposoby postępowania z obserwacjami odstającymi

- Eliminacja obserwacji ze zbioru danych.
- Potraktowanie obserwacji odstających jako brakujących danych i uzupełnienie tych danych odpowiednimi metodami (np. zastąpienie średnią arytmetyczną wyznaczoną dla obserwacji sąsiednich lub reprezentujących podobne cechy).
- **W każdym przypadku należy je zidentyfikować i trzeba przyrzeć się im dokładniej (znaleźć ich przyczynę).**

Metody identyfikacji obserwacji odstających

- ❶ Analiza jednowymiarowa: analiza wartości poszczególnych cech (atrybutów).
- ❷ Analiza wielowymiarowa.
- ❸ Wykrywanie obserwacji, które „nie pasują” do modelu.


Metody identyfikacji obserwacji odstających

1) Analiza jednowymiarowa: analiza wartości poszczególnych cech (atrybutów)


- Proste narzędzia graficzne: histogram, wykres pudełkowy.
- Formalne metody statystyczne: zakładamy odpowiedni model parametryczny opisujący rozkład naszych danych (np. rozkład normalny).
- W praktyce za obserwacje odstające często uznaje się te, które wykraczają poza przedział $[Q_1 - 1.5/IQR, Q_3 + 1.5/IQR]$
- Obserwacje ekstremalnie odstające to natomiast takie, które wykraczają poza przedział $[Q_1 - 3/IQR, Q_3 + 3/IQR]$.

Obserwacje odstające

Przykład: Wykorzystanie wykresów pudełkowych (boxplot) do identyfikacji wartości odstających dla zmiennej Price.



A) wszystkie typy aut



B) z podziałem na typy



Metody identyfikacji obserwacji odstających

2) Analiza wielowymiarowa

- Proste narzędzia graficzne: wykresy rozrzutu 2D lub 3D.
- Metody dystansowe: analiza odległości pomiędzy obserwacjami a ich centrum (wektorem średnich), metody najbliższego sąsiada, metody oparte na grupowaniu danych (ang. clustering).
- Formalne metody statystyczne: dopasowanie odpowiedniego rozkładu do danych (m.in. podejście oparte na funkcji wiarygodności).

Obserwacje odstające

Przykład: Identyfikacja obserwacji odstających. Analiza 1D vs 2D.





A) widoczna obserwacja odstająca **B)** brak obserwacji odstających

Wniosek: Identyfikacja obserwacji nietypowych polegająca na niezależnej analizie poszczególnych atrybutów nie zawsze daje dobre wyniki.

Obserwacje odstające

Przykład: Metody oparte na analizie odległości.



A) odległość euklidesowa

$$d_E(x, y) = \sqrt{(x - y)'(x - y)}$$

B) odległość Mahalanobisa

$$d_M(x, y) = \sqrt{(x - y)'\Sigma^{-1}(x - y)}$$

Wniosek: Odległość Mahalanobisa uwzględnia korelacje między zmiennymi, co pozwala skutecznie wykrywać obserwacje odstające w danych wielowymiarowych.

(źródło: Grentzelos et al. A comparative study of methods to handle outliers in multivariate data analysis. Comp and Math Methods. 2021;3:e1129.)



Metody identyfikacji obserwacji odstających

3) Wykrywanie obserwacji, które „nie pasują” do modelu

- Metody wykrywania obserwacji odstających w analizie regresji.
- Identyfikacja tzw. obserwacji wpływowych (obserwacji, które mają istotny wpływ na postać modelu).
- Diagnostyka modelu: analiza błędów (reszt).

Obserwacje odstające

Przykład: wpływ obserwacji odstającej na postać dopasowanego modelu regresji liniowej: $Y = \beta_0 + \beta_1 \cdot x + \epsilon$.



A) brak obserwacji odstających **B)** widoczna obserwacja odstająca

Podstawowe transformacje danych

Dlaczego przekształcamy dane?

- Standaryzacja/normalizacja: Przekształcamy zmienne o różnych jednostkach (skalach pomiarowych) w wielkości niemiarowane i porównywalne. Ujednolicamy w ten sposób wpływ każdej ze zmiennych na wyniki.
- Ułatwienie procesu modelowania: oryginalne dane często nie spełniają założeń nakładanych przez dany model (np. założenie o liniowej zależności, założenie o normalności rozkładu itp.).
- Zredukowanie wpływu obserwacji odstających.
- Dyskretyzacja/przedziałowanie: przekształcenie zmiennych ciągłych (ilościowych) na zmienne jakościowe.
- Binaryzacja – konwersja atrybutów ilościowych i jakościowych na zmienne/cechy binarne.

Podstawowe transformacje danych

- **Ogólnie:** Transformacje zmiennych (cech) – przekształcenie zastosowane dla wszystkich wartości danej zmiennej.
- Podstawowe transformacje:
 - normalizacja/standaryzacja,
 - transformacje funkcyjne,
 - przedziałowanie/dyskretyzacja cech ciągłych,
 - łączenie kategorii dla zmiennych jakościowych.

Podstawowe transformacje danych

Standaryzacja

Cel standaryzacji: Chcemy aby różne skale pomiarowe (dla różnych zmiennych) nie miały wpływu na wyniki analiz.

- **Centrowanie:** od wartości cechy odejmujemy jej średnią próbkową:

$$\tilde{X} = X - \text{mean}(X)$$

- **Skalowanie:** wartość cechy dzielimy przez próbkowe odchylenie standardowe (standard deviation):

$$\tilde{X} = X / \text{sd}(X)$$

- **Standaryzacja:** wykonujemy równocześnie centrowanie i skalowanie


$$\tilde{X} = \frac{X - \text{mean}(X)}{\text{sd}(X)}.$$

- Cechy po standaryzacji będą miały średnią 0 i wariancję 1.

Podstawowe transformacje danych

Standaryzacja

Przykład: porównanie danych przed i po wykonaniu standaryzacji.



Standaryzacja w R

- W środowisku R do przeprowadzenia standaryzacji możemy wykorzystać funkcję `scale()`, za pomocą której można wykonać centrowanie, skalowanie lub obie te transformacje (czyli standaryzację danych).
- `scale(x, center = TRUE, scale = TRUE)`

Podstawowe transformacje danych

Alternatywa dla standaryzacji

- **Problem:** średnia i odchylenie standardowe nie są odporne na obserwacje odstające. Możemy rozważyć zastosowanie innych (bardziej odpornych) miar, np.:

$$\tilde{X} = \frac{X - \text{med}(X)}{\sigma(X)},$$

- $\text{med}(X)$ – mediana (wartość środkowa),
- $\sigma(X)$ – średnie odchylenie bezwzględne,
 $\sigma(X) = \sum_{i=1}^n |x_i - \mu| / n$ (gdzie μ - średnia albo mediana).
- Alternatywą dla standaryzacji może być także normalizacja min-max

$$\tilde{X} = \frac{X - \min(X)}{\text{zakres}(X)} = \frac{X - \min(X)}{\max(X) - \min(X)}.$$

Znormalizowane wartości będą należały do przedziału $[0, 1]$.

- **Uwaga:** Terminy standaryzacja i normalizacja są często używane zamiennie.

Podstawowe transformacje danych

Czy standaryzacja może utrudnić analizę?




FIGURE 14.5. Simulated data: on the left, K -means clustering (with $K=2$) has been applied to the raw data. The two colors indicate the cluster memberships. On the right, the features were first standardized before clustering. This is equivalent to using feature weights $1/[2 \cdot \text{var}(X_j)]$. The standardization has obscured the two well-separated groups. Note that each plot uses the same units in the horizontal and vertical axes.

(źródło: Elements of Statistical Learning (2nd Ed.) Hastie, Tibshirani & Friedman 2009, Chap 14)

Podstawowe transformacje danych

Przekształcenia funkcyjne

- Cel stosowania transformacji funkcyjnych
 - przekształcenie do rozkładu normalnego (wymagane niektórych metod),
 - stabilizacja (poprawa jednorodności) wariancji,
 - zredukowanie wpływu obserwacji odstających,
 - zmiana charakteru zależności (zależności nieliniowe → zależności liniowe).
- Popularne transformacje nieliniowe: $\log(x)$, $\sqrt{x}$, $1/x$.
- Rodzina transformacji Boxa-Coxa:

$$\tilde{X}_\lambda = \begin{cases} (X^\lambda - 1)/\lambda & \text{dla } \lambda \neq 0 \\ \log(X) & \text{dla } \lambda = 0 \end{cases}$$

- Uwaga: istnieją metody pozwalające na wybór optymalnej wartości parametru λ transformacji Boxa-Coxa.

Przekształcenia funkcyjne

Własności transformacji o których należy pamiętać

- Transformacje najczęściej zmieniają charakter danych, np. transformacja $1/x$ redukuje znaczenie wartości > 1 i jednocześnie powoduje, że wartości $0 < x < 1$ będą miały (po transformacji) większe znaczenie (innymi słowy: transformacja $f(x) = 1/x$ odwraca oryginalny porządek!)
- Przed wybraniem transformacji powinniśmy stwierdzić:
 - Czy wyjściowy porządek obserwacji powinien być zachowany po transformacji?
 - Czy transformację będzie można zastosować do wszystkich wartości (w szczególności dla wartości < 0)?
 - Jaki efekt ma transformacja dla wartości znajdujących się pomiędzy 0 i 1?

Podstawowe transformacje danych

Przedziałowanie (dyskretyzacja) cech ciągłych

- **Idea:** przekształcenie zmiennej ciągłej w zmienną jakościową (nominalną/porządkową).
- Przedziałowanie możemy zastosować nie tylko dla cech ciągłych, ale również dla cech dyskretnych przyjmujących wiele wartości (cechy dyskretne o bardzo wielu wartościach liczbowych (np. *wiek*) w praktyce uznaje się za cechy ciągłe.)
- Dyskretyzacja może ułatwić analizę danych (np. ułatwić interpretację rezultatów, spowodować, że otrzymamy prostszy i bardziej efektywny model, itp.).

Podstawowe transformacje danych

Przedziałowanie (dyskretyzacja) cech ciągłych

Dwa etapy:

- Przekształcenie zmiennej ciągłej w zmienną jakościową obejmuje dwa główne etapy
 - ① Ustalenie liczby kategorii.
 - ② Określanie sposobu odwzorowania wartości atrybutu ciągłego na te kategorie.
- Zagadnienie dyskretyzacji jest równoważne z decyzją, ile punktów podziału (ang. *breaks*) zastosować (dla N kategorii mamy $N - 1$ punktów podziału) i gdzie je umieścić.

Podstawowe transformacje danych I

Przedziałowanie (dyskretyzacja) cech ciągłych

Wynik dyskretyzacji

Wynik dyskretyzacji można przedstawić jako zbiór przedziałów

$$\{(x_0, x_1], (x_1, x_2], \dots, (x_{N-1}, x_N]\},$$

lub równoważnie, jako odpowiadające im nierówności

$$x_0 \leq x < x_1, \dots, x_{N-1} \leq x < x_N.$$

Podstawowe transformacje danych

Przedziałowanie (dyskretyzacja) cech ciągłych

Dwa różne podejścia:

- **dyskretyzacja nienadzorowana (ang. unsupervised discretization)** – znajdujemy punkty podziałów (ang. breaks) w danych, bez wykorzystania informacji nt. etykietek klas,
- **dyskretyzacja nadzorowana (ang. supervised discretization)** – wykorzystujemy (znane) etykiety klas do znalezienia punktów podziału.

Podstawowe transformacje danych

Dyskretyzacja nienadzorowana (ang. *unsupervised discretization*)


Popularne algorytmy:

- **Dyskretyzacja według równej szerokości (ang. equal width discretization)** – dzielimy zakres wartości zmiennej na określoną liczbę przedziałów, z których każdy ma tę samą szerokość. Problem: istotny wpływ wartości odstających!
- **Dyskretyzacja według równej częstości (ang. equal frequency discretization)** – staramy się, aby w każdym przedziale znalazła się taka sama liczba obiektów (często preferowane podejście w porównaniu do metody opartej na równej szerokości przedziałów),
- **Dyskretyzacja oparta na algorytmie k-średnich (ang. K-means discretization)** – stosujemy algorytm grupowania (klasteryzacji) k-means,
- **Metoda oparta na wizualizacji** – dyskretyzacja oparta na wizualizacji danych niekiedy może być wystarczająco dobra.

Podstawowe transformacje danych

Dyskretyzacja nienadzorowana (ang. *unsupervised discretization*)

Przykład: Punkty należą do czterech grup (klas), mamy dwie wartości odstające (duże kropki). Stosujemy różne techniki dyskretyzacji, aby podzielić wartości cechy X na cztery kategorie (współrzędna Y jest wybierana losowo, aby ułatwić wizualizację).




(źródło: Introduction to Data Mining, Tan, Steinbach & Kumar 2006, Chap 2)

Podstawowe transformacje danych

Dyskretyzacja nienadzorowana (ang. *unsupervised discretization*)


Przykład cd.: Metoda oparta na wizualizacji danych w tym przypadku byłaby skuteczna, ale nie jest to podejście automatyczne.



Podstawowe transformacje danych

Dyskretyzacja nienadzorowana (ang. *unsupervised discretization*)

Przykład cd.: Dyskretyzacja oparta na jednakowej szerokości (equal width discretization) jest wyraźnie wrażliwa na obserwacje odstające.




(Punkty podziału są reprezentowane jako linie przerywane. Skuteczność dyskretyzacji możemy ocenić analizując, w jakim stopniu obiekty należące do różnych grup (klas) są przypisane do tej samej kategorii.)

Podstawowe transformacje danych

Dyskretyzacja nienadzorowana (ang. *unsupervised discretization*)

Przykład cd.: Metoda oparta na jednakowej częstości (equal frequencies discretization) działa dużo lepiej.




(Punkty podziału są reprezentowane jako linie przerywane. Skuteczność dyskretyzacji możemy ocenić analizując, w jakim stopniu obiekty należące do różnych grup (klas) są przypisane do tej samej kategorii.)

Podstawowe transformacje danych

Dyskretyzacja nienadzorowana (ang. *unsupervised discretization*)

Przykład cd.: algorytm dyskretyzacji oparty na k-means wydaje się być najbardziej efektywną metodą.




(d) K-means discretization.

(Punkty podziału są reprezentowane jako linie przerywane. Skuteczność dyskretyzacji możemy ocenić analizując, w jakim stopniu obiekty należące do różnych grup (klas) są przypisane do tej samej kategorii.)

Podstawowe transformacje danych

Dyskretyzacja nienadzorowana (ang. *unsupervised discretization*)

Przykład cd.: Porównanie metod.



Podstawowe transformacje danych

Przedziałowanie (dyskretyzacja) cech ciągłych

Dyskretyzacja nadzorowana (ang. supervised discretization)

- Wykorzystanie w dyskretyzacji dodatkowych informacji (etykiet klas) może dać lepsze wyniki.
- **Idea:** umieszczamy podziały w sposób, który minimalizuje wybraną miarę różnorodności klas dla poszczególnych przedziałów (tzn. większość obserwacji w danym przedziale należy do tej samej klasy → kryterium „czystości” przedziałów).
- W praktyce musimy zdecydować, jakie ograniczenie dla różnorodności klas przyjąć i jaka będzie dopuszczalna minimalna długość przedziału.
- Jednymi z najbardziej efektywnych są metody dyskretyzacji nadzorowanej oparte na entropii.

Podstawowe transformacje danych

Przedziałowanie (dyskretyzacja) cech ciągłych w R

- Aby wykonać w R dyskretyzację dla punktów podziału zadanych przez użytkownika, można wykorzystać wbudowaną funkcję `cut()`.
- Kilka podstawowych algorytmów dyskretyzacji nienadzorowanej (ang. unsupervised discretization) jest zaimplementowanych w funkcji `discretize()` (pakiet `arules`).
- R-pakiet `discretization` zawiera natomiast zestaw nadzorowanych metod dyskretyzacji (ang. supervised discretization).

Binaryzacja

- Binaryzacja przekształca zmienne ilościowe lub jakościowe w jedną lub więcej zmiennych binarnych.
- Taka transformacja jest zwykle stosowana w analizie reguł asocjacyjnych (np. analiza koszykowa).
- W przypadku zmiennej ciągłej, najpierw możemy przekształcić ją w zmienną jakościową (np. stosując jedną z metod dyskretyzacji), a następnie możemy przekonwertować otrzymaną zmienną jakościową na odpowiedni zestaw atrybutów binarnych (tzw. zmienne „dummy”).

Pozostałe (bardziej zaawansowane) transformacje

Idea: Szukamy podzbioru cech (zmiennych) lub tworzymy nowe, bardziej reprezentatywne zmienne, które zawierają istotną informację na temat danych.
Różne podejścia:

- **wybór cech (ang. feature selection)** – wybieramy najważniejsze cechy i odrzucamy te nieistotne (opracowano wiele technik, szczególnie na potrzeby klasyfikacji).
- **ekstrakcja cech (ang. feature extraction)** – konstruujemy nowe cechy na podstawie oryginalnych, wówczas możemy odwzorować dane do nowej przestrzeni (np. metoda PCA (Principal Component Analysis) – nowe cechy są odpowiednimi liniowymi kombinacjami oryginalnych, skonstruowanymi tak, aby wyjaśniały jak największą część wyjściowej zmienności danych).
- **agregacja cech (ang. feature aggregation)** – łączenie dwóch lub więcej zmiennych w pojedynczą zmienną (np. konstruujemy nową cechę $Income \times Age$ na podstawie oryginalnych cech $Income$ oraz Age).

Podsumowując...

- Pojęcia „*dobrej jakości danych*” nie da się precyzyjnie zdefiniować.
- Oryginalne (surowe) dane często wymagają zastosowania odpowiedniego przetwarzania wstępnego (ang. *preprocessing*).
- Transformacje danych należy stosować ostrożnie - niepotrzebne lub błędne przekształcenia mogą utrudnić analizę.
- Przygotowanie danych może wymagać więcej wysiłku i czasu niż właściwa analiza.

Dziękuję za uwagę!