

Redukcja wymiaru – wprowadzenie

Adam Zagdański

Wydział Matematyki PWr

Wrocław
27 III 2026

Wprowadzenie do redukcji wymiaru
Analiza składowych głównych (PCA)
Skalowanie wielowymiarowe (MDS) – wprowadzenie

Plan prezentacji

- 1 Wprowadzenie do redukcji wymiaru
 - Curse of dimensionality
 - Cele stosowania redukcji wymiaru
 - Dwa podejścia do zmniejszenia wymiaru danych
 - Przegląd metod redukcji wymiaru
- 2 Analiza składowych głównych (PCA)
 - Wybór liczby składowych
 - Przykłady
 - Pozostałe własności
 - Uogólnienia
- 3 Skalowanie wielowymiarowe (MDS) – wprowadzenie

Potrzeba redukcji wymiaru

Motywacja

- **Problem:** Gdy rośnie wymiar danych analiza staje się znacznie trudniejsza.
- W szczególności, wraz ze wzrostem wymiaru dane są coraz „rzadsze” w wyjściowej przestrzeni.
- W przypadku **klasyfikacji**, może to oznaczać, że nie będziemy mieli wystarczającej liczby próbek uczących, aby zbudować dokładny model predykcyjny.
- W przypadku **analizy skupień**, w wielowymiarowych przestrzeniach pojęcie odległości między obiektami staje się problematyczne.
- W konsekwencji, wiele algorytmów analizy skupień lub klasyfikacji może charakteryzować się dużo gorszą efektywnością.

Potrzeba redukcja wymiaru

Niezbędne oznaczenia

- p -wymiarowy wektor cech/atributów/zmiennych objaśniających opisujących dany obiekt będziemy oznaczali jako:
$$\underline{X} = (X_1, X_2, \dots, X_p)^T \in \mathcal{X}$$
- $\mathcal{X}$ będziemy nazywali **przestrzenią cech** (ang. feature space).
- W najprostszym przypadku: $\mathcal{X} = \mathbb{R}^p$.
- W ogólności cechy mogą być zarówno ilościowe (ang. quantitative) jak i jakościowe (ang. qualitative),
- Stosujemy zwyczajową konwencję aby odróżnić wielkości teoretyczne od obserwowanych tzn.: $\underline{X} = (X_1, X_2, \dots, X_p)^T$ i $\underline{x} = (x_1, x_2, \dots, x_p)^T$.

Potrzeba redukcja wymiaru

- Dane (zbiór uczący): n -obiektów, p -cech: $\{\underline{x}_1, \dots, \underline{x}_n\}$.
- Aby skonstruować dobry model, dane powinny „odpowiednio gęsto” wypełniać całą przestrzeń.
- Moglibyśmy oczekiwać, że mając do dyspozycji „odpowiednio liczny” zbiór uczący będziemy w stanie konstruować reguły decyzyjne zbliżone do optymalnych.
- Czy jednak nasze intuicje są słuszne?

Przekleństwo wielowymiarowości

Curse of Dimensionality

Przykład 1: Średnia odległość do najbliższego sąsiada rośnie wraz z p .

- Niech $\mathcal{X} = [-1, 1]^p$ oraz zależność między Y i X jest postaci:
 $Y = f(\underline{X}) = \exp(-8 \cdot \|\underline{X}\|^2)$
- Liczność zbioru uczącego $n = 1000$.
- Stosujemy metodę najbliższego sąsiada (ang. 1-nearest neighbor, 1-NN) do oszacowania $f(0)$.

Przekleństwo wielowymiarowości

Curse of Dimensionality

Przykład 1: Średnia odległość do najbliższego sąsiada rośnie wraz z p .

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 2




FIGURE 2.7. A simulation example, demonstrating the curse of dimensionality and its effect on MSE, bias and variance. The input features are uniformly distributed in $[-1, 1]^p$ for $p = 1, \dots, 10$. The top left panel shows the target function (no noise) in $\mathbb{R}^1: f(X) = e^{-8|X|^2}$, and demonstrates the error that 1-nearest neighbor makes in estimating $f(0)$.

Przekleństwo wielowymiarowości

Curse of Dimensionality

Przykład 2: Otoczenia „lokalne” w $\mathbb{R}^p$ przestają być lokalnymi.

- $\mathcal{X} = [0, 1]^p$
- r – frakcja całkowitej objętości lokalnego otoczenia ($r \in (0, 1)$)
- Oczekiwana długość krawędzi lokalnego otoczenia: $e_p(r) = r^{1/p}$.

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 2




FIGURE 2.6. The curse of dimensionality is well illustrated by a subcubical neighborhood for uniform data in a unit cube. The figure on the right shows the

In ten dimensions we need to cover 80% of the range of each coordinate to capture 10% of the data.

Przekleństwo wielowymiarowości

Curse of Dimensionality

Przykład 2: Otoczenia "lokalne" w $\mathbb{R}^p$ przestają być lokalnymi.

- Dla przykładu, dla $p = 10$ mamy: $e_{10}(0.01) = 0.63$, $e_{10}(0.1) = 0.8$.
- Interpretacja: aby otrzymać otoczenie lokalne zawierające 1% (lub 10%) danych, musimy uwzględnić 63% (lub 80%) całkowitego zakresu każdej z p zmiennych.

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 2





FIGURE 2.6. The curse of dimensionality is well illustrated by a subcubical neighborhood for uniform data in a unit cube. The figure on the right shows the side-length of the subcube needed to capture a fraction r of the volume of the data, for different dimensions p . In ten dimensions we need to cover 80% of the range of each coordinate to capture 10% of the data.

Przekleństwo wielowymiarowości

Curse of Dimensionality

Przykład 3: Wymagana wielkość próby rośnie wykładniczo z p .

- Gęstość próby jest proporcjonalna do $n^{1/p}$, gdzie p jest wymiarem wyjściowej przestrzeni a n oznacza wielkość próbki.
- **Przykład:** jeśli $n_1 = 100$ jest gęstą próbą dla $p = 1$, wówczas $n_{10} = 100^{10}$ będzie wymaganym rozmiarem próbki aby osiągnąć tę samą gęstość w przypadku $p = 10$ zmiennych.



Przekleństwo wielowymiarowości

Curse of Dimensionality

Podsumowując:

- 1 W przestrzeniach wielowymiarowych otoczenia lokalne przestają być lokalnymi.
- 2 Wraz z p szybko rośnie odległość do najbliższego sąsiada.
- 3 Wymagana wielkość próby rośnie wykładniczo wraz z wymiarem danych (p).

Cel redukcji wymiaru

- Eliminacja zbędnej informacji.
- Ekstrakcja cech (mniejsza liczba reprezentatywnych wymiarów).
- Wizualizacja (wykresy 2d i 3d).
- Identyfikacja struktury zależności w danych.
- **Uwaga:** redukcja wymiaru często poprzedza kolejne etapy analizy np. budowę reguły klasyfikacyjnej lub grupowanie (analizę skupień).

Dwa podejścia do zmniejszenia wymiaru danych

- ① **Wybór cech (ang. feature selection)** – wybieramy najważniejsze cechy i odrzucamy te nieistotne. Opracowano wiele technik, szczególnie na potrzeby klasyfikacji. Algorytmy wyboru cech zwykle dzielimy na: filtry, metody typu wrapper i metody wbudowane.
- ② **Ekstrakcja cech (ang. feature extraction)** – konstruujemy nowe cechy na podstawie oryginalnych, wówczas możemy odwzorować dane do nowej przestrzeni (np. metoda PCA (Principal Component Analysis) – nowe cechy są odpowiednimi liniowymi kombinacjami oryginalnych, skonstruowanymi tak, aby wyjaśniały jak największą część wyjściowej zmienności danych).

Uwaga: redukcję wymiaru (ang. dimension reduction) będziemy utożsamiali z ekstrakcją cech!

Metody redukcji wymiaru

- **Analiza składowych głównych (Principal Components Analysis (PCA))**
- **Skalowanie wielowymiarowe (Multidimensional Scaling (MDS))**
- Inne algorytmy
 - Non-negative Matrix Factorization (NMF)
 - Analiza składowych niezależnych (Independent Component Analysis (ICA))
 - Analiza czynnikowa (Factor Analysis)
 - Projekcje losowe (random projections)
 - Analiza dyskryminacyjna Fishera
 - Partial Least Squares (PLS)
 - ...

Metody redukcji wymiaru

Uczenie nienadzorowane vs. uczenie nadzorowane

- Metody redukcji wymiaru, które będziemy omawiali dokładniej, tzn. algorytmy PCA i MDS są przykładem **uczenia nienadzorowanego (ang. unsupervised learning)**, tzn. nie wykorzystujemy informacji nt. przynależności obiektów do klas/grup.
- Niektóre metody wykorzystują jednak taką informację. Przykładami metod redukcji wymiaru zaliczanych do **supervised learning** są np. analiza dyskryminacyjna Fishera lub algorytm PLS.
- Stosunkowo niedawno zaproponowano również wersję nadzorowaną algorytm PCA, tzn. metodę **supervised PCA** (praca źródłowa: Bair, Hastie, Paul and Tibshirani, *Prediction by Supervised Principal Components*, JASA 2006, Vol. 101, No. 473).


Analiza składowych głównych (PCA)

Historia metody


- PCA = Principal Component Analysis.
- W postaci załączkowej analiza składowych głównych pojawiła się na początku XX w. dzięki Karlowi Pearsonowi (1901).
- Metoda została następnie rozwinięta przez Hotellinga (1933).
- PCA jest zaliczana do metod uczenia nienadzorowanego, których zadaniem jest wykrycie wewnętrznej struktury danych (w szczególności współzależności występujących w analizowanych danych).
- W dużym uproszczeniu, polega ona na poszukiwaniu mniej licznych zbioru zmiennych, na podstawie którego możliwe będzie zachowanie najważniejszych własności wyjściowych danych.

Analiza składowych głównych (PCA)


Idea



A) Wyjściowe dane



B) Wyznaczamy kierunek o największej zmienności



C) Dane po transformacji

Analiza składowych głównych (PCA)

Idea

- **Cel:** Wyznaczenie nowego zbioru zmiennych (tzw. składowych głównych), ozn. $PC_1, \dots, PC_p$.
- **Założenia**
 - 1 Każda składowa główna jest liniową kombinacją oryginalnych zmiennych $X_1, \dots, X_p$.
 - 2 Składowe są ortogonalne (tworzą bazę ortogonalną).
 - 3 Składowe są uporządkowane: 1-sza składowa (PC_1) odpowiada kombinacji liniowej zmiennych o największej wariancji (zmienności) itd.

Analiza składowych głównych (PCA)


Redukcja korelacji

- Metoda PCA jest szczególnie przydatna, gdy w analizowanych danych występują silnie skorelowane zmienne.
- Obecność korelacji świadczy o nadmiarowej informacji.
- PCA można wykorzystać do zredukowania danych do mniejszej liczby nowych zmiennych (składowych głównych) wyjaśniających odpowiednio dużą frakcję wariancji pierwotnych zmiennych.


Analiza składowych głównych (PCA)

Redukcja korelacji


Przykład: różny poziom korelacji w danych



a) brak korelacji



b) średnia korelacja



c) duża korelacja

Analiza składowych głównych (PCA)

Redukcja wymiaru

Redukcja wymiaru na bazie PCA

Wybieramy kilka pierwszych składowych głównych, które wyjaśniają „odpowiednio dużą” frakcję całkowitej zmienności danych.

Analiza składowych głównych (PCA)

Idea

- Niech $\underline{X} = (X_1, \dots, X_p)^T \in \mathbb{R}^p$
- Rozważamy kombinacje liniowe oryginalnych zmiennych:
$$a_1 X_1 + a_2 X_2 + \dots + a_p X_p = \underline{a}^T \underline{X}, \text{ gdzie } \|\underline{a}\|^2 = \underline{a}^T \underline{a} = 1.$$

- **1-sza składowa główna (PC_1):**

$$\text{Var}(\underline{a}_1^T \underline{X}) = \max_{\underline{a} \in \mathbb{R}^p, \|\underline{a}\|=1} \{ \text{Var}(\underline{a}^T \underline{X}) \}.$$

- **2-ga składowa główna (PC_2):**

$$\text{Var}(\underline{a}_2^T \underline{X}) = \max_{\underline{a} \in \mathbb{R}^p, \|\underline{a}\|=1} \{ \text{Var}(\underline{a}^T \underline{X}) \}$$

$$\text{Cov}(\underline{a}_1^T \cdot \underline{X}, \underline{a}_2^T \cdot \underline{X}) = 0.$$

- itd.
- Otrzymujemy p składowych głównych: $PC_1, PC_2, \dots, PC_p$.

Analiza składowych głównych (PCA)

Algorytm metody PCA

- ❶ Krok opcjonalny: standaryzacja danych (centrowanie i skalowanie).
- ❷ Wyznaczamy estymator macierzy kowariancji $\hat{\Sigma}$.
- ❸ Wyznaczamy wartości własne $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_p > 0$, i wektory własne: $\underline{u}_1, \underline{u}_2, \dots, \underline{u}_p$, gdzie $\hat{\Sigma}\underline{u}_i = \lambda_i\underline{u}_i$.
- ❹ 1-szy kierunek główny $\equiv$ wektor własny $\underline{u}_1$ (odpowiadający największej wartości własnej, tzn. λ_1),
- ❺ 2-gi kierunek główny $\equiv$ wektor własny $\underline{u}_2$ odpowiadający λ_2 ,
- ❻ itd.

Analiza składowych głównych (PCA)

Terminologia

- **Kierunki główne:** wektory $\underline{a}_1, \dots, \underline{a}_p \in \mathbb{R}^p$ o długości 1, wyznaczające ortogonalne kierunki o największej zmienności.
- Wektor $\underline{a}_i$ jest także nazywany **i-tym wektorem ładunków (ang. loadings)**
- Wektor $\underline{a}_i$ wyznaczamy jako wektor własny estymowanej macierzy kowariancji $\hat{\Sigma}$ odpowiadający i -tej co do wielkości wartości własnej λ_i .
- $\underline{y}_i = \underline{a}_i^T \underline{x}$ – **i-ta składowa główna wektora $\underline{x}$** .

Analiza składowych głównych (PCA)

Wyjaśniona wariancja



- Wartość własna λ_i jest równa wariancji próbkowej i -tej składowej głównej (tzn. wariancji próbkowej $\underline{a}_i^T \underline{x}_1, \dots, \underline{a}_i^T \underline{x}_n$).
- Wyjaśniona wariancja odpowiadająca poszczególnym składowym

$$V_j = \lambda_j / \sum_{i=1}^p \lambda_i \cdot 100\%$$

- Całkowita wariancja (całkowita zmienność)
 $= \text{Var}(X_1) + \dots \text{Var}(X_p)$
- **Fakt:** $\lambda_1 + \dots \lambda_p = \text{Var}(X_1) + \dots + \text{Var}(X_p) = \text{tr}(\hat{\Sigma})$.
- Redukcja wymiaru na bazie PCA: wybieramy kilka pierwszych składowych, które łącznie wyjaśniają określoną frakcję całkowitej zmienności danych (np. 80% lub 90%).

Analiza składowych głównych (PCA)

Wariancja odpowiadająca poszczególnym składowym głównym



Analiza składowych głównych (PCA)

Wybór liczby składowych


- Procent zmienności wektora losowego $\underline{x}$ wyjaśniony przez k pierwszych składowych

$$\frac{\lambda_1 + \dots + \lambda_k}{\lambda_1 + \dots + \lambda_p} 100\%, \text{ gdzie } k \leq p.$$

- Przydatnym narzędziem graficznym wykorzystywanym do znalezienia optymalnej liczby składowych jest wykres osypiskowy (ang. scree plot).

Analiza składowych głównych (PCA)

Wybór liczby składowych – *scree plot* (wykres osypiskowy)



Analiza składowych głównych (PCA)

Wybór liczby składowych – strategie

- Powszechnie stosowaną strategią jest ustalenie frakcji wyjaśnionej wariancji (np. 80% lub 90%).
- Często jaką optymalną liczbę składowych wybieramy tę wartość, dla której wykres osypiskowy (scree plot) po raz pierwszy jest zbliżony do linii poziomej.
- Inną metodą wyboru liczby składowych głównych jest pominięcie tych składowych, których wartości własne (wariancje) są mniejsze od wartości średniej

$$\bar{\lambda} = \frac{1}{p} \sum_{i=1}^p \lambda_i.$$

Analiza składowych głównych (PCA)

Wybór liczby składowych – strategie cd.

- **W przypadku danych standaryzowanych:**
 $\lambda_i > 1$ oznacza, że i -tej składowej głównej odpowiada większa wariancja niż wariancja pojedynczej zmiennej (równa 1).
- Możemy więc wybrać tylko te składowe główne, dla których wartość własna (λ_i) jest większa od 1.

Analiza składowych głównych (PCA)

Przykład 1: Dane USArrests{datasets}

- Zilustrujemy działania PCA dla danych USArrests zawierających informacje na temat liczby brutalnych przestępstw w poszczególnych stanach USA w roku 1973.
- Mamy $n = 50$ przypadków i $p = 4$ zmienne:
 - Murder – liczba aresztowanych za morderstwo (na 100000 mieszkańców),
 - Assault – liczba aresztowanych za napad (na 100000 mieszkańców),
 - UrbanPop – odsetek populacji mieszkającej w obszarach zurbanizowanych,
 - Rape – liczba aresztowanych za gwałt (na 100000 mieszkańców).

Analiza składowych głównych (PCA)

Przykład 1: Dane USArrests{datasets}


Fragment danych:

```
> head(USArrests)
```

	Murder	Assault	UrbanPop	Rape
Alabama	13.2	236	58	21.2
Alaska	10.0	263	48	44.5
Arizona	8.1	294	80	31.0
Arkansas	8.8	190	50	19.5
California	9.0	276	91	40.6
Colorado	7.9	204	78	38.7

Analiza składowych głównych (PCA)

Przykład 1: Dane USArrests{datasets}



Uwaga: Standaryzujemy dane przed użyciem PCA!

Analiza składowych głównych (PCA)

Przykład 1: Dane USArrests{datasets}

	PC1	PC2	PC3	PC4
wariancja	2.4802416	0.9897652	0.3565632	0.1734301

Tabela: Wariancje kolejnych składowych głównych

Uwaga: $Var(PC_1) + Var(PC_2) + Var(PC_3) + Var(PC_4) = 4$.

Analiza składowych głównych (PCA)

Przykład 1: Dane USArrests{datasets}

	PC1	PC2	PC3	PC4
Murder	-0.5359	0.4182	-0.3412	0.6492
Assault	-0.5832	0.1880	-0.2681	-0.7434
UrbanPop	-0.2782	-0.8728	-0.3780	0.1339
Rape	-0.5434	-0.1673	0.8178	0.0890

Tabela: Wektory ładunków (loadings) dla składowych głównych

- **1-szy wektor ładunków** przypisuje w przybliżeniu jednakową wagę zmiennym Assault, Murder i Rape i dużo mniejszą wagę zmiennej UrbanPop. **PC1** możemy interpretować jako ogólny wskaźnik brutalnych przestępstw.
- **2-gi wektor ładunków** przypisuje największą wagę zmiennej UrbanPop i dużo mniejszą pozostałym zmiennym. **PC2** związana jest więc głównie z poziomem zurbanizowania danego stanu.

Analiza składowych głównych (PCA)

Przykład 1: Dane USArrests{datasets}

	PC1	PC2	PC3	PC4
Standard deviation	1.5749	0.9949	0.5971	0.4164
Proportion of Variance	0.6201	0.2474	0.0891	0.0434
Cumulative Proportion	0.6201	0.8675	0.9566	1.0000


Tabela: Udział wyjaśnionej wariancji

- PC1 wyjaśnia 62% całkowitej zmienności danych, a PC2 – 24%.
- Dwie pierwsze składowe wyjaśniają łącznie ponad 85% całkowitej wariancji.

Analiza składowych głównych (PCA)

Przykład 1: Dane USArrests{datasets}


Udział wyjaśnionej wariancji (scree plot)



Analiza składowych głównych (PCA)

Przykład 1: Dane USArrests{datasets}


Wizualizacja danych: Wykres rozrzutu w przestrzeni (PC1,PC2)



Analiza składowych głównych (PCA)

Przykład 1: Dane USArrests{datasets}


Dwuwykres (biplot): wykres rozrzutu w przestrzeni (PC_1, PC_2) + wektory ładunków dla poszczególnych zmiennych.



- Zmienne związane z przestępczością są położone blisko siebie i jednocześnie oddalone od zmiennej UrbanPop.
- Wskazuje to na dość dużą korelację tych zmiennych (stany o dużym wskaźniku morderstw charakteryzują się również dużą liczbą napadów i gwałtów).

Analiza składowych głównych (PCA)

Przykład 1: Dane USArrests{datasets}




	Murder	Assault	UrbanPop	Rape
Murder	1.00	0.80	0.07	0.56
Assault	0.80	1.00	0.26	0.67
UrbanPop	0.07	0.26	1.00	0.41
Rape	0.56	0.67	0.41	1.00

Tabela: Macierz korelacji

Analiza składowych głównych (PCA)

Przykład 1: Dane USArrests{datasets}


Czy standaryzacja danych jest konieczna?



Analiza składowych głównych (PCA)

Przykład 1: Dane USArrests{datasets}


Czy standaryzacja danych jest konieczna?



Analiza składowych głównych (PCA)

Przykład 1: Dane USArrests{datasets}

Czy standaryzacja danych jest konieczna?



(C) 2026, A.Zagdański, Redukcja wymiaru – wprowadzenie

43/54

Analiza składowych głównych (PCA)

Znaczenie standaryzacji danych

Uwaga

Składowe główne nie są niezmiennicze ze względu na zmianę skali oryginalnych zmiennych.

- **Zalecenie:** jeżeli wariancje wyjściowych zmiennych są bardzo zróżnicowane, aby uniknąć dominacji zmiennej o bardzo dużej wariancji powinniśmy przed zastosowaniem metody PCA przeprowadzić standaryzację danych.
- Alternatywnym rozwiązaniem jest wykorzystaniem macierzy korelacji zamiast macierzy kowariancji.

(C) 2026, A.Zagdański, Redukcja wymiaru – wprowadzenie

44/54

PCA w pakiecie R

- `prcomp()`, `princomp()` – wbudowany pakiet stats,
- `PCA()` – pakiet FactoMineR,
- `dudi.pca()` – pakiet ade4,
- `epPCA()` – pakiet ExPosition.

Analiza składowych głównych (PCA)

Wybrane uogólnienia

- Sparse PCA – dodatkowe ograniczenia na współczynniki,
- Supervised PCA – wersja nadzorowana metody PCA,
- Principal curves,
- Principal surfaces,
- Kernel PCA – wersja nieliniowa metody PCA.

Analiza składowych głównych (PCA)

Uogólnienia

Principal curves

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 14




FIGURE 14.27. The principal curve of a set of data. Each point on the curve is the average of all data points that project there.

Analiza składowych głównych (PCA)

Uogólnienia

Principal surfaces

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 14




FIGURE 14.28. Principal surface fit to half-sphere data. (Left panel:) fitted two-dimensional surface. (Right panel:) projections of data points onto the surface, resulting in coordinates $\hat{\lambda}_1, \hat{\lambda}_2$.

Alternatywa dla PCA: skalowanie wielowymiarowe (MDS)

- PCA umożliwia odwzorowanie danych $\underline{x}_i \in \mathbb{R}^p$ na podprzestrzeń o wymiarze r ($r < p$), tak aby dane po rzutowaniu miały największą możliwą zmienność.
- Skalowanie wielowymiarowe (Multidimensional Scaling (MDS)) jest metodą redukcji wymiaru, która stara się zachować inną ważną własność danych – wyjściowe odległości.

Alternatywa dla PCA: skalowanie wielowymiarowe (MDS)

Przykład: Odwzorowanie mapy Europy.

	Athens	Barcelona	Brussels	Calais	Cherbourg	Cologne	Copenhagen	Geneva	Gibraltar	Hamburg	Hook of Holland	Lisbon	Lyons	Madrid	Marseilles	Milan	Munich	Paris	Rome	Stockholm	Vienna
Athens	0	3313	2963	3175	3339	2762	3276	2610	4485	2977	3030	4532	2753	3949	2865	2282	2179	3000	817	3927	1991
Barcelona	3313	0	1318	1326	1294	1498	2218	803	1172	2018	1490	1305	645	636	521	1014	1365	1033	1460	2868	1802
Brussels	2963	1318	0	204	583	206	966	677	2256	597	172	2084	690	1558	1011	925	747	285	1511	1616	1175
Calais	3175	1326	204	0	460	409	1136	747	2224	714	330	2052	739	1550	1059	1077	977	280	1662	1786	1381
Cherbourg	3339	1294	583	460	0	785	1545	853	2047	1115	731	1827	789	1347	1101	1209	1160	340	1794	2196	1588
Cologne	2762	1498	206	409	785	0	760	1662	2436	460	269	2290	714	1764	1035	911	583	465	1497	1403	937
Copenhagen	3276	2218	966	1136	1545	760	0	1418	3196	460	269	2971	1458	2498	1778	1537	1104	1176	2050	650	1455
Geneva	2610	803	677	747	853	1662	1418	0	1975	1118	895	1936	158	1439	425	328	591	513	995	2068	1019
Gibraltar	4485	1172	2256	2224	2047	2436	3196	1975	0	2897	2428	676	1817	698	1693	2185	2565	1971	2631	3886	2974
Hamburg	2977	2018	597	714	1115	460	460	1118	2897	0	550	2671	1159	2198	1479	1238	805	877	1751	949	1155
Hook of Holland	3030	1490	172	330	731	269	269	895	2428	550	0	2280	863	1730	1183	1098	851	457	1683	1500	1205
Lisbon	4532	1305	2084	2052	1827	2290	2971	1936	676	2671	2280	0	1178	668	1762	2250	2507	1799	2700	3231	2937
Lyons	2753	645	690	739	789	714	1458	158	1817	1159	863	1178	0	1281	320	328	724	471	1048	2108	1157
Madrid	3949	636	1558	1550	1347	1764	2498	1439	698	2198	1730	668	1281	0	1157	1724	2010	1273	2097	3188	2409
Marseilles	2865	521	1011	1059	1101	1035	1778	425	1693	1479	1183	1762	320	1157	0	618	1109	792	1011	2428	1363
Milan	2282	1014	925	1077	1209	911	1537	328	2185	1238	1098	2250	328	1724	618	0	331	856	586	2187	898
Munich	2179	1365	747	977	1160	583	1104	591	2565	805	851	2507	724	2010	1109	331	0	821	946	1754	428
Paris	3000	1033	285	280	340	465	1176	513	1971	877	457	1799	471	1273	792	856	821	0	1476	1827	1249
Rome	817	1460	1511	1662	1794	1497	2050	995	2631	1751	1683	2700	1048	2097	1011	586	946	1476	0	2707	1209
Stockholm	3927	2868	1616	1786	2196	1403	650	2068	3886	949	1500	3231	2108	3188	2428	2187	1754	1827	2707	0	2105
Vienna	1991	1802	1175	1381	1588	937	1455	1019	2974	1155	1205	2937	1157	2409	1363	898	428	1249	1209	2105	0

Dane wejściowe: Odległości między 21 miastami w Europie.

Na następnym wykładzie

- Skalowanie wielowymiarowe (Multidimensional Scaling, MDS) – idea metody i przykłady.
- Skalowanie klasyczne (classical MDS) – związek z PCA.
- Skalowanie metryczne i niemetryczne – wybrane algorytmy.
- Ocena jakości skalowania wielowymiarowego.

Dziękuję za uwagę!