

Skalowanie wielowymiarowe (MDS)

Redukcja wymiaru cd.

Adam Zagdański

Wydział Matematyki PWr

Wrocław
30.03.2026

Idea i rodzaje skalowania wielowymiarowego
Ocena jakości skalowania wielowymiarowego
Wybrane rozszerzenia algorytmu MDS
MDS w pakiecie R

Plan prezentacji

- 1 Idea i rodzaje skalowania wielowymiarowego
 - Skalowanie klasyczne
 - Skalowanie metryczne – wersja ogólna
 - Skalowanie niemetryczne (porządkowe)
- 2 Ocena jakości skalowania wielowymiarowego
- 3 Wybrane rozszerzenia algorytmu MDS
- 4 MDS w pakiecie R

Skalowanie wielowymiarowe

Multidimensional Scaling (MDS)

Idea metody:

- W nowej przestrzeni (o mniejszym) wymiarze staramy się odtworzyć odległości (odmienności) między obiektami.
- Bardziej formalnie

$$MDS : \mathcal{X} \rightarrow \mathbb{R}^d,$$

gdzie $d < p$.

- Odtworzenie konfiguracji punktów w przestrzeni o mniejszym wymiarze odgrywa istotną rolę m.in. w wizualizacji danych.
- Z tego powodu metoda MDS jest bardzo często wykorzystywana do graficznego przedstawienia danych w przestrzeni dwu- lub trójwymiarowej ($d = 2$ lub $d = 3$).

Rodzaje skalowanie wielowymiarowego (MDS)

- **Skalowanie metryczne** – metoda stara się możliwie dobrze przybliżyć oryginalne odległości (odmienności) obiektów.
- **Skalowanie niemetryczne (porządkowe)** – ważne jest zachowanie porządku, a nie samych wartości odległości.

Skalowanie klasyczne (ang. classical scaling)

Przykład skalowania metrycznego

- Niech $\underline{x}_i \in \mathbb{R}^p$, gdzie $i = 1, \dots, n$
- Odległość euklidesowa:
$$d_{ij} = d_E(\underline{x}_i, \underline{x}_j) = \sqrt{\sum_{k=1}^p (x_{i,k} - x_{j,k})^2}.$$
- **Cel:** Szukamy takiej podprzestrzeni $\mathbb{R}^d$ (gdzie d ustalone, $d < p$), tak aby minimalizowane było kryterium

$$\begin{aligned} S_C(\underline{z}_1, \dots, \underline{z}_n) &= \sum_{i=1}^n \sum_{j=1}^n (d_{ij}^2 - \tilde{d}_{ij}^2) \\ &= \sum_{i=1}^n \sum_{j=1}^n (\|\underline{x}_i - \underline{x}_j\|^2 - \|\underline{z}_i - \underline{z}_j\|^2), \end{aligned}$$

gdzie:

- $\underline{z}_1, \dots, \underline{z}_n$ są rzutami punktów $\underline{x}_1, \dots, \underline{x}_n$,
- $\tilde{d}_{ij}$ – odległość euklidesowa między $\underline{z}_i$ i $\underline{z}_j$.

Pytanie: Dlaczego w kryterium S_C mamy $(d_{ij}^2 - \tilde{d}_{ij}^2)$ a nie np. $|d_{ij}^2 - \tilde{d}_{ij}^2|$?

Skalowanie klasyczne (ang. classical scaling)

Związek z PCA

Fakt

Rozwiązaniem zadania minimalizacji kryterium S_C (w problemie skalowania klasycznego) jest przestrzeń określona przez d pierwszych składowych głównych.

Wniosek

- Jeżeli $\mathcal{X} = \mathbb{R}^p$ i bazujemy na odległości euklidesowej, algorytm skalowania klasycznego (*classical scaling*) jest równoważny redukcji wymiaru opartej na metodzie PCA, gdzie d jest równe liczbie składowych głównych.
- Skalowanie klasyczne jest znane również pod nazwą **Principal Coordinates Analysis (PCoA)**.

Skalowanie klasyczne (ang. classical scaling)

Uogólnienie

- Algorytm skalowania klasycznego może być uogólniony na przypadek macierzy odmienności $[d_{ij}]_{i,j=1,\dots,n}$, spełniającej nierówność trójkąta i pewne dodatkowe warunki.
- Więcej szczegółów: np. Koronacki i Ćwik (2008).

Skalowanie metryczne – wersja ogólna

Motywacja

- W praktyce często mamy do czynienia z danymi, które zawierają zarówno atrybuty ilościowe jak i jakościowe.
- W tym przypadku pomocne może być zastąpienie miary odległości jedną z miar odmienności.
- Odwzorowanie oryginalnych danych do przestrzeni euklidesowej o małym wymiarze możemy zastosować np. do wizualizacji danych.
- Wykorzystując nową reprezentację danych, możemy również zastosować metody/modele, które wymagają aby wyjściowe dane pochodziły z przestrzeni euklidesowej.

Skalowanie metryczne – wersja ogólna

Miara odmienności / niepodobieństwa

Miara odmienności / niepodobieństwa (ang. dissimilarity measure)

Od odmienności $d(x, y)$ między dowolnymi elementami $x, y \in \mathcal{X}$ będziemy wymagali aby

- ① $d(x, y) \geq 0$,
- ② $d(x, y) = d(y, x)$,
- ③ $d(x, y) = 0 \iff x = y$.

Uwaga 1: W ogólności miara odmienności może nie spełniać nierówności trójkąta ($d(x, y) \leq d(x, z) + d(z, y)$).

Uwaga 2: W środowisku R do wyznaczenia miary odmienności można wykorzystać funkcję `daisy()` z pakietu `cluster`.

Skalowanie metryczne – wersja ogólna

- **Dane wejściowe:** $D = [d_{ij}]_{i,j=1,\dots,n}$ - macierz odmienności (ang. dissimilarity matrix) między obiektami.
- **Cel:** szukamy $\underline{z}_1, \dots, \underline{z}_n \in \mathbb{R}^d$ minimalizujących tzw. **funkcję STRESS** (ang. stress function)

$$S(\underline{z}_1, \dots, \underline{z}_n) = \sum_{i=1}^n \sum_{j=1}^n a_{ij} (d_{ij} - \|\underline{z}_i - \underline{z}_j\|)^2,$$

gdzie a_{ij} – wagi (różne dla różnych wersji algorytmu).

Skalowanie metryczne

Wybrane algorytmy

① Skalowanie Kruskala-Sheparda

$$S_M(\underline{z}_1, \dots, \underline{z}_n) = \sum_{i \neq j} (d_{ij} - ||z_i - z_j||)^2.$$

② Skalowanie Sammona

$$S_{SM}(\underline{z}_1, \dots, \underline{z}_n) = \sum_{i \neq j} \frac{(d_{ij} - ||z_i - z_j||)^2}{d_{ij}}$$

(kładziemy większy nacisk na dobre odwzorowanie małych odległości)

Skalowanie metryczne

Uwagi

- Do minimalizacji funkcji kryterialnej STRESS wykorzystuje się algorytmy numeryczne (np. algorytm najszybszego spadku).
- Punkty startowe są wybierane w taki sposób, aby miały one jak największą wariancję w przestrzeni docelowej.
- Funkcja STRESS jest niezmiennicza ze względu na przesunięcia, obroty, odbicia oraz jednostajne rozciąganie i zwężanie danych.
- Odwzorowanie jest więc wyznaczone z dokładnością do tego rodzaju przekształceń (→ przykład ilustrujący odwzorowanie mapy Europy na podstawie odległości między miastami).

Skalowanie niemetryczne (porządkowe)

- **Cel:** Szukamy $\underline{z}_1, \dots, \underline{z}_n \in \mathbb{R}^d$ (gdzie $d < p$), dla których możliwie wiernie zachowany jest porządek.
- Porządek odległości (między obiektami) w nowej przestrzeni $\mathbb{R}^d$ powinien być taki sam jak porządek w wyjściowej macierzy odmienności.
- Odległości powinny być monotoniczną funkcją odmienności.
- Podstawowy warunek monotoniczności:

$$d_{rs} < d_{ij} \Rightarrow \tilde{d}_{rs} \leq \tilde{d}_{ij}.$$

Skalowanie niemetryczne (porządkowe)

Skalowanie niemetryczne Sheparda-Kruskala

- Algorytm wykorzystuje jedynie rangi wyjściowych odmienności.
- Szukamy $\underline{z}_1, \dots, \underline{z}_n$, które minimalizują kryterium

$$S_{NM}(\underline{z}_1, \dots, \underline{z}_n, \theta) = \frac{\sum_{i \neq j} (\|\underline{z}_i - \underline{z}_j\| - \theta(d_{ij}))^2}{\sum_{i \neq j} \|\underline{z}_i - \underline{z}_j\|^2},$$

gdzie

- d_{ij} – odmiennosc między $\underline{x}_i$ i $\underline{x}_j$,
- $\theta(\cdot)$ – funkcja monotoniczna (rosnaca).

Skalowanie niemetryczne (porządkowe)


Skalowanie niemetryczne Sheparda-Kruskala

- Do optymalizacji S_{NM} wykorzystujemy schemat iteracyjny
 - Iterujemy kroki 1-2 do osiągnięcia zbieżności:
- Przy ustalonej funkcji $\theta(\cdot)$ minimalizujemy S_{NM} ze względu na $\underline{z}_1, \dots, \underline{z}_n$, stosując algorytm gradientowy.
 - Przy ustalonych $\{\underline{z}_i\}_{i=1, \dots, n}$ szukamy najlepszej monotonicznej aproksymacji $\theta(d_{ij})$ dla $\|\underline{z}_i - \underline{z}_j\|$ ($\rightarrow$ algorytm *isotonic regression*).

Skalowanie niemetryczne (porządkowe)

Przykład 1: Dane 'zoo' ($n = 99, p = 16$).


źródło: <http://archive.ics.uci.edu/ml/datasets/zoo>




	hair	feathers	eggs	milk	airborne	aquatic	predator	toothed	backbone	breathes	venomous	fins	legs	tail	domestic	catsize
aardvark	1	0	0	1	0	0	1	1	1	1	0	0	4	0	0	1
antelope	1	0	0	1	0	0	0	1	1	1	0	0	4	1	0	1
bass	0	0	1	0	0	1	1	1	1	0	0	1	0	1	0	0
bear	1	0	0	1	0	0	1	1	1	1	0	0	4	0	0	1
boar	1	0	0	1	0	0	1	1	1	1	0	0	4	1	0	1
buffalo	1	0	0	1	0	0	0	1	1	1	0	0	4	1	0	1
calf	1	0	0	1	0	0	0	1	1	1	0	0	4	1	1	1
carp	0	0	1	0	0	1	0	1	1	0	0	1	0	1	1	0
catfish	0	0	1	0	0	1	1	1	1	0	0	1	0	1	0	0
cavy	1	0	0	1	0	0	0	1	1	1	0	0	4	0	1	0
cheetah	1	0	0	1	0	0	1	1	1	1	0	0	4	1	0	1
chicken	0	1	1	0	1	0	0	0	1	1	0	0	2	1	1	0
chub	0	0	1	0	0	1	1	1	1	0	0	1	0	1	0	0
clam	0	0	1	0	0	0	1	0	0	0	0	0	0	0	0	0
crab	0	0	1	0	0	1	1	0	0	0	0	0	4	0	0	0
crayfish	0	0	1	0	0	1	1	0	0	0	0	0	6	0	0	0
crow	0	1	1	0	1	0	1	0	1	1	0	0	2	1	0	0
deer	1	0	0	1	0	0	0	1	1	1	0	0	4	1	0	1
dogfish	0	0	1	0	0	1	1	1	1	0	0	1	0	1	0	1
dolphin	0	0	0	1	0	1	1	1	1	1	0	1	0	1	0	1
dove	0	1	1	0	1	0	0	0	1	1	0	0	2	1	1	0
duck	0	1	1	0	1	1	0	0	1	1	0	0	2	1	0	0
elephant	1	0	0	1	0	0	0	1	1	1	0	0	4	1	0	1
flamingo	0	1	1	0	1	0	0	0	1	1	0	0	2	1	0	1
flea	0	0	1	0	0	0	0	0	0	1	0	0	6	0	0	0
frog	0	0	1	0	0	1	1	1	1	1	0	0	4	0	0	0
fruitbat	1	0	0	1	1	0	0	1	1	1	0	0	2	1	0	0

Skalowanie niemetryczne (porządkowe)

Przykład 1: Macierz odmienności/niepodobieństwa




Dissimilarity matrix – 'zoo' dataset



Skalowanie niemetryczne (porządkowe)


Przykład 1 cd.: wizualizacja danych w przestrzeni (MDS_1 , MDS_2).

MDS: 'zoo' dataset




Skalowanie niemetryczne (porządkowe)

Przykład 1 cd.: wizualizacja danych w przestrzeni (MDS_1, MDS_2).




Skalowanie niemetryczne (porządkowe)

Przykład 1 cd.: wizualizacja danych w przestrzeni (MDS_1, MDS_2).




Skalowanie niemetryczne (porządkowe)

Przykład 1 cd.: wizualizacja danych w przestrzeni (MDS_1, MDS_2).



Skalowanie niemetryczne (porządkowe)

Przykład 1 cd.: wizualizacja danych w przestrzeni (MDS_1, MDS_2).




Ocena jakości skalowania wielowymiarowego

- **STRESS vs. dimension:** analiza zachowania funkcji STRESS dla różnych wymiarów d , gdzie $d < p$ (odpowiednik wykresu typu *scree plot*).
- **Diagram Sheparda:** porównanie na wykresie oryginalnych odległości (odmienności) z odległościami po zastosowaniu algorytmu MDS (tzn. po odwzorowaniu do przestrzeni $\mathbb{R}^d$).

Ocena jakości skalowania wielowymiarowego


STRESS vs. dimension

Przykład 1: dane 'ZOO'.




Ocena jakości skalowania wielowymiarowego

Przykład 2: dane Cars93.




Ocena jakości skalowania wielowymiarowego

Przykład 2: dane Cars93.



Ocena jakości skalowania wielowymiarowego


Przykład 2: dane Cars93.



Ocena jakości skalowania wielowymiarowego

STRESS vs. dimension

Przykład 2: dane Cars93.




Uwaga: jakość odwzorowania MDS poprawia się wraz ze wzrostem wymiaru (d).

Ocena jakości skalowania wielowymiarowego

Diagram Sheparda dla różnych wymiarów

Przykład 2: dane Cars93.



Uwaga: jakość odwzorowania MDS poprawia się wraz ze wzrostem wymiaru (d).

Wybrane rozszerzenia algorytmu MDS

Metoda FastMap

- „Szybsza” alternatywa dla MDS (liniowa złożoność obliczeniowa).
- Może być stosowany ”stopniowo”, tzn. początkowo metoda FastMap jest stosowana do całego zestawu danych. Następnie uzyskany wynik można zastosować aby odwzorować nowe obiekty.

źródło: Ch.Faloutsos, & K-I.Lin, (1997). *FastMap: A Fast Algorithm for Indexing, Data-Mining and Visualization of Traditional and Multimedia Datasets*. ACM international conference on management of data (SIGMOD).

Wybrane rozszerzenia algorytmu MDS


Metoda FastMap

- Algorytm FastMap wybiera parę obiektów (O_a i O_b), które są najbardziej oddalone od siebie (tzw. *pivot objects*).
- Następnie rzutujemy obiekty na prostą $O_a O_b$ i wykorzystujemy to odwzorowanie do wyznaczenia/ekstrakcji pierwszej zmiennej.
- W kolejnym kroku rzutujemy obiekty na $(p - 1)$ -wymiarową hiperpłaszczyznę ortogonalną do prostej $O_a O_b$.
- Powtarzamy powyższe kroki do momentu wyznaczenia k nowych atrybutów.

Wybrane rozszerzenia algorytmu MDS

Metoda ISOMAP

- **Motywacja:** Klasyczne algorytmy MDS i PCA nie działają dobrze, gdy dane mają skomplikowaną, nieliniową strukturę.
- Algorytm ISOMAP został opracowany z myślą o takich zbiorach danych.
- **Przykład:** Powierzchnia "Swiss roll" – dwuwymiarowy zbiór danych w przestrzeni trójwymiarowej.



Wybrane rozszerzenia algorytmu MDS

Metoda ISOMAP

Algorytm ISOMAP

- 1 Dla każdej obserwacji znajdujemy jej najbliższych sąsiadów i tworzymy ważony graf (łącząc dany punkt z jego sąsiadami). Wierzchołkami są obserwacje (punkty), a wagami krawędzi są odległości między punktami.
- 2 Definiujemy na nowo odległości między punktami jako długości najkrótszej ścieżki (celem tego kroku jest obliczenie odległości geodezyjnej; tj. odległości między dwoma punktami, które znajdują się na danej powierzchni zamiast odległości euklidesowej).
- 3 Stosujemy klasyczny MDS dla nowej macierzy odległości.

źródło: Silva VD, Tenenbaum JB (2003). *Global Versus Local Methods in Nonlinear Dimensionality Reduction*.

Advances in Neural Information Processing Systems 15, 721-728. MIT Press.

MDS w pakiecie R

- `cmdscale{stats}` – classical multidimensional scaling,
- `sammon{MASS}` – Sammon scaling,
- `isoMDS{MASS}` – Kruskal scaling,
- `do.mds{Rdimtools}` – classical multidimensional scaling (bardziej efektywna implementacja niż `cmdscale`),
- `do.isomap{Rdimtools}` – metoda ISOMAP (Isometric Feature Mapping),
- `do.fastmap{Rdimtools}` – algorytm FastMap.

Dziękuję za uwagę!