

Podobieństwo, odmienność i odległość między obiektami

Adam Zagdański

Wydział Matematyki PWr

Wrocław
10.04.2026

Miara odmienności/niepodobieństwa
Niestandardowe miary podobieństwa – przykłady

Plan prezentacji

- 1 Miara odmienności/niepodobieństwa
 - Wprowadzenie
 - Zmienne ilościowe
 - Zmienne binarne
 - Zmienne porządkowe
 - Zmienne nominalne
 - Wersja ogólna – atrybuty różnych typów
- 2 Niestandardowe miary podobieństwa – przykłady
 - Odległość Levenshteina (edycyjna)
 - Podobieństwo semantyczne (znaczeniowe)

Wprowadzenie

- W eksploracji danych często kluczowe jest odpowiednie mierzenie podobieństwa lub odległości między obiektami.
- Przykłady zadań eksploracji opartych na odległościach:
 - redukcja wymiaru / wizualizacja danych (przykładowe algorytmy: skalowanie wielowymiarowe (MDS)).
 - klasyfikacja (przykładowe metody: algorytm k najbliższych sąsiadów (k-NN)).
 - grupowanie / analiza skupień (przykładowe metody: algorytm k-średnich (k-means), metody hierarchiczne (np. aglomeracyjne)).
- W praktyce wykorzystywane są zarówno klasyczne miary odległości, jak i bardziej elastyczne podejście oparte na odpowiednio dobranej **mierze odmienności / niepodobieństwa (ang. dissimilarity measure)**.

Miara odmienności/niepodobieństwa

Miara odmienności / niepodobieństwa (ang. dissimilarity measure)

Od odmienności $d(x, y)$ między dowolnymi elementami $x, y \in \mathcal{X}$ będziemy wymagali aby

- ① $d(x, y) \geq 0$,
- ② $d(x, y) = d(y, x)$,
- ③ $d(x, y) = 0 \iff x = y$.

Oznaczenia:

- $d_{ij} = d(\underline{x}_i, \underline{x}_j)$,
- $D = \{d_{ij}\}_{i,j=1}^n$ – macierz odmienności / niepodobieństwa (ang. dissimilarity matrix).

Miara odmienności/niepodobieństwa

Uwagi

- 1) W niektórych przypadkach macierz odmienności lub podobieństwa między elementami stanowi jedyne dostępne dane (nie zawsze dysponujemy wektorem cech opisującym dany obiekt).
- 2) Odmienności/niepodobieństwa możemy otrzymać np. na podstawie opinii eksperckich lub jako wynik badania preferencji.
- 3) W ogólności miara odmienności nie musi spełniać nierówności trójkąta ($d(x, y) \leq d(x, z) + d(z, y)$).

Uwaga: Dowolną macierz odmienności można przekształcać do macierzy, która spełnia warunek trójkąta (ale tylko dla n rozważanych obiektów).

Miara odmienności/niepodobieństwa

Uwagi cd.

- 4) Niekiedy potrzebna jest symetryzacja macierzy odmienności, aby zagwarantować spełnienie warunku $d(x, y) = d(y, x)$, tzn.:

$$\tilde{D} = (D + D^T)/2.$$

- 5) Czasami zamiast o odmienności wygodniej jest mówić o podobieństwie obiektów (ang. similarity). Jeżeli $d_{ij} \in [0, 1]$, podobieństwo możemy zdefiniować jako

$$s_{ij} = 1 - d_{ij}.$$

Uwaga: w razie potrzeby, jeżeli miara odmienności nie spełnia warunku $d_{ij} \in [0, 1]$, możemy ją odpowiednio przeskalować (mnożenie przez stałą C , gdzie $C > 0$ nie zmienia porządku).

Miara odmienności/niepodobieństwa

Uwagi cd.

- 6) Określając odpowiednio macierz odmienności możemy łączyć (integrować) dane pochodzące z różnych źródeł (ang. data fusion), tzn.:

$$d_{ij} = \lambda d_{ij}^{(1)} + (1 - \lambda) d_{ij}^{(2)},$$

gdzie

- $d_{ij}^{(1)}, d_{ij}^{(2)}$ – odmienności na bazie dwóch źródeł danych,
- λ – współczynnik fuzji ($\lambda \in [0, 1]$).

Miara odmienności/niepodobieństwa

Zmienne różnych typów

- Wybór miary odmienności zależy głównie od specyfiki danych.
- Omówimy najczęściej stosowane miary dla różnych typów zmiennych:
 - ① zmienne ilościowe: $\mathcal{X} = \mathbb{R}^p$,
 - ② zmienne binarne: $\mathcal{X} = \{0, 1\}^p$,
 - ③ zmienne porządkowe,
 - ④ zmienne nominalne,
 - ⑤ **wersja ogólna**: atrybuty różnych typów.

Miara odmienności/niepodobieństwa

Zmienne ilościowe: $\mathcal{X} = \mathbb{R}^p$

- Odległość euklidesowa

$$d_{ij}^E = \sqrt{\sum_{k=1}^p (x_{i,k} - x_{j,k})^2}.$$

- Odległość Minkowskiego

$$d_{ij}^M = \left(\sum_{k=1}^p |x_{i,k} - x_{j,k}|^q \right)^{1/q}, \quad q \in \mathbb{N}.$$

- Odległość korelacyjna

$$d_{ij}^C = 1 - \frac{\sum_{k=1}^p (x_{i,k} - \bar{x}_i)(x_{j,k} - \bar{x}_j)}{\sqrt{\sum_{k=1}^p (x_{i,k} - \bar{x}_i)^2 \sum_{k=1}^p (x_{j,k} - \bar{x}_j)^2}},$$


gdzie $\bar{x}_i = \sum_{k=1}^p x_{i,k} / p$ – średnia względem p zmiennych.

Miara odmienności/niepodobieństwa

Zmienne ilościowe: $\mathcal{X} = \mathbb{R}^p$

Uwaga: Wybór odpowiedniej miary odległości zależy od konkretnego zagadnienia (np. odległość korelacyjną stosujemy aby uwzględnić podobieństwo wzorców / profili).

Przykład:



Odległość euklidesowa			
	x	y	z
x	0.00	3.67	3.77
y	3.67	0.00	3.57
z	3.77	3.57	0.00

Odległość korelacyjna			
	x	y	z
x	0.00	0.04	1.81
y	0.04	0.00	1.91
z	1.81	1.91	0.00

Miara odmienności/niepodobieństwa

Zmienne ilościowe: $\mathcal{X} = \mathbb{R}^p$

- Uogólnienie: ważona odległość euklidesowa

$$d_{ij}^{E_w} = \sqrt{\sum_{k=1}^p w_k^2 (x_{i,k} - x_{j,k})^2}.$$

- Przyjmując wagi $w_k = 1/std(X_k)$, każda cecha (zmienna) będzie miała jednakowy wkład do miary odległości.

Miara odmienności/niepodobieństwa

Zmienne binarne: $\mathcal{X} = \{0, 1\}^p$

Założenie: mamy p zmiennych binarnych, tzn. $\mathcal{X} = \{0, 1\}^p$. Niech

$$\underline{x}_i, \underline{x}_j \in \mathcal{X}.$$

i/j	1	0	Σ
1	a	b	a+b
0	c	d	c+d
Σ	a+c	b+d	p

- Unormowana odległość Hamminga (współczynnik dopasowania)

$$d_{ij}^H = \frac{b+c}{p} = \frac{b+c}{a+b+c+d}.$$

Stosujemy dla zmiennych binarnych symetrycznych ('0' i '1' są jednakowo ważne).

Miara odmienności/niepodobieństwa

Zmienne binarne: $\mathcal{X} = \{0, 1\}^p$

Założenie: mamy p zmiennych binarnych, tzn. $\mathcal{X} = \{0, 1\}^p$. Niech

$$\underline{x}_i, \underline{x}_j \in \mathcal{X}.$$

i/j	1	0	Σ
1	a	b	a+b
0	c	d	c+d
Σ	a+c	b+d	p

- Współczynnik (odległość) Jaccarda

$$d_{ij}^J = \frac{b + c}{a + b + c}.$$

Stosujemy dla zmiennych binarnych asymetrycznych ('1' ma większe znaczenie).

Miara odmienności/niepodobieństwa

Zmienne binarne: $\mathcal{X} = \{0, 1\}^p$

Przykład: Dane o zwierzętach ($p = 5$ cech binarnych)

gatunek	cechy				
	hair	feathers	predator	aquatic	fins
bear	1	0	1	0	0
carp	0	0	0	1	1
duck	0	1	0	1	0
elephant	1	0	0	0	0

- Dla przykładu:
 - odległość Hamminga:** $d_H(\text{carp}, \text{duck}) = 2/5 = 0,4$
 - odległość Jaccarda:** $d_J(\text{carp}, \text{duck}) = 2/3 \approx 0,67$.

Miara odmienności/niepodobieństwa

Zmienne binarne: $\mathcal{X} = \{0, 1\}^P$

Przykład cd.: Porównanie macierzy odległości

		bear	carp	duck	elephant
Odległość Hamminga	bear	0.0	0.8	0.8	0.2
	carp	0.8	0.0	0.4	0.6
	duck	0.8	0.4	0.0	0.6
	elephant	0.2	0.6	0.6	0.0

		bear	carp	duck	elephant
Odległość Jaccarda	bear	0.0	1.0	1.0	0.5
	carp	1.0	0.0	0.67	1.0
	duck	1.0	0.67	0.0	1.0
	elephant	0.5	1.0	1.0	0.0

Miara odmienności/niepodobieństwa

Zmienne porządkowe

- **Idea:** zmienne porządkowe przekształcamy do zmiennych ilościowych.
- Wartość cechy $x_{i,k}$ zastępujemy rangą $r_{i,k} \in \{1, \dots, M_k\}$ i przekształcamy do $[0, 1]$, tzn. wyznaczamy

$$z_{i,k} = \frac{r_{i,k} - 1}{M_k - 1}.$$

- Dalej, dla tak przekształconej zmiennej, korzystamy z miar odległości dla zmiennych ilościowych.

Miara odmienności/niepodobieństwa

Zmienne nominalne

- Załóżmy, że mamy p zmiennych nominalnych.
- Do mierzenia odległości możemy wykorzystać unormowaną odległość Hamminga, tzn.

$$d_{ij} = \frac{p - m}{p},$$

gdzie m – liczba zmiennych przyjmujących jednakowe wartości.

Miara odmienności/niepodobieństwa

Wersja ogólna – atrybuty różnych typów

- W ogólnym przypadku, gdy mamy p atrybutów różnych typów możemy wykorzystać **miarę odmienności Gowera**

$$d_{ij} = \sum_{k=1}^p w_k d_{ij}^k / \sum_{k=1}^p w_k, \quad \text{gdzie:}$$

- w_k – waga k -tej zmiennej,
- $d_{i,j}^k$ – odległość (odmiennosc) wyznaczona na bazie k -tej zmiennej.
- Zakładamy, że odmiennosci cząstkowe i końcowa są znormalizowane do $[0,1]$, tzn. $d_{i,j}^k \in [0,1]$ i $d_{i,j} \in [0,1]$.
- Przyjmujemy

$$w_k = \begin{cases} 0, & \text{gdy mamy przynajmniej jedną wartość brakującą} \\ & \text{lub dla zmiennej binarnej asymetrycznej i obu wartości} = 0, \\ 1, & \text{w pozostałych przypadkach.} \end{cases}$$

Miara odmienności/niepodobieństwa w pakiecie R

- Funkcja `dist()` (pakiet `stats`) - podstawowa funkcja do obliczania odległości między wierszami macierzy lub ramki danych (metody: "euclidean", "maximum", "manhattan", "canberra", "binary", "minkowski").
- Funkcja `daisy()` (pakiet `cluster`) - bardziej zaawansowana funkcja, która obsługuje dane typu mieszanego (zmienne ilościowe i jakościowe), w szczególności implementuje miarę odmienności Gowera.
- R-pakiety implementujące inne (specjalistyczne) miary: `philentropy`, `proxy`, `TSdist`, `vegan`, `sf`, `geosphere`, ...

Niestandardowe miary podobieństwa / odmienności

- Klasyczne miary podobieństwa mogą być niewystarczające, szczególnie gdy mamy do czynienia z danymi o nietypowej lub złożonej strukturze.
- Przykłady sytuacji wymagających zastosowania niestandardowych miar podobieństwa / odmienności:
 - Analiza danych tekstowych - np. porównywanie dokumentów, wykrywanie plagiatów itp.
 - Analiza szeregów czasowych i sygnałów – np. badanie przebiegów giełdowych, sygnałów medycznych (EKG/EEG) itp.
 - Eksploracja danych grafowych - np. analiza powiązań w sieciach społecznościowych,
 - Analiza danych przestrzennych i geoinformacyjnych.
- Omówimy dokładniej dwa przykłady
 - 1 odległość Levenshteina (edycyjna),
 - 2 podobieństwo semantyczne (znaczeniowe).

Niestandardowe miary podobieństwa – przykłady

Odległość Levenshteina (edycyjna)

- **Odległość Levenshteina (edycyjna)** między dwoma napisami to najmniejsza liczba tzw. operacji prostych, które przekształcają jeden napis w drugi.
- Działania proste:
 - wstawienie nowego znaku do napisu,
 - usunięcie znaku z napisu,
 - zamiana znaku w napisie na inny znak.

Niestandardowe miary podobieństwa – przykłady

Odległość Levenshteina (edycyjna)

		S	A	T	U	R	D	A	Y
	0	1	2	3	4	5	6	7	8
S	1	0 (<i>'S'='S'</i>)	1 (<i>usun 'A'</i>)	2 (<i>usun 'T'</i>)	3	4	5	6	7
U	2	1	1	2	2 (<i>'U'='U'</i>)	3	4	5	6
N	3	2	2	2	3	3 (<i>'R' → 'N'</i>)	4	5	6
D	4	3	3	3	3	4	3 (<i>'D'='D'</i>)	4	5
A	5	4	3	4	4	4	4	3 (<i>'A'='A'</i>)	4
Y	6	5	4	4	5	5	5	4	3 (<i>'Y'='Y'</i>)

W pakiecie R:

```
> adist("SATURDAY", "SUNDAY")
3
```

Niestandardowe miary podobieństwa – przykłady

Podobieństwo semantyczne (znaczeniowe)


Słowność (PIWordNet): <http://plwordnet.pwr.wroc.pl/wordnet/>



Niestandardowe miary podobieństwa – przykłady

Podobieństwo semantyczne (znaczeniowe)

Przykład: graf reprezentujący zależności między słowami



Niestandardowe miary podobieństwa – przykłady

Podobieństwo semantyczne (zaczeniowe)

Przykład: znajdowanie słów o podobnym znaczeniu

samochód	
podobieństwo	jednostka leksykalna
0.368	pojazd
0.350	auto
0.297	ciężarówka
0.290	wóz
0.262	autobus
0.230	furgonetka
0.220	limuzyna
0.218	taksówka
0.216	autokar
0.206	motocykl
0.203	radiowóz
0.191	pociąg
0.185	lokomotywa


(C) 2026, A.Zagdański, Podobieństwo, odmienność i odległość między obiektami

25/27

Niestandardowe miary podobieństwa – przykłady

Podobieństwo semantyczne (zaczeniowe)

Przykład: ocena podobieństwa genów pod względem pełnionych funkcji
(na podstawie repozytorium Gene Ontology (GO))



(C) 2026, A.Zagdański, Podobieństwo, odmienność i odległość między obiektami

26/27

Dziękuję za uwagę!