

Wprowadzenie do klasyfikacji

Adam Zagdański

Wydział Matematyki PWr

Wrocław
17 IV 2026

Rodzaje zadań związanych z prognozowaniem
Ogólne sformułowanie zadania klasyfikacji
Przykłady prostych metod klasyfikacji – przypadek $K = 2$ klas
Dekompozycja błędu prognozy
Klasyfikacja w przypadku $K \geq 3$ klas

Plan prezentacji

- 1 Rodzaje zadań związanych z prognozowaniem
- 2 Ogólne sformułowanie zadania klasyfikacji
- 3 Przykłady prostych metod klasyfikacji – przypadek $K = 2$ klas
 - Model liniowy regresji
 - Metoda k najbliższych sąsiadów
- 4 Dekompozycja błędu prognozy
- 5 Klasyfikacja w przypadku $K \geq 3$ klas
 - Model liniowej regresji wielowymiarowej
 - Algorytm k -NN

Dwa rodzaje zadań związanych z prognozowaniem

Niezbędne oznaczenia

- **Przypomnienie:** p -wymiarowy wektor cech/atrybutów/zmiennych objaśniających/predyktorów opisujących dany obiekt będziemy oznaczali jako:

$$\underline{X} = (X_1, X_2, \dots, X_p)^T \in \mathcal{X}$$

- W najprostszym przypadku: $\mathcal{X} = \mathbb{R}^p$.
- W ogólności cechy mogą być zarówno ilościowe (ang. quantitative) jak i jakościowe (ang. qualitative).
- Stosujemy zwyczajową konwencję aby odróżnić wielkości teoretyczne od obserwowanych tzn.: $\underline{X} = (X_1, X_2, \dots, X_p)^T$ i $\underline{x} = (x_1, x_2, \dots, x_p)^T$.

Dwa rodzaje zadań związanych z prognozowaniem

Niezbędne oznaczenia

- Zmienną zależną (objaśnianą) będziemy oznaczali jako:
 - Y – gdy prognozujemy zmienną ilościową,
 - G – gdy prognozujemy zmienną jakościową.

Cel

Mając wektor wejściowy $\underline{X}$ skonstruować jak najlepsze prognozy zmiennej zależnej.

Dwa rodzaje zadań związanych z prognozowaniem

1 REGRESJA

- Idea: prognozujemy zmienną ilościową.
- Oznaczenia: Y – zmienna zależna ($Y \in R$), $\hat{Y}$ – prognoza.

2 KLASYFIKACJA

- Idea: prognozujemy zmienną jakościową, np. etykietkę klasy/grupy.
- Oznaczenia: $G \in \mathcal{G} = \{1, 2, \dots, K\}$, $\hat{G}$ – prognozowana etykieta.
- Przykłady:
 $\mathcal{G} = \{\text{chory}, \text{zdrowy}\}$,
 $\mathcal{G} = \{\text{setosa}, \text{versicolor}, \text{virginica}\}$ (klasyfikacja irysów),
 $\mathcal{G} = \{0, 1, \dots, 9\}$ (rozpoznawanie ręcznie pisanych cyfr).

Dwa rodzaje zadań związanych z prognozowaniem

Dodatkowe uwagi

- Niektóre metody/algorytmy klasyfikacji można zastosować wyłącznie dla cech ilościowych, inne – wyłącznie dla jakościowych. Mamy również takie metody, które radzą sobie z obsługą cech różnych typów.
- W przypadku, kiedy mamy tylko dwie klasy mówimy o **klasyfikacji binarnej**.
- Oba typy zadań są ze sobą ściśle powiązane.
- Zadanie klasyfikacji często można przedstawić również jako zadanie regresji.

Ogólne sformułowanie zadania klasyfikacji

Zadanie klasyfikacji

Naszym celem jest skonstruowanie reguły decyzyjnej $G(\underline{x})$ (reguły dyskryminacyjnej, reguły klasyfikacyjnej, klasyfikatora), która będzie dla dowolnej obserwacji $\underline{x} \in \mathcal{X}$ przypisywała przynależność do jednej z klas ze zbioru $\mathcal{G}$.

Formalnie:

$$G : \mathcal{X} \rightarrow \mathcal{G}.$$

Ogólne sformułowanie zadania klasyfikacji

Dodatkowe uwagi

- Nie zawsze możliwe jest wyznaczenie jawnej (analitycznej) postaci reguły klasyfikacyjnej $G(\underline{x})$.
- W przypadku niektórych metod mamy jedynie zestaw reguł lub algorytm pozwalający na wyznaczenie prognozowanej etykiety.
- Wynikiem zwracanym przez klasyfikator może być także prawdopodobieństwo a posteriori tego, że dany obiekt należy do danej klasy, tzn. $P(G = g | X = \underline{x})$.

Klasyfikacja jako przykład uczenia nadzorowanego (ang. supervised learning)

- **Przypomnienie:** system uczący się pod nadzorem ma za zadanie nauczyć się rozpoznawania zależności pomiędzy X i Y na podstawie zbioru uczącego (treningowego).
- System taki wykorzystany jest następnie do prognozowania (predykcji) wartości Y dla nowo zaobserwowanych wartości wejściowych X .
- Do konstrukcji klasyfikatora również wykorzystujemy dane uczące (ang. learning/training set)

$$\{(\underline{x}_i, g_i) : \underline{x}_i \in \mathcal{X}, g_i \in \mathcal{G}\}_{i=1, \dots, n}$$

Klasyfikacja – przykłady praktyczne

- Diagnostyka medyczna (2 klasy: nowotwór łagodny / nowotwór złośliwy)
- Analiza ryzyka kredytowego (2 klasy: GOOD/BAD)
- Klasyfikacja e-maili (2 klasy: spam / nie spam)
- Rozpoznawanie ręcznie pisanych cyfr (10 klas: 0,1,...,9)
- Klasyfikacja: gen – pełniona funkcja biologiczna (kilka tysięcy klas)
- ...

Przykłady prostych metod klasyfikacji

Przypadek $K = 2$ klas

- Na początek klasyfikację sprowadzimy do zagadnienia regresji
- Dla uproszczenia rozważmy przypadek klasyfikacji binarnej (2 klasy)
- Przyjmujemy standardowe kodowanie klas:
 - $Y = 0$ (gdy $G = \text{"klasa 1"}$),
 - $Y = 1$ (gdy $G = \text{"klasa 2"}$).
- Rozważmy dwie najprostsze metody
 - 1 Model liniowy regresji,
 - 2 Metodę k -najbliższych sąsiadów.

Model liniowy regresji

Założenia

- Zakładamy, że wpływ każdej rozpatrywanej zmiennej **objaśniającej** (zmiennej **niezależnej**) X_i na zmienną **objaśnianą** (zmienną **zależną**) Y jest liniowy.
- Formalnie, przyjmujemy model postaci:

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \cdots + \beta_p X_p + \epsilon,$$

gdzie ϵ – błędy losowe o wartości średniej 0 i jednakowej (nieznanej) wariancji σ^2 (zwykle zakładamy także dodatkowo rozkład normalny).

Model liniowy regresji

- Jako prognozę zmiennej zależnej Y przyjmujemy

$$\hat{Y} = \hat{\beta}_0 + \sum_{j=1}^p \hat{\beta}_j X_j,$$

gdzie $\hat{\beta}_j$ - estymatory (oceny) nieznanych współczynników.


- W postaci wektorowej możemy zapisać:

$$\hat{Y} = \underline{X}^T \underline{\hat{\beta}},$$

gdzie $\underline{X} = (1, X_1, \dots, X_p)^T$ oraz $\underline{\hat{\beta}} = (\hat{\beta}_0, \hat{\beta}_1, \dots, \hat{\beta}_p)^T$.

Model liniowy regresji

Przykłady: interpretacja geometryczna



Rysunek: Dane Cars93 - dopasowane modele regresji liniowej

Model liniowy regresji

Metoda najmniejszych kwadratów (MNK)

- W praktyce, do wyznaczenia estymowanych współczynników wykorzystujemy **metodę najmniejszych kwadratów (MNK)**.
- Szukamy wektora współczynników $\underline{\beta} = (\beta_0, \beta_1, \dots, \beta_p)^T$, który minimalizuje sumę kwadratów

$$S(\underline{\beta}) = \sum_{i=1}^n (y_i - (\beta_0 + \beta_1 x_{i,1} + \dots + \beta_p x_{i,p}))^2 = \sum_{i=1}^n (y_i - \hat{y}_i)^2$$

- Równoważnie, w postaci wektorowej możemy zapisać

$$S(\underline{\beta}) = \sum_{i=1}^n (y_i - \underline{x}_i^T \underline{\beta})^2 = (\underline{y} - \mathbb{X} \underline{\beta})^T (\underline{y} - \mathbb{X} \underline{\beta}).$$

Model liniowy regresji

Metoda najmniejszych kwadratów (MNK)

Fakt

Jeżeli kolumny macierzy $\mathbb{X}^T \mathbb{X}$ są liniowo niezależne, to jest ona odwracalna i otrzymujemy jawną postać estymatorów MNK

$$\hat{\underline{\beta}} = (\mathbb{X}^T \mathbb{X})^{-1} \mathbb{X}^T \underline{y}$$

gdzie:

- $\mathbb{X}_{n \times (p+1)}$ – macierz modelu (macierz eksperymentu),

$$\mathbb{X}_{n \times (p+1)} = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & & & & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}.$$

- $\underline{y} = (y_1, y_2, \dots, y_n)^T$ – wektor wartości zmiennej zależnej.

Model liniowy regresji

Prognoza zmiennej zależnej

- Niech $\underline{x}_0 = (1, x_{0,1}, x_{0,2}, \dots, x_{0,p})^T$ – dowolny wektor wejściowy.
- Wówczas prognozę zmiennej zależnej wyznaczamy jako

$$\hat{y}(\underline{x}_0) = \underline{x}_0^T \cdot \underline{\hat{\beta}}.$$

Model liniowy regresji

PRZYKŁAD

- Dane symulowane, 2 klasy.
- $X = (X_1, X_2) \in \mathbb{R}^2$.
- $G \in \{BLUE, ORANGE\}$.
- Kodowanie dla Y :
 $BLUE = 0, ORANGE = 1$.
- Liczność: $n = 100 + 100$.
- Reguła klasyfikacyjna

$$\hat{G} = \begin{cases} ORANGE & \text{jeżeli } \hat{Y} > 0.5, \\ BLUE & \text{jeżeli } \hat{Y} \leq 0.5. \end{cases}$$

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 2




FIGURE 2.1. A classification example in two dimensions. The classes are coded as a binary variable ($BLUE = 0$, $ORANGE = 1$), and then fit by linear regression. The line is the decision boundary defined by $x^T \hat{\beta} = 0.5$. The orange shaded region denotes that part of input space classified as $ORANGE$, while the blue region is classified as $BLUE$.

Model liniowy regresji

PRZYKŁAD c.d.

- Reguła klasyfikacyjna

$$\hat{G} = \begin{cases} \text{ORANGE} & \text{jeżeli } \hat{Y} > 0.5, \\ \text{BLUE} & \text{jeżeli } \hat{Y} \leq 0.5. \end{cases}$$

$$\hat{G} = \begin{cases} \text{ORANGE} & \{x : x^T \hat{\beta} > 0.5\}, \\ \text{BLUE} & \{x : x^T \hat{\beta} \leq 0.5\}. \end{cases}$$

- Granica decyzyjna:

$$\{(x_1, x_2) : \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 = 0.5\}$$

$$\{x : x^T \hat{\beta} = 0.5\}$$

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 2




FIGURE 2.1. A classification example in two dimensions. The classes are coded as a binary variable (BLUE = 0, ORANGE = 1), and then fit by linear regression. The line is the decision boundary defined by $x^T \hat{\beta} = 0.5$. The orange shaded region denotes that part of input space classified as ORANGE, while the blue region is classified as BLUE.

Model liniowy regresji

PRZYKŁAD c.d.

- Czy liniowy model regresji dobrze się sprawdza?
- Jakie problemy dostrzegamy?
- Czy inny model byłby lepszy?

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 2




FIGURE 2.1. A classification example in two dimensions. The classes are coded as a binary variable (BLUE = 0, ORANGE = 1), and then fit by linear regression. The line is the decision boundary defined by $x^T \hat{\beta} = 0.5$. The orange shaded region denotes that part of input space classified as ORANGE, while the blue region is classified as BLUE.

Metoda k najbliższych sąsiadów

(k-nearest neighbors, k-NN)

- **Idea:** dla danego obiektu $\underline{x}$ wyznaczamy jego k najbliższych sąsiadów w zbiorze uczącym $\{(\underline{x}_i, y_i)\}_{i=1, \dots, n}$, wykorzystując przyjętą miarę odległości (np. odległość euklidesową).
- Oznaczamy:
 $N_k(\underline{x})$ – k najbliższych sąsiadów dla obserwacji $\underline{x}$ w zbiorze uczącym (k obserwacji najbliższych $\underline{x}$ w sensie odległości euklidesowej).
- Prognoza

$$\hat{Y}(\underline{x}) = \frac{1}{k} \sum_{\underline{x}_i \in N_k(\underline{x})} y_i$$

Metoda k najbliższych sąsiadów

(k-nearest neighbors, k-NN)

PRZYKŁAD c.d.

- $\hat{Y}(\underline{x}) = \frac{1}{k} \sum_{\underline{x}_i \in N_k(\underline{x})} y_i$
- Reguła klasyfikacyjna

$$\hat{G} = \begin{cases} \text{ORANGE} & \text{jeżeli } \hat{Y} > 0.5, \\ \text{BLUE} & \text{jeżeli } \hat{Y} \leq 0.5. \end{cases}$$
- Przyjmijmy $k = 15$ (metoda 15-NN)
- Problem: jak dobrać optymalną wartość parametru k ?

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 2




FIGURE 2.2. The same classification example in two dimensions as in Figure 2.1. The classes are coded as a binary variable (BLUE = 0, ORANGE = 1) and then fit by 15-nearest-neighbor averaging as in (2.8). The predicted class is hence chosen by majority vote amongst the 15-nearest neighbors.

Metoda k najbliższych sąsiadów (k-nearest neighbors, k-NN)

15-NN

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 2




FIGURE 2.2. The same classification example in two dimensions as in Figure 2.1. The classes are coded as a binary variable (BLUE = 0, ORANGE = 1) and then fit by 15-nearest-neighbor averaging as in (2.8). The predicted class is hence chosen by majority vote amongst the 15-nearest neighbors.

1-NN

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 2




FIGURE 2.3. The same classification example in two dimensions as in Figure 2.1. The classes are coded as a binary variable (BLUE = 0, ORANGE = 1), and then predicted by 1-nearest-neighbor classification.

Porównanie: model liniowy vs. k-NN Błąd klasyfikacji na zbiorze uczącym i testowym.

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 2




FIGURE 2.4. Misclassification curves for the simulation example used in Figures 2.1, 2.2 and 2.3. A single training sample of size 200 was used, and a test sample of size 10,000. The orange curves are test and the blue are training error for k-nearest-neighbor classification. The results for linear regression are the bigger orange and blue squares at three degrees of freedom. The purple line is the optimal Bayes error rate.

Optymalny klasyfikator bayesowski

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 2




FIGURE 2.5. The optimal Bayes decision boundary for the simulation example of Figures 2.1, 2.2 and 2.3. Since the generating density is known for each class, this boundary can be calculated exactly (Exercise 2.2).

Dekompozycja błędu prognozy

- Dla uproszczenia rozważmy model regresji, tzn. zakładamy, że

$$Y = f(X) + \varepsilon,$$

gdzie

- $f(\cdot)$ – funkcja regresji,
- ε – zakłócenie losowe; $E(\varepsilon) = 0$ i $\text{Var}(\varepsilon) = \sigma^2$.
- Rozważmy **oczekiwany błąd predykcji** (ang. **Expected Prediction Error, EPE**)

$$\text{EPE}(x_0) = E(Y - \hat{f}(x_0))^2$$

- Można pokazać, że

$$\text{EPE}(x_0) = \sigma^2 + \text{bias}^2(\hat{f}(x_0)) + \text{Var}(\hat{f}(x_0)).$$

Dekompozycja błędu prognozy

Uzasadnienie:

$$\begin{aligned} EPE(x_0) &= E(Y - \hat{f}(x_0))^2 \\ &= E\left((Y - f(x_0)) + (f(x_0) - \hat{f}(x_0))\right)^2 \\ &= E(Y - f(x_0))^2 + E(f(x_0) - \hat{f}(x_0))^2 + 2E(Y - f(x_0))(f(x_0) - \hat{f}(x_0)) \\ &= \sigma^2 + E(f(x_0) - \hat{f}(x_0))^2 \\ &= \sigma^2 + MSE(\hat{f}(x_0)) \quad // \text{ MSE – błąd średniokwadratowy} \\ &= \sigma^2 + E\left((f(x_0) - E\hat{f}(x_0)) + (E\hat{f}(x_0) - \hat{f}(x_0))\right)^2 \\ &= \sigma^2 + (E\hat{f}(x_0) - f(x_0))^2 + E(\hat{f}(x_0) - E\hat{f}(x_0))^2 \\ &= \sigma^2 + bias^2(\hat{f}(x_0)) + Var(\hat{f}(x_0)) \end{aligned}$$

Dekompozycja błędu prognozy


Interpretacja

- Oczekiwany błąd predykcji (Expected Prediction Error, EPE)

$$EPE(x_0) = \sigma^2 + bias^2(\hat{f}(x_0)) + Var(\hat{f}(x_0))$$

- σ^2 – składnik nieredukowalny związany z wariancją nowego przypadku testowego (poza naszą kontrolą, nawet jeżeli znamy prawdziwą postać $f(\cdot)$),
- Jeżeli rośnie złożoność modelu: rośnie wariancja i maleje obciążenie (bias).
- Odwrotna sytuacja występuje, gdy złożoność modelu maleje.
- **Wniosek:** Kluczowe jest znalezienie kompromisu między obciążeniem a wariancją!

Dekompozycja błędu prognozy



Klasyfikacja z wykorzystaniem regresji liniowej

Przypadek K klas ($K \geq 3$)

Niezbędne oznaczenia

- Mamy: n obserwacji, K klas (grup), p cech (zmiennych).
- Wektor zmiennych zależnych: $y_i = (y_{i1}, \dots, y_{iK})$, gdzie

$$y_{ik} = \begin{cases} 1, & \text{jeżeli } g_i = k, \\ 0, & \text{jeżeli } g_i \neq k. \end{cases}$$

- Macierz wskaźników (ang. indicator matrix)

$$\mathbb{Y}_{n \times K} = \begin{bmatrix} y_{11} & \dots & y_{1K} \\ y_{21} & \dots & y_{2K} \\ \vdots & & \vdots \\ y_{n1} & \dots & y_{nK} \end{bmatrix}$$

(oczywiście w każdym wierszu mamy tylko jedną wartość równą 1 i pozostałe wartości równe 0)

Klasyfikacja z wykorzystaniem regresji liniowej

Przypadek K klas ($K \geq 3$)

Niezbędne oznaczenia c.d.

- Macierz modelu

$$\mathbb{X}_{n \times (p+1)} = \begin{bmatrix} 1 & x_{11} & x_{12} & \dots & x_{1p} \\ 1 & x_{21} & x_{22} & \dots & x_{2p} \\ \vdots & & & & \vdots \\ 1 & x_{n1} & x_{n2} & \dots & x_{np} \end{bmatrix}.$$

- Prognoza

$$\hat{\mathbb{Y}} = \mathbb{X}(\mathbb{X}^T \mathbb{X})^{-1} \mathbb{X}^T \mathbb{Y} = \mathbb{X} \cdot \hat{\mathbb{B}}.$$

- Macierz estymowanych współczynników

$$\hat{\mathbb{B}}_{(p+1) \times K} = (\mathbb{X}^T \mathbb{X})^{-1} \mathbb{X}^T \mathbb{Y}.$$

Klasyfikacja z wykorzystaniem regresji liniowej

Reguła decyzyjna

Zakładamy, że mamy nowy przypadek (obiekt), opisany przez p cech

$$\underline{x}_0 = (1, x_{01}, x_{02}, \dots, x_{0p})^T.$$

- Wyznaczamy prognozę (K -wymiarowy wektor):

$$\hat{y}_0 = \hat{f}(\underline{x}_0) = [\underline{x}_0^T \cdot \hat{\mathbb{B}}]^T$$

(oznaczmy: $\hat{f}(\underline{x}_0) = (\hat{f}_1(\underline{x}_0), \dots, \hat{f}_K(\underline{x}_0))^T$)

- Przypisujemy tę klasę, dla której otrzymujemy największą wartość $\hat{f}_k(\underline{x}_0)$:

$$\hat{G}(\underline{x}_0) = \operatorname{argmax}_{k \in \mathcal{G}} \hat{f}_k(\underline{x}_0).$$

Klasyfikacja z wykorzystaniem regresji liniowej

Reguła decyzyjna

Uwaga

Zamiast konstruować klasyfikator na bazie modelu regresji dla wektora zmiennych zależnych $Y = (Y_1, \dots, Y_K)$ możemy równoważnie zbudować K niezależnych modeli regresji, przyjmując w k -tym modelu jako zmienną zależną indykator k -tej klasy, tzn. Y_k (gdzie $k = 1, 2, \dots, K$).

Klasyfikacja z wykorzystaniem regresji liniowej

Uzasadnienie formalne

- W naszym przypadku: $Y = (Y_1, \dots, Y_K)$
- Składowe funkcje regresji $f(x) = (f_1(x), \dots, f_K(x))$ możemy interpretować jako odpowiednie warunkowe wartości oczekiwane

$$f_k(x) = E(Y_k | X = x)$$

- Z drugiej strony:

$$E(Y_k | X = x) = P(G = k | X = x)$$

- Estymując funkcję regresji, szacujemy prawdopodobieństwo a posteriori

$$\hat{f}_k(x) = \hat{P}(G = k | X = x).$$

- Prognozowaną klasą jest więc ta klasa, dla której prawdopodobieństwo a posteriori jest największe.

Klasyfikacja z wykorzystaniem regresji liniowej

Dodatkowe uwagi

- Można pokazać, że

$$\forall x \quad \sum_{k \in \mathcal{G}} \hat{f}_k(x) = 1.$$

- Z drugiej strony, niektóre wartości $\hat{f}_k(x)$ mogą być ujemne lub większe od 1.
- Pytanie:** Czy zastosowanie modelu regresji liniowej do konstrukcji reguły klasyfikacyjnej będzie dawało zadowalające wyniki?

Klasyfikacja z wykorzystaniem regresji liniowej

Problem maskowania klas, gdy $K > 2$

- Klasyfikacja z wykorzystaniem modelu regresji liniowej może nie działać poprawnie w przypadku, gdy liczba klas $K > 2$.
- W tym przypadku może wystąpić tzw. zjawisko **maskowania klas**.
- W skrajnym przypadku, reguła klasyfikacyjna może w ogóle pomijać istnienie jednej z klas (nigdy na nią nie wskazując!).

Klasyfikacja z wykorzystaniem regresji liniowej

Problem maskowania klas, gdy $K > 2$

Przykład: Efekt maskowania (przesłaniania) środkowej klasy.

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 4




FIGURE 4.2. The data come from three classes in $\mathbb{R}^2$ and are easily separated by linear decision bound-
 (C) 2026, A.Zagdański, Wprowadzenie do klasyfikacji

37/49

linear discriminant analysis. The left plot shows the boundaries found by linear regression of the indica-
 tor response variables. The middle class is completely

Klasyfikacja z wykorzystaniem regresji liniowej

Problem maskowania klas, gdy $K \geq 3$

Przykład: Efekt maskowania (przesłaniania) środkowej klasy.

Ilustracja: Rzutujemy dane na prostą łączącą środki centrów klas i wyznaczamy indykatory Y_1, Y_2 i Y_3 . Error – oznacza błąd na zbiorze uczącym.

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 4




FIGURE 4.3. The effects of masking on linear regres-
 (C) 2026, A.Zagdański, Wprowadzenie do klasyfikacji

38/49

the base indicates the positions and class membership

Klasyfikacja z wykorzystaniem regresji liniowej

Problem maskowania klas, gdy $K \geq 3$

Reguła praktyczna

- Rozważamy zastosowanie modelu regresji liniowej w zagadnieniu klasyfikacji do K klas. Aby otrzymać dobrą separację klas, powinniśmy uwzględnić składniki wielomianowe i iloczyny zmiennych stopnia $K - 1$.
- Dla przykładu: Jeżeli $K = 3$ i $X = (X_1, X_2) \in \mathbb{R}^2$, do budowy klasyfikatora wykorzystujemy $\tilde{X} = (X_1, X_2, X_1^2, X_2^2, X_1X_2)$.
- W ogólności: w przypadku p -wymiarowej przestrzeni cech możemy potrzebować $O(p^{K-1})$ składników (w najgorszym przypadku).

Klasyfikacja z wykorzystaniem regresji liniowej

Przykład dla danych rzeczywistych

Przykład: Rozpoznawanie samogłosek języka angielskiego.

- Mamy $K = 11$ klas i $p = 10$ cech.
- Trudny problem klasyfikacyjny. Dla najlepszych metod uzyskano błędy klasyfikacji rzędu 40% dla danych testowych.
- Zobaczmy jak poradziła sobie regresja liniowa na tle innych metod.

Klasyfikacja z wykorzystaniem regresji liniowej

Zastosowanie dla danych rzeczywistych

Przykład: Rozpoznawanie samogłosek języka angielskiego.
 Dane po zrzutowaniu do przestrzeni 2-wymiarowej.

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 4




FIGURE 4.4. A two-dimensional plot of the vowel training data. There are eleven classes with $X \in \mathbb{R}^{10}$, and this is the best view in terms of a LDA model (Section 4.3.3). The heavy circles are the projected mean

(C) 2026, A.Zagdański, Wprowadzenie do klasyfikacji

41/49

Klasyfikacja z wykorzystaniem regresji liniowej

Zastosowanie dla danych rzeczywistych

Przykład: Rozpoznawanie samogłosek języka angielskiego.

Technique	Error Rates	
	Training	Test
Linear regression	0.48	0.67
Linear discriminant analysis	0.32	0.56
Quadratic discriminant analysis	0.01	0.53
Logistic regression	0.22	0.51

Tabela: Porównanie wyników (źródło: Tab.4.1, [HTF]).

Algorytm k -NN (k najbliższych sąsiadów)

Przypadek $K \geq 3$ klas

- Algorytm k -NN możemy łatwo uogólnić na przypadek $K \geq 3$ klas.
- Reguła decyzyjna: obiekt $\underline{x}$ zaliczamy do tej klasy, do której należy większość z jego k najbliższych sąsiadów (z próby uczącej).
- Formalnie, metoda k -NN daje bezpośrednie oszacowanie prawdopodobieństw a posteriori

$$\hat{P}(G = g|\underline{x}) = \frac{1}{k} \sum_{i=1}^n \mathbb{I}(d(\underline{x}, \underline{x}_i) \leq d(\underline{x}, \underline{x}^{(k)})) \cdot \mathbb{I}(y_i = g), \quad g = 1, \dots, K;$$

gdzie:

- $\underline{x}^{(k)}$ – k -ty co do odległości od $\underline{x}$ element próby uczącej,
- $d(\cdot, \cdot)$ – odległość (lub ogólniej: miara niepodobieństwa).

Algorytm k -NN (k najbliższych sąsiadów)

Problemy praktyczne

- Klasyfikator dla metody k -NN ma postać

$$\hat{G}(\underline{x}) = \operatorname{argmax}_{g \in \mathcal{G}} \hat{P}(G = g|\underline{x}).$$

- Możliwe problemy związane ze stosowaniem reguły k -NN w praktyce:
 - Może się zdarzyć, że więcej niż jedna obserwacja z próby uczącej jest tak samo odległa od $\underline{x}$ jak k -ta obserwacja (w takim przypadku, aby wyznaczyć prognozowaną etykietkę klasy, zazwyczaj bierzemy pod uwagę nie k ale więcej obserwacji).
 - Mogą się zdarzyć "remisy" w głosowaniu, tzn. więcej niż jedna klasa może mieć tę samą (największą) liczbę reprezentantów (w takim przypadku stosowane są różne strategie, np. wybór losowy "zwycięskiej" klasy lub na wybór na podstawie metody 1-NN).

Algorytm k -NN (k najbliższych sąsiadów)

Wybór miary odległości

- Istotnie znaczenie dla jakości klasyfikacji z wykorzystaniem metody k -NN ma postać zastosowanej **odległości (metryki)** w przestrzeni obserwacji.
- Wybór odpowiedniej miary odległości jest szczególnie ważny wtedy, gdy liczność próby (n) jest mała lub gdy liczba klas (K) jest duża.
- Standardowym i często skutecznym rozwiązaniem jest zastosowanie **odległości euklidesowej**.
- Przed wyznaczaniem odległości pomiędzy obiektami warto również rozważyć zastosowanie **standaryzacji danych**.
- Standaryzacja przekształca zmienne o różnych jednostkach (skalach pomiarowych) w wielkości niemiarowane i porównywalne.

Algorytm k -NN (k najbliższych sąsiadów)

Wybór miary odległości – przypadek cech jakościowych

- Stosując algorytm k -NN, zakładamy zazwyczaj, że obserwacje należą do przestrzeni euklidesowej $\mathbb{R}^p$.
- W szczególności metoda nie może być zastosowana, gdy wektor obserwacji zawiera zmienne jakościowe.
- Dla otrzymania zadowalających wyników wystarcza niekiedy *ad hoc* **zakodowanie zmiennych jakościowych** za pomocą zmiennych ilościowych.
- Bardziej zaawansowanym rozwiązaniem jest zastosowanie uogólnienia pojęcia odległości, tzw. **miary odmienności** (ang. *dissimilarity measure*).
- Jedną z bardziej popularnych miar tego typu jest tzw. miara podobieństwa Gowera (implementacja w R: funkcja `daisy()` w pakiecie `cluster`).

Algorytm k -NN (k najbliższych sąsiadów)

Wybór liczby sąsiadów (k)

- W problemach o małym wymiarze przestrzeni obserwacji (p) dobre wyniki daje często metoda 1-NN.
- Algorytm 1-NN może być jednak zbyt czuły ze względu na losowość (np. małe zmiany w zbiorze uczącym, błędne sklasyfikowanie obiektu itp.).
- W praktyce k dobiera się najczęściej stosując próbę testową lub schemat typu cross-validation (walidacja krzyżowa).
- Oczywiście wraz ze wzrostem k otrzymujemy coraz „gładszą” regułę decyzyjną.

Algorytm k -NN (k najbliższych sąsiadów)

Pozostałe uwagi

- Pomimo swojej prostoty metoda k -NN często daje zadowalające wyniki.
- Nierzadko jednak aby uzyskać satysfakcjonujący rezultat musimy mieć odpowiednio duży zbiór uczący.
- Wadą algorytmu k -NN może być duża złożoność obliczeniowa na etapie klasyfikacji (konieczność wyznaczenia i porównywania odległości).
- Kolejną trudność mogą stanowić wymagania dotyczące zajętości pamięci (konieczność przechowywania danych uczących).

Dziękuję za uwagę!