

# Klasyfikator bayesowski i naiwny klasyfikator bayesowski

Adam Zagdański

Wydział Matematyki PWr

Wrocław  
24 IV 2026

Rzeczywisty poziom błędu  
Klasyfikator bayesowski  
Naiwny klasyfikator bayesowski

## Plan prezentacji

- 1 Rzeczywisty poziom błędu
- 2 Klasyfikator bayesowski
  - Przypadek dwóch klas ( $K = 2$ )
  - Przypadek wieloklasowy ( $K > 2$ )
- 3 Naiwny klasyfikator bayesowski

## Rzeczywisty poziom błędu

- **Zagadnienie klasyfikacji:** prognozowanie (predykcja) nieznanej etykiety  $G \in \mathcal{G}$  na podstawie wektora cech  $X \in \mathcal{X}$  opisujących dany obiekt.
- Chcemy znaleźć taką regułę klasyfikacyjną (klasyfikator)  $d : \mathcal{X} \rightarrow \mathcal{G}$ , która daje dokładną predykcję.
- Miarą dokładności klasyfikatora jest jego rzeczywisty poziom błędu.

Definicja (Rzeczywisty poziom błędu klasyfikatora)

*Rzeczywisty poziom błędu klasyfikatora  $d$  (ang. true error rate) definiujemy jako*

$$e(d) = P(d(X) \neq G).$$

## Przypadek dwóch klas (klasyfikacja binarna)

- Na początek rozważymy przypadek dwóch klas, tzn.  $\mathcal{G} = \{0, 1\}$ .
- Dla uproszczenia założymy również, że  $\mathcal{X} \subseteq \mathbb{R}^p$ .
- Otrzymujemy wówczas

$$\begin{aligned} r(x) = E(G|X = x) &= 1 \cdot P(G = 1|X = x) + 0 \cdot P(G = 0|X = x) \\ &= P(G = 1|X = x) \end{aligned}$$

- Terminologia: funkcję  $r(x)$  nazywamy **funkcją regresji** lub **prawdopodobieństwem a posteriori**.

## Przypadek dwóch klas cd.

- Na mocy twierdzenia Bayesa możemy zapisać

$$\begin{aligned} r(x) &= P(G = 1|X = x) \\ &= \frac{P(G = 1, X = x)}{P(X = x)} \\ &= \frac{f(x|G = 1)P(G = 1)}{f(x|G = 1)P(G = 1) + f(x|G = 0)P(G = 0)} \\ &= \frac{\pi_1 f_1(x)}{\pi_1 f_1(x) + \pi_0 f_0(x)}, \end{aligned}$$

gdzie

- $f_1(x) = f(x|G = 1)$ ,  $f_0(x) = f(x|G = 0)$  – rozkłady warunkowe w grupach (klasach),
- $\pi_0 = P(G = 0)$ ,  $\pi_1 = P(G = 1)$  – prawdopodobieństwa a priori dwóch klas (oczywiście  $\pi_0 + \pi_1 = 1$ ).

## Przypadek dwóch klas cd.

### Definicja (Klasyfikator bayesowski)

*Klasyfikatorem bayesowskim będziemy nazywali klasyfikator postaci*

$$d_B(x) = \begin{cases} 1, & \text{jeżeli } P(G = 1|X = x) > \frac{1}{2} \\ 0, & \text{w przeciwnym przypadku} \end{cases}$$

### Uwaga

*W równoważnej postaci:*

$$d_B(x) = \begin{cases} 1, & \text{jeżeli } P(G = 1|X = x) > P(G = 0|X = x) \\ 0, & \text{w przeciwnym przypadku} \end{cases}$$

*lub*

$$d_B(x) = \begin{cases} 1, & \text{jeżeli } \pi_1 f_1(x) > \pi_0 f_0(x) \\ 0, & \text{w przeciwnym przypadku} \end{cases}$$

## Przypadek dwóch klas cd.

### Definicja (Granica decyzyjna)

#### Zbiór postaci

$$\{x : P(G = 1|X = x) = P(G = 0|X = x)\}$$

nazywamy granicą decyzyjną lub powierzchnią rozdzielającą klasy (ang. decision boundary, decision surface).

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 2

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 2

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 2




FIGURE 2.1. A classification example in two dimensions. The classes are coded as a binary variable (BLUE = 0, ORANGE = 1), and then fit by linear regression. The line is the decision boundary defined by  $x^T \hat{\beta} = 0.5$ . The orange shaded region denotes that part of input space classified as ORANGE, while the blue region is classified as BLUE.




FIGURE 2.2. The same classification example in two dimensions as in Figure 2.1. The classes are coded as a binary variable (BLUE = 0, ORANGE = 1) and then fit by 15-nearest-neighbor averaging as in (2.8). The predicted class is hence chosen by majority vote amongst the 15-nearest neighbors.




FIGURE 2.3. The same classification example in two dimensions as in Figure 2.1. The classes are coded as a binary variable (BLUE = 0, ORANGE = 1), and then predicted by 1-nearest-neighbor classification.

## Przypadek dwóch klas cd.

### Twierdzenie (Optymalność klasyfikatora bayesowskiego)

- Klasyfikator bayesowski jest klasyfikatorem optymalnym.
- Jeżeli  $d(\cdot)$  jest jakimkolwiek innym klasyfikatorem, wówczas rzeczywisty poziom błędu klasyfikatora  $d$  jest większy od rzeczywistego poziomu błędu klasyfikatora bayesowskiego, tzn.  $e(d_B) \leq e(d)$ .

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 2




FIGURE 2.5. The optimal Bayes decision boundary for the simulation example of Figures 2.1, 2.2 and 2.3. Since the generating density is known for each class, this boundary can be calculated exactly (Exercise 2.2).

## Przypadek dwóch klas cd.

Konstrukcja klasyfikatora na bazie próby uczącej

- **Problem:** Klasyfikator bayesowski  $d_B$  możemy wyznaczyć tylko wówczas, gdy znamy rozkłady warunkowe  $f_1(x) = f(x|G = 1)$  i  $f_0(x) = f(x|G = 0)$  oraz prawdopodobieństwa a priori  $\pi_0 = P(G = 0)$  i  $\pi_1 = P(G = 1)$ .
- Najczęściej rozkłady te nie są znane i stąd klasyfikator  $d_B$  nie jest znany.
- Możemy jednak skonstruować odpowiednie oszacowanie klasyfikatora bayesowskiego, wykorzystując próbę uczącą (ang. learning set)  $\mathcal{L}_n = \{(x_1, g_1), \dots, (x_n, g_n)\}$ , tzn. konstruujemy

$$\hat{d}(x) = \hat{d}(x; \mathcal{L}_n).$$

## Przypadek dwóch klas cd.

Konstrukcja klasyfikatora na bazie próby uczącej

- Jakość klasyfikatora skonstruowanego w oparciu o próbę uczącą  $\mathcal{L}_n$  mierzymy wyznaczając tzw. **aktualny poziom błędu** (ang. *actual error rate*)

$$e(\hat{d}) = P(\hat{d}(X) \neq G | \mathcal{L}_n),$$

gdzie para losowa  $(X, G)$  jest niezależna od próby uczącej  $\mathcal{L}_n$ .

- Chcemy znaleźć klasyfikator  $\hat{d}$ , dla którego  $e(\hat{d})$  jest bliskie  $e(d_B)$ .
- Formalnie, możemy mówić o zgodności klasyfikatora  $\hat{d}$ , tzn.:
  - zgodność:  $\lim_{n \rightarrow \infty} P(|e(\hat{d}) - e(d_B)| \geq \varepsilon) = 0$ ,
  - mocna zgodność:  $P(\lim_{n \rightarrow \infty} e(\hat{d}) = e(d_B)) = 1$ .
- W praktyce stosowane są różne metody szacowania aktualnego poziomu błędu, np. cross-validation, bootstrap itp.

## Przypadek dwóch klas cd.

Konstrukcja klasyfikatora na bazie próby uczącej

### Różne podejścia

- 1 Znajdujemy ocenę  $\hat{r}(x) = \hat{P}(G = 1|X = x)$  i definiujemy klasyfikator

$$\hat{d}(x) = \begin{cases} 1, & \text{jeżeli } \hat{P}(G = 1|X = x) > \frac{1}{2}, \\ 0, & \text{w przeciwnym przypadku} \end{cases}$$

- 2 Estymujemy  $f_1(x) = f(x|G = 1)$  na podstawie obserwacji ze zbioru uczącego, które należą do klasy 1 oraz estymujemy  $f_0(x) = f(x|G = 0)$  na podstawie obserwacji z klasy 0. Dodatkowo, estymujemy prawdopodobieństwa a priori jako  $\hat{\pi}_1 = \frac{n_1}{n}$  i  $\hat{\pi}_0 = \frac{n_0}{n} = 1 - \hat{\pi}_1$ , gdzie  $n_0$  i  $n_1$  to odpowiednie liczebności obiektów z poszczególnych klas. Wówczas

$$\hat{P}(G = 1|X = x) = \frac{\hat{\pi}_1 \hat{f}_1(x)}{\hat{\pi}_1 \hat{f}_1(x) + (1 - \hat{\pi}_1) \hat{f}_0(x)}$$

## Przypadek dwóch klas cd.

Konstrukcja klasyfikatora na bazie próby uczącej

- Różne metody klasyfikacji w różny sposób estymują prawdopodobieństwa a posteriori lub gęstości warunkowe w grupach (klasach).
- Przykłady
  - **Podejście parametryczne:** zakładamy, że obserwacje pochodzą z określonego rozkładu (wielowymiarowego) o nieznanymi parametrach. Dla przykładu, założenie o wielowymiarowej normalności rozkładu prowadzi do liniowych bądź kwadratowych granic decyzyjnych (liniowa i kwadratowa analiza dyskryminacyjna, LDA i QDA).
  - **Podejście nieparametryczne:** alternatywnie możemy estymować gęstości w poszczególnych klasach nie zakładając żadnego konkretnego modelu parametrycznego, np. wykorzystując jądrowy estymator gęstości Rosenblatt-Parzena.

## Przypadek wieloklasowy ( $K > 2$ )

- Wcześniejsze rozważania możemy łatwo uogólnić na przypadek większej liczby klas ( $K > 2$ ).

### Definicja (Klasyfikator bayesowski - przypadek wieloklasowy)

- Założmy, że  $G \in \mathcal{G} = \{1, \dots, K\}$ . Klasyfikatorem bayesowskim nazywamy klasyfikator postaci

$$d_B(x) = \arg \max_k P(G = k | X = x), \text{ gdzie } k \in \{1, \dots, K\}.$$

- Zauważmy, że

$$P(G = k | X = x) = \frac{\pi_k f_k(x)}{\sum_{i=1}^K \pi_i f_i(x)}.$$

- Możemy więc zapisać w postaci równoważnej:

$$d_B(x) = \arg \max_k \pi_k f_k(x)$$

## Przypadek $K$ klas ( $K > 2$ ) cd.

### Twierdzenie (Optymalność klasyfikatora bayesowskiego)

- Klasyfikator bayesowski  $d_B$  jest optymalny, tzn. jeżeli  $d(\cdot)$  jest innym klasyfikatorem, wówczas

$$e(d_B) \leq e(d),$$

gdzie  $e(d)$  jest rzeczywistym poziomem błędu klasyfikatora  $d$ .

- Ponadto

$$e(d_B) = 1 - \int_{\mathbb{R}^p} \max_{1 \leq k \leq K} [f_k(x) \cdot \pi_k] dx.$$

**Uwaga:** rzeczywisty poziom błędu klasyfikatora bayesowskiego  $d_B$  nazywamy **błędem bayesowskim**.

## Przypadek $K$ klas ( $K > 2$ ) cd.

Dowód.

- Niech  $R_k = \{x : d(x) = k\}$ , dla  $k = 1, 2, \dots, K$ .
- Możemy zapisać

$$\begin{aligned} 1 - e(d) &= P(d(X) = G) \\ &= \sum_{k=1}^K P(d(X) = k | G = k) \cdot \pi_k \\ &= \sum_{k=1}^K P(X \in R_k | G = k) \cdot \pi_k \\ &= \sum_{k=1}^K \int_{R_k} f_k(x) \cdot \pi_k dx \\ &= \int_{\mathbb{R}^p} \left[ \sum_{k=1}^K 1(d(x) = k) \cdot f_k(x) \cdot \pi_k \right] dx \end{aligned}$$

- Dla ustalonego  $x$  mamy:  $\sum_{k=1}^K 1(d(x) = k) \cdot f_k(x) \cdot \pi_k \leq \max_k [f_k(x) \cdot \pi_k]$ .
- Stąd  $P(d(X) = G) \leq P(d_B(X) = G) = \int_{\mathbb{R}^p} \max_{1 \leq k \leq K} [f_k(x) \cdot \pi_k] dx$ .

□

## Naiwny klasyfikator bayesowski

- Przypomnienie: optymalny klasyfikator bayesowski ma postać

$$d_B(x) = \arg \max_k [f_k(x) \cdot \pi_k], \text{ gdzie } k \in \{1, \dots, K\}.$$

- Szacując  $\pi_k$  i  $f_k$ , możemy estymować klasyfikator bayesowski.
- Bezpośrednia estymacja gęstości  $f_k$  w przypadku dużego wymiaru (duże  $p$ ) może jednak nie być łatwa, szczególnie w przypadku podejścia nieparametrycznego ( $\Rightarrow$  przekleństwo wielowymiarowości).
- W szczególności, w praktyce nie stosuje się wielowymiarowych estymatorów jądrowych gęstości dla  $p > 5$ .
- Problem estymacji  $f_k$  znacznie się upraszcza jeżeli założymy, że wszystkie zmienne są niezależne.



## Naiwny klasyfikator bayesowski

- Niech  $X = (X_1, X_2, \dots, X_p)'$  i założmy, że wszystkie składowe wektora  $X$  są niezależne.

- Wówczas

$$f_k(x_1, x_2, \dots, x_p) = \prod_{j=1}^p f_{k,j}(x_j),$$

gdzie  $f_{k,j}$  oznacza (jednowymiarową) gęstość rozkładu  $j$ -tej zmiennej dla  $k$ -tej klasy.

- Problem estymacji sprowadzamy w ten sposób do estymacji  $p$  jednowymiarowych funkcji gęstości w każdej z  $K$  klas.
- Uzyskany w ten sposób klasyfikator nazywamy **naiwnym klasyfikatorem bayesowskim** (ang. naïve Bayes classifier).

## Naiwny klasyfikator bayesowski

Algorytm (Konstrukcja naiwnego klasyfikatora bayesowskiego)

- 1 Dla każdej klasy  $k$  (gdzie  $k \in \{1, \dots, K\}$ ) wyznaczamy estymator  $\hat{f}_{k,j}$  gęstości  $f_{k,j}$  zmiennej losowej  $X_j$ , wykorzystując tylko te elementy próby uczącej, które należą do  $k$ -tej klasy (grupy).
- 2 Określamy estymator gęstości wielowymiarowej dla  $k$ -tej klasy

$$\hat{f}_k(x) = \hat{f}_k(x_1, x_2, \dots, x_p) = \prod_{j=1}^p \hat{f}_{k,j}(x_j).$$

- 3 Określamy estymator prawdopodobieństwa a priori:  $\hat{\pi}_k = \frac{n_k}{n}$ , gdzie  $n_k$  oznacza liczbę elementów zbioru uczącego należących do  $k$ -tej klasy.
- 4 Wyznaczamy naiwny klasyfikator bayesowski

$$\hat{d}_{NB}(x) = \arg \max_k [\hat{f}_k(x) \cdot \hat{\pi}_k].$$

## Naiwny klasyfikator bayesowski

### Pozostałe uwagi

- **Problem:** Założenie o niezależności poszczególnych zmiennych zazwyczaj nie jest spełnione.
- Pomimo tego naiwny klasyfikator bayesowski daje często zadowalające wyniki i jest popularną metodą wśród praktyków.
- Jest on szczególnie popularny w sytuacji, kiedy  $X$  jest wektorem dyskretnym o dużej liczbie składowych (cech).
- Wówczas zamiast gęstości warunkowych  $f_k(x) = f(x|G = k)$  mamy warunkowe prawdopodobieństwa  $p_k(x) = P(x|G = k)$ , tzn.

$$\begin{aligned}\hat{d}_{NB}(x) &= \arg \max_k [P(X = x|G = k) \cdot \hat{\pi}_k] = \\ &= \arg \max_k \left[ \prod_{j=1}^p P(X_j = x_j|G = k) \cdot \hat{\pi}_k \right].\end{aligned}$$

## Naiwny klasyfikator bayesowski

### Przykład (zadanie na laboratorium)

- Rozważamy następujące dane uczące (dwie klasy: '+' i '-'; trzy zmienne binarne:  $X_1, X_2, X_3$ ):

| ID | $X_1$ | $X_2$ | $X_3$ | klasa |
|----|-------|-------|-------|-------|
| 1  | 1     | 0     | 1     | +     |
| 2  | 0     | 0     | 0     | +     |
| 3  | 0     | 0     | 1     | -     |
| 4  | 0     | 1     | 1     | -     |
| 5  | 0     | 0     | 1     | +     |
| 6  | 1     | 0     | 1     | -     |
| 7  | 1     | 1     | 1     | +     |
| 8  | 1     | 0     | 1     | +     |
| 9  | 1     | 0     | 1     | -     |
| 10 | 0     | 1     | 1     | -     |

- Wykorzystując naiwny klasyfikator bayesowski wyznacz prognozowaną etykietkę klasy dla przypadku  $x_0 = (0, 1, 0)$ .

# Dziękuję za uwagę!