

Drzewa klasyfikacyjne (drzewa decyzyjne)

Adam Zagdański

Wydział Matematyki PWr

Wrocław
29 IV 2026

Wprowadzenie
Konstrukcja drzewa
Reguły przycinania drzew
Drzewa klasyfikacyjne w R
Wady i zalety

Plan prezentacji

- 1 Wprowadzenie
- 2 Konstrukcja drzewa
- 3 Reguły przycinania drzew
- 4 Drzewa klasyfikacyjne w R
- 5 Wady i zalety

Drzewa klasyfikacyjne (decyzyjne) – historia metody

- Morgan i Sonquist (1963) – badania socjologiczne, algorytm AID (Automatic Interaction Detection).
- Quinlan (lata 70-te) – uczenie maszynowe, algorytmy ID3 i C4.5.
- Breiman (1984) – statystyka, algorytm CART (Classification And Regression Trees).
- Inne algorytmy: CHAID, C5.0, QUEST, CRUISE, ...

Niezbędna terminologia

- Drzewa – nieskierowane grafy acykliczne¹ i spójne.²
- Drzewa klasyfikacyjne – drzewa skierowane, mające wyróżniony wierzchołek początkowy, tzw. korzeń (ang. root).
- Węzły – wierzchołki.
- Gałęzie – krawędzie.
- Relacja węzłów: rodzice, dzieci, potomkowie.
- Węzły końcowe (liście): do każdego liścia prowadzi tylko jedna droga od korzenia.
- Podzbiory: poddrzewo, poddrzewo zakorzenione.

¹Graf acykliczny – nie istnieje ciąg krawędzi łączący wierzchołek z nim samym

²Graf spójny – każda para wierzchołków jest połączona ciągiem krawędzi

Niezbędna terminologia


Drzewa binarne

Będziemy ograniczali się do drzew binarnych, tzn. takich, dla których z każdego węzła poza liśćmi wychodzą dwie krawędzie.

Niezbędna terminologia

Przykład: drzewo binarne dla klasyfikacji spam/e-mail.

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 9





Idea konstrukcji drzewa

- 1 Rekurencyjny podział danych ze względu na wybraną zmienną.
- 2 W każdym kroku wybierany jest podział dający najsilniej rozseparowane podzbiory.

Wniosek: drzewa klasyfikacyjne dzielą przestrzeń $\mathcal{X}$ na hiperprostokąty, z krawędziami równoległymi do osi.

Idea konstrukcji drzewa

Przykład: drzewo dla zagadnienia klasyfikacji irysów.



Warunki podziału w węzłach

- Dla zmiennych ilościowych i porządkowych: $\{X_i < a\}$ lub $\{X_i \geq b\}$ (gdzie: X_i – wybrana zmienna, a, b – wartości progowe).
- Dla zmiennych jakościowych: $\{X_i = 'a'\}$ lub $\{X_i \in \{'a', 'b', 'c'\}\}$.

Uwaga

Drzewa dobrze radzą sobie z różnymi typami zmiennych (ilościowymi i jakościowymi).

Budowanie/uczenie drzewa

- Drzewo klasyfikacyjne budowane jest na podstawie próby uczącej.
- W korzeniu skupiona jest cała próba ucząca.
- Kolejne elementy próby przesuwają się wzdłuż gałęzi (kierunek: z góry na dół): jeżeli warunek w węźle jest spełniony idziemy w lewo, jeżeli nie – w prawo.
- Elementom w liściach (węzłach końcowych) nadaje się etykietkę tej klasy, z której pochodzi najwięcej elementów próby uczącej, które dotarły do danego liścia.

Reguła decyzyjna (klasyfikator) skonstruowana na podstawie drzewa

- 1 Przepuszczamy nowy obiekt x przez drzewo.
- 2 Znajdujemy liść, do którego trafił ten obiekt.
- 3 Przyporządkowujemy x do klasy, do której należy większość elementów w tym liściu.

Konstrukcja drzewa klasyfikacyjnego w praktyce

- 1 Wybór metody podziału węzłów.
- 2 Ustalenie kryterium zatrzymania podziału.
- 3 Analiza struktury skonstruowanego drzewa pod kątem określonych zastosowań (np. przycinanie drzewa, ang. pruning).

Reguły podziału

- Jakość drzewa zależy od warunków, których użyjemy do podziału danych w każdym węźle.
- Celem jest uzyskanie możliwie jednorodnych liści (czyli zawierających większość obserwacji z tej samej klasy).
- W tym celu potrzebujemy:
 - ① miary różnorodności klas w węźle (ang. impurity measure),
 - ② miary różnicy między różnorodnością klas w danym węźle i różnorodnością klas w węzłach dzieciach.

Reguły podziału

Oznaczenia

- T – drzewo klasyfikacyjne.
- $\{(x_i, y_i)\}_{i=1, \dots, n}$ – próba ucząca.
- G – liczba klas / grup.
- $R_m \subseteq \mathcal{X}$ – prostokąt definiujący węzeł m .
- $\hat{p}_{m,k} = \frac{1}{n_m} \sum_{x_i \in R_m} 1_{\{y_i=k\}} = \frac{n_{m,k}}{n_m}$, gdzie $k = 1, \dots, G$.
- Reguła klasyfikacyjna:

$$k(m) = \arg \max_k \hat{p}_{m,k},$$

gdzie $k(m)$ – klasa przypisana do węzła m .

- Jeżeli węzeł m jest liściem – mamy ostateczny wynik. W przeciwnym przypadku, wykorzystujemy $\hat{p}_{m,k}$ do oceny czystości węzłów.

Miara różnorodności klas (ang. impurity measure)

Idea: „sensowna” miara różnorodności klas w danym węźle powinna przyjmować:

- a) wartość 0, gdy wszystkie obserwacje w węźle należą do tej samej klasy,
- b) wartość maksymalną, gdy rozkład przynależności jest jednostajny ($p_{m,1} = p_{m,2} = \dots = p_{m,G} = \frac{1}{G}$).

Miara różnorodności klas (ang. impurity measure)

Najczęściej stosowane miary:

❶ **błąd klasyfikacji:**

$$Q_m(T) = \frac{1}{n_m} \sum_{i \in R_m} 1_{\{y_i \neq k(m)\}} = 1 - \hat{p}_{m,k(m)},$$

❷ **indeks Giniego:**

$$Q_m(T) = \sum_{k \neq k'} \hat{p}_{m,k} \hat{p}_{m,k'} = \sum_{k=1}^G \hat{p}_{m,k} (1 - \hat{p}_{m,k}) = 1 - \sum_{k=1}^G \hat{p}_{m,k}^2,$$

❸ **entropia:**

$$Q_m(T) = - \sum_{k=1}^G \hat{p}_{m,k} \log \hat{p}_{m,k}.$$

Miara różnorodności klas (ang. impurity measure)

Szczególny przypadek: klasyfikacja binarna ($G = 2$)

$$Q_m(T) = \begin{cases} 1 - \max(p, 1 - p) & \text{(błąd klasyfikacji)} \\ 2p(1 - p) & \text{(indeks Giniego)} \\ -p \log p - (1 - p) \log(1 - p) & \text{(entropia)}. \end{cases}$$

(p - prawdopodobieństwo przynależności do jednej z klas).





FIGURE 9.3. Node impurity measures for two-class classification, as a function of the proportion p in class 2. Cross-entropy has been scaled to pass through $(0.5, 0.5)$.

Miara różnorodności klas (ang. impurity measure)

Łączna miara różnorodności klas w dzieciach węzła m



Określamy:

- $\hat{p}_L = \frac{n_{m_L}}{n_m}$ (prawdopodobieństwo przejścia z m do m_L),
- $\hat{p}_R = \frac{n_{m_R}}{n_m} = 1 - \hat{p}_L$ (prawdopodobieństwo przejścia z m do m_R).

Miara różnorodności klas (ang. impurity measure)

Łączna miara różnorodności klas w dzieciach węzła m

- Wyznaczamy uśrednioną (ważoną) wartość różnorodności klas w dzieciach węzła m

$$Q_{m_L, m_R}(T) = \hat{p}_L \cdot Q_{m_L}(T) + \hat{p}_R \cdot Q_{m_R}(T).$$

- Miara różnicy różnorodności klas w węźle rodzicu (m) i węzłach dzieciach (m_L i m_R):

$$\Delta Q_{m, m_L, m_R} = Q_m(T) - Q_{m_L, m_R}(T).$$

- Idea:** W danym węźle wybieramy taką zmienną (cechę) i taką wartość progową, które maksymalizuje $\Delta Q_{m, m_L, m_R}$ (maksymalizujemy po wszystkich możliwych podziałach).

Miara różnorodności klas (ang. impurity measure)

Uwaga: wybór miary różnorodności

- W zastosowaniach preferowaną miarą różnorodności klas jest zazwyczaj indeks Giniego lub entropia niż błąd klasyfikacji.
- Obie te miary są bardziej czułe na zmianę rozkładów klas (tzn. proporcji błędnych klasyfikacji).

Miara różnorodności klas (ang. impurity measure)

Przykład (zadanie na laboratorium)

- Rozważamy zagadnienie klasyfikacji binarnej (klasy: A i B).
- Załóżmy, że węzeł m zawiera: 400 elementów z klasy A oraz 400 elementów z klasy B .
- Rozważamy dwa podziały węzła m
 - ① **podział I**
 - m_L : 300 obiektów z A / 100 obiektów z B ,
 - m_R : 100 obiektów z A / 300 obiektów z B ,
 - ② **podział II**
 - m_L : 200 obiektów z A / 400 obiektów z B ,
 - m_R : 200 obiektów z A / 0 obiektów z B ,
- Który podział (I czy II) będzie preferowany jeżeli jako miarę różnorodności klas wykorzystamy: a) błąd klasyfikacji, b) indeks Giniego, c) entropię?

Miara różnorodności klas (ang. impurity measure)

Metody maksymalizacji różnicy różnorodności klas

- **Problem:** Jak znaleźć optymalną regułę podziału węzła?
- Załóżmy, że zmienna przyjmuje L różnych wartości w całej próbie uczącej.
- Mamy $\frac{1}{2}2^L - 1 = 2^{L-1} - 1$ możliwych podziałów zbioru wartości na dwa rozłączne podzbiory.
- Sprawdzenie (dla dużego L) wszystkich możliwych podziałów może być bardzo kosztowne obliczeniowo!
- Dla atrybutów ilościowych (ciągłych lub dyskretnych) lub atrybutów porządkowych wystarczy ograniczyć się do podziałów monotonicznych: $X_i \leq c$ lub $X_i > c$. Mamy wówczas: $L - 1$ możliwych podziałów.
- Co zrobić, gdy mamy atrybut nominalny?

Miara różnorodności klas (ang. impurity measure)

Metody maksymalizacji różnicy różnorodności klas

Problem: Wyznaczenie optymalnego podziału węzła dla atrybutu nominalnego.

Twierdzenie (Breiman et al., 1984)

Niech miarą różnorodności klas $Q(\cdot)$ będzie entropia lub indeks Giniego.

- W przypadku klasyfikacji binarnej ($G = 2$), możemy uporządkować wartości atrybutu, tzn.:

$$p(1|x^{(1)}) \leq p(1|x^{(2)}) \leq \dots \leq p(1|x^{(L)}).$$

- Wówczas, jeden z $L - 1$ podziałów typu $\{x^{(1)}, \dots, x^{(l)}\}$, $\{x^{(l+1)}, \dots, x^{(L)}\}$ maksymalizuje $\Delta Q_{m, m_L, m_R}$.

Uwaga: Dla $G > 2$ niestety nie mamy podobnego rezultatu.

Wyznaczenie optymalnego podziału węzłów

Problem: duża złożoność obliczeniowa dla zmiennych nominalnych o dużej liczbie wartości

- Przykład:** Porównanie złożoności obliczeniowej różnych algorytmów konstrukcji drzewa klasyfikacyjnego.
- Dane:** Cars93, porównanie przypadku z i bez zmiennej *manuf* Manufacturer (31 kategorii).

TABLE 3 | Tree Construction Times on a 2.66 Ghz Intel Core 2 Quad Extreme Processor for the Car Data.

	C4.5	CRUISE	GUIDE	QUEST	RPART
Without <i>manuf</i>	0.004s	3.57s	2.49s	2.26s	0.09s
With <i>manuf</i>	0.003s	4.00s	1.86s	2.54s	3h 2m

(źródło: Wei-Yin Loh, Classification and regression trees, 2011.)

Reguły zatrzymania podziału węzłów

- Ograniczenie na minimalną liczbę obiektów w liściu (węźle końcowym),
- Ograniczenie na minimalną liczbę obiektów w węźle dzielącym,
- Czystość węzłów końcowych (tylko obiekty jednej klasy) lub odpowiednie ograniczenie dla miary różnorodności klas,
- Ograniczenie dotyczące maksymalnej wysokości drzewa (tzn. maksymalnej długości drogi od korzenia do liścia).
- **Alternatywne podejście:** Przycinanie drzewa (ang. pruning) po jego utworzeniu zamiast ograniczania jego wzrostu
- **Uwaga:** W praktyce może być stosowana tylko jedna reguła lub ich kombinacja.

Algorytmy konstrukcji drzew klasyfikacyjnych

TABLE 1 | Comparison of Classification Tree Methods. A Check Mark Indicates Presence of a Feature


Feature	C4.5	CART	CHAID	CRUISE	GUIDE	QUEST
Unbiased Splits				✓	✓	✓
Split Type	<i>u</i>	<i>u, l</i>	<i>u</i>	<i>u, l</i>	<i>u, l</i>	<i>u, l</i>
Branches/Split	≥ 2	2	≥ 2	≥ 2	2	2
Interaction Tests				✓	✓	
Pruning	✓	✓		✓	✓	✓
User-specified Costs		✓	✓	✓	✓	✓
User-specified Priors		✓		✓	✓	✓
Variable Ranking		✓		✓	✓	✓
Node Models	<i>c</i>	<i>c</i>	<i>c</i>	<i>c, d</i>	<i>c, k, n</i>	<i>c</i>
Bagging & Ensembles					✓	
Missing Values	<i>w</i>	<i>s</i>	<i>b</i>	<i>i, s</i>	<i>m</i>	<i>i</i>

b, missing value branch; *c*, constant model; *d*, discriminant model; *i*, missing value imputation; *k*, kernel density model; *l*, linear splits; *m*, missing value category; *n*, nearest neighbor model; *u*, univariate splits; *s*, surrogate splits; *w*, probability weights

(źródło: Wei-Yin Loh, Classification and regression trees, 2011.)

Problem: podatność drzew klasyfikacyjnych na przeuczenie

- Drzewa klasyfikacyjne, z uwagi na dużą elastyczność w modelowaniu granic decyzyjnych, charakteryzują się podatnością na przeuczenie (ang. overfitting).
- W szczególności budowę drzewa możemy kontynuować do momentu, gdy liście zawierają tylko elementy należące do jednej klasy.



Reguły przycinania drzew

Kilkuetapowa konstrukcja drzewa

- Aby uniknąć nadmiernego dopasowania drzewa do danych uczących często stosowanym pomysłem jest kilkuetapowa konstrukcja.
- W pierwszym kroku budowane jest „duże” drzewo (tzw. drzewo pełne, ozn. T_0), np. rozbudowywane do momentu spełnienia naturalnego warunku stopu.
- Następnie przeprowadza się systematyczne przycinanie drzewa tak, aby otrzymać najlepszą zdolność klasyfikacyjną dla danych testowych.

Reguły przycinania drzew

Algorytm oparty na kryterium kosztu złożoności (ang. Cost-Complexity Pruning)

- Oznaczenia:
 - T_0 – drzewo pełne,
 - $|T_0|$ – rozmiar drzewa (liczba liści),
 - T – poddrzewo zakorzenione drzewa pełnego T_0 ,
 - $R(T)$ – miara niedoskonałości drzewa (najczęściej stosujemy ułamek błędnych klasyfikacji).
- Kryterium kosztu-złożoności (kompromis między dokładnością klasyfikacji i złożonością)

$$R_{cp}(T) = R(T) + cp \cdot |T|,$$

gdzie cp jest współczynnikiem złożoności (ang. complexity parameter (cp)).

- **Cel:** Wybieramy poddrzewo T minimalizujące $R_{cp}(T)$.

Reguły przycinania drzew

Algorytm oparty na kryterium kosztu złożoności (ang. Cost-Complexity Pruning)


Wybór optymalnego drzewa:

- Aby znaleźć optymalną wartość parametru cp stosujemy zazwyczaj schemat k-fold cross-validation (unikamy w ten sposób obciążenia związanego z wykorzystaniem zbioru uczącego).
- Stosując kryterium kosztu-złożoności powinniśmy wybrać drzewo, które daje najmniejszy błąd klasyfikacji.
- W praktyce funkcja kryterialna często charakteryzuje się "płaskim" minimum i zalecane jest zastosowanie reguły 1SE.
- **Reguła 1SE (one standard error):** Jako optymalne drzewo, wybieramy drzewo o najmniejszej liczbie podziałów (najmniejszym rozmiarze), dla którego ułamek błędnych klasyfikacji jest odległy o nie więcej niż jedno odchylenie standardowe od minimum ułamka błędnych klasyfikacji.

Reguły przycinania drzew

Algorytm oparty na kryterium kosztu złożoności (ang. Cost-Complexity Pruning)

Przykład: Wybór optymalnego drzewa na bazie reguły 1SE.



Obsługa wartości brakujących

Podziały główne i podziały zastępcze

- Podczas budowy drzewa z wykorzystaniem próby uczącej, podział w danym węźle występuje jedynie na podstawie atrybutu nie zawierającego brakujących wartości.
- Są to tak zwane podziały właściwe lub podziały główne (ang. primary splits).
- Aby obsłużyć przypadek wartości brakujących dodatkowo możemy zdefiniować tzw. podziały zastępcze (ang. surrogate splits).
- Podziały zastępcze określają reguły (z innymi zmiennymi niż zmienna w podziale głównym) podziału w węźle, które są stosowane w przypadku, gdy obserwacja, dla której chcemy wyznaczyć prognozy ma brakującą wartość zmiennej występującej w głównej regule podziału węzła.

Drzewa klasyfikacyjne w R

Dostępne R-pakiety:

- `rpart`, `rpart.plot` – implementacja (zalecana) CART i dodatkowe narzędzia wizualizacji,
- `tree` – klasyczna implementacja algorytmu CART,
- `RWeka` – interfejs do implementacji algorytmów w WEKA (m.in. algorytm J4.8 - wariant C4.5 i algorytm M5).
- Inne pakiety: `C50`, `maptree`, `party`,
- Więcej szczegółów: CRAN Task View → Recursive Partitioning <https://cran.r-project.org/web/views/MachineLearning.html>.

Drzewa klasyfikacyjne w R

Przykład: Dane Cars93

Konstrukcja drzewa

```
> library(MASS)
> library(rpart)

> model <- Type ~ Weight + Length + Horsepower + Price + DriveTrain
> Cars93.tree.simple <- rpart(model, data=Cars93, cp=.05, minsplit=5)
> print(Cars93.tree.simple)
n= 93

node), split, n, loss, yval, (yprob)
* denotes terminal node

1) root 93 71 Midsize (0.17 0.12 0.24 0.23 0.15 0.097)
 2) Price>=12.35 69 47 Midsize (0.19 0.16 0.32 0.014 0.19 0.13)
   4) Length>=183.5 45 23 Midsize (0.11 0.22 0.49 0 0.044 0.13)
     8) Length>=199.5 13 3 Large (0 0.77 0.23 0 0 0) *
     9) Length<199.5 32 13 Midsize (0.16 0 0.59 0 0.062 0.19)
       18) Weight<3732.5 27 8 Midsize (0.19 0 0.7 0 0.074 0.037) *
       19) Weight>=3732.5 5 0 Van (0 0 0 0 0 1) *
   5) Length<183.5 24 13 Sporty (0.33 0.042 0 0.042 0.46 0.12) *
 3) Price<12.35 24 4 Small (0.12 0 0 0.83 0.042 0) *
```

Drzewa klasyfikacyjne w R

Przykład: Dane Cars93


Wizualizacja

```
# prosta wizualizacja  
> plot(Cars93.tree.simple)  
> text(Cars93.tree.simple)  
  
# zaawansowana wizualizacja  
> library(rpart.plot)  
> rpart.plot(Cars93.tree.simple)
```


Drzewa klasyfikacyjne w R

Przykład: Dane Cars93

Wizualizacja



a) prosta wizualizacja



b) zaawansowana wizualizacja

Drzewa klasyfikacyjne w R

Przykład: Dane Cars93

Prognozowanie

```
> pred.labels <- predict(Cars93.tree.simple, newdata = Cars93,
  type = "class")
> table(pred.labels, Cars93$Type)
```


pred.labels	Compact	Large	Midsize	Small	Sporty	Van
Compact	0	0	0	0	0	0
Large	0	10	3	0	0	0
Midsize	5	0	19	0	2	1
Small	3	0	0	20	1	0
Sporty	8	1	0	1	11	3
Van	0	0	0	0	0	5

Drzewa klasyfikacyjne w R

Przykład: Dane Cars93

Przycinanie drzewa

```
# Konstruujemy ''duże'' drzewo
> Cars93.tree.complex <- rpart(model, data=Cars93, cp=.01, minsplit=5, maxdepth=20)
> rpart.plot(Cars93.tree.complex)
```




Drzewa klasyfikacyjne w R

Przykład: Dane Cars93

Przycinanie drzewa: Wybór kandydatów

```
> plotcp(Cars93.tree.complex)
```



(C) 2026, A.Zagdański, Drzewa klasyfikacyjne (drzewa decyzyjne)

39/47

Drzewa klasyfikacyjne w R

Przykład: Dane Cars93

Przycinanie drzewa: Wybór kandydatów

```
> printcp(Cars93.tree.complex)
```

```
Classification tree: rpart(formula = model, data = Cars93, cp = 0.01, minsplit = 5, maxdepth = 20)
Variables actually used in tree construction: Horsepower Length Price Weight
```

```
Root node error: 71/93 = 0.76344
n= 93
```

	CP	nsplit	rel error	xerror	xstd
1	0.281690	0	1.00000	1.12676	0.047100
2	0.154930	1	0.71831	0.71831	0.067594
3	0.098592	2	0.56338	0.78873	0.066481
4	0.070423	3	0.46479	0.67606	0.067878
5	0.042254	4	0.39437	0.57746	0.067436
6	0.028169	6	0.30986	0.53521	0.066769
7	0.014085	12	0.14085	0.52113	0.066481
8	0.010000	13	0.12676	0.52113	0.066481

Wniosek: Najmniejsza wartość błędu krosvalidacyjnego (xerror) wynosząca 0.52113, z błędem standardowym

(xstd) równym 0.066481 jest przyjmowana dla $cp=0.014085$. Stosując regułę 1SE wybieramy drzewo o

najmniejszym rozmiarze, dla której $xerror < 0.52113 + 0.066481 = 0.587611$, czyli drzewo dla $cp=0.042254$

(C) 2026, A.Zagdański, Drzewa klasyfikacyjne (drzewa decyzyjne)

40/47

Drzewa klasyfikacyjne w R

Przykład: Dane Cars93


Przycinanie drzewa: zastosowanie kryterium kosztu-złożoności

```
> Cars93.tree.complex.pruned <-  
  prune(Cars93.tree.complex, cp = 0.042254)  
> rpart.plot(Cars93.tree.complex,  
             main="Oryginalne drzewo")  
> rpart.plot(Cars93.tree.complex.pruned,  
             main="Przyciete drzewo")
```

Drzewa klasyfikacyjne w R

Przykład: Dane Cars93

Przycinanie drzewa: zastosowanie kryterium kosztu-złożoności




Drzewa klasyfikacyjne w R

Interaktywne przycinanie drzewa

```
> Cars93.tree.complex.snipped <-  
  rpart.plot(Cars93.tree.complex, snip = TRUE)$obj  
> rpart.plot(Cars93.tree.complex.snipped)
```

Drzewa klasyfikacyjne w R

Interaktywne przycinanie drzewa



Najważniejsze zalety drzew klasyfikacyjnych

- Jedna z najprostszych interpretacyjnie technik eksploracji danych.
- Reguły są łatwiejsze w interpretacji niż funkcje.
- Atrakcyjność wizualna.
- Brak założeń dotyczących rozkładów.
- Obsługa różnych typów zmiennych (ilościowych i jakościowych).
- Obsługa wartości brakujących.
- Możliwość oceny ważności cech.

Najważniejsze wady drzew klasyfikacyjnych

- Drzewa decyzyjne często charakteryzują się mniejszą dokładnością predykcyjną w porównaniu do innych modeli.
- Podatność na przeuczenie.
- Niestabilność (niewielka zmiana danych uczących lub zmiana parametrów algorytmu może w istotny sposób wpływać na otrzymany rezultat).
- **Uwaga:** Aby poprawić własności klasyfikatorów skonstruowanych w oparciu o drzewa możemy zastosować jeden z algorytmów „wzmacniania”, np.: bagging, boosting lub random forest (szczegóły → kolejny wykład).

Dziękuję za uwagę!