

# Ocena dokładności klasyfikacji

Adam Zagdański

Wydział Matematyki PWr

Wrocław  
8 V 2026

Wprowadzenie  
Podstawowe schematy stosowane w ocenie dokładności  
Czułość i specyficzność  
Klasyfikator scoringowy – krzywa ROC i AUC

## Plan prezentacji

- 1 Wprowadzenie
  - Funkcja straty
  - Błąd na zbiorze uczącym i testowym
- 2 Podstawowe schematy stosowane w ocenie dokładności
  - K-fold cross-validation
  - Metoda bootstrap
- 3 Czułość i specyficzność
  - Różne koszty błędnej klasyfikacji
  - Macierz/tablica pomyłek (ang. confusion matrix)
  - Przykład
  - Inne kryteria
- 4 Klasyfikator scoringowy – krzywa ROC i AUC
  - Krzywa ROC
  - Area Under ROC Curve (AUC)

## Ocena dokładności predykcji – wprowadzenie

### Podstawowe cele

Ocena dokładności prognoz jest nieodzownym etapem budowy każdego modelu. Podstawowe cele stosowania oceny dokładności:

- 1 **Wybór modelu** – porównanie skuteczności różnych modeli (algorytmów) i wybór najlepszego z nich. W szczególności możemy wybrać optymalne parametry danego modelu/algorytmu lub najlepszą kombinację cech (zmiennych).
- 2 **Ocena zdolności uogólniających modelu** – oceniamy zdolność modelu/algorytmu do konstrukcji dokładnych prognoz dla niezależnych danych, tzn. zdolności do uogólniania wiedzy (ang. generalization properties).

## Ocena dokładności predykcji – wprowadzenie

### Funkcja straty

#### Oznaczenia:

- $\mathbf{X}$  – wektor zmiennych niezależnych (objaśniających).
- $Y$  – zmienna zależna (w szczególności, w przypadku klasyfikacji:  $Y \equiv G$ ),
- $\hat{f}(\mathbf{X})$  – model predykcyjny (w szczególności:  $\hat{f}(\mathbf{X}) = \hat{G}(\mathbf{X})$ ), dopasowany na bazie zbioru uczącego (ang. learning set)  
 $\mathcal{L} = \{(\mathbf{x}_i, y_i)\}_{i=1, \dots, n}$ .

#### Funkcja straty (ang. loss function)

- **regresja:**  $L(Y, \hat{f}(\mathbf{X})) = (Y - \hat{f}(\mathbf{X}))^2$  (kwadratowa funkcja straty),
- **klasyfikacja:**  $L(G, \hat{G}(\mathbf{X})) = \mathbb{1}_{\{G \neq \hat{G}(\mathbf{X})\}}$  (0-1 funkcja straty).

## Błąd na zbiorze uczącym

(ang. training error)

- Ogólnie:

$$\overline{err} = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{f}(\mathbf{x}_i))$$

- W przypadku modeli klasyfikacyjnych:

$$\overline{err} = \frac{1}{n} \sum_{i=1}^n \mathbb{1}_{\{y_i \neq \hat{G}(\mathbf{x}_i)\}}$$

## Błąd na zbiorze testowym

(ang. test error)

- Błąd testowy (dla ustalonego zbioru uczącego)

$$Err_{\mathcal{L}} = E[L(Y, \hat{f}(\mathbf{X})) | \mathcal{L}].$$

gdzie  $\mathbf{X}$ ,  $Y$  - wybrane losowo z rozkładu łącznego.

- Oczekiwany błąd predykcji (oczekiwany błąd testowy)


$$Err = E[L(Y, \hat{f}(\mathbf{X}))] = E[Err_{\mathcal{L}}].$$

- **Uwaga:** naszym celem jest estymacja  $Err_{\mathcal{L}}$ . Większość metod pozwala jednak jedynie na efektywną estymację oczekiwanego błędu testowego, tzn.  $Err$ .

## Przykład: błąd na zbiorze uczącym vs. błąd testowy

**Problem:** Błąd na zbiorze uczącym jest zbyt optymistycznym oszacowaniem błędu testowego.

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 7



**FIGURE 7.1.** Behavior of test sample and training sample error as the model complexity is varied. The light blue curves show the training error  $\overline{\text{Err}}$ , while the light red curves show the conditional test error  $\text{Err}_T$  for 100 training sets of size 50 each, as the model complexity is increased. The solid curves show the expected test error  $\text{Err}$  and the expected training error  $E[\overline{\text{Err}}]$ .

(C) 2026, A.Zagdański, Ocena dokładności klasyfikacji

7/38

## Zbiór uczący, walidacyjny i testowy

Przypadek „dużej” ilości danych

zbiór uczący

zbiór walidacyjny

zbiór testowy

- **Zbiór treningowy** – dopasowujemy (uczymy) modele/algorytmy,
- **Zbiór walidacyjny** – oceniamy błąd predykcji i wybieramy optymalny model,
- **Zbiór testowy** – badamy zdolności uogólniające wybranego modelu.

**Problem:** Często nie mamy wystarczającej ilości danych, aby zastosować powyższy schemat. Metody, które omówimy nie zakładają takiego podziału.

## Najpopularniejsze schematy oceny dokładności

- Losowy podział na zbiór uczący/testowy (ang. learning/test random split),
- K-fold Cross-Validation (CV) – k-krotny sprawdzian krzyżowy
  - k-fold cross-validation
  - leave-one-out
- Metoda bootstrap
  - leave-one-out bootstrap
  - estymator ".632"
  - estymator ".632+"

## Schemat K-fold Cross-Validation (CV)

Idea metody

**Przykład:** schemat metody 5-fold cross-validation.



- Dzielimy dostępne dane na  $K$  możliwie równolicznych podzbiorów.
- Wykonujemy  $K$  iteracji za każdym razem zmieniając podzbiór, który pełni rolę zbioru testowego (pozostałe  $K - 1$  podzbiory tworzą zbiór uczący).

## Schemat K-fold Cross-Validation (CV)

### Formalizm

#### Niezbędne oznaczenia

- Funkcja indeksująca  $\kappa : \{1, \dots, n\} \rightarrow \{1, \dots, K\}$
- $\hat{f}^{-i}(\mathbf{x})$  – model predykcyjny dopasowany po usunięciu  $i$ -tego podzbioru ( $i \in \{1, \dots, K\}$ ).

Estymator błędu predykcji wyznaczony na bazie Cross-Validation

$$CV(\hat{f}) = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{f}^{-\kappa(i)}(\mathbf{x}_i)).$$

- W praktyce stosujemy najczęściej:  $K = 5, 10$  lub  $n$ .
- Gdy  $K = n$  mówimy o schemacie leave-one-out ( $\kappa(i) = i$ ).

## Schemat K-fold Cross-Validation (CV)

### Zastosowania

- Schemat CV możemy wykorzystać do wybrania optymalnej wartości parametru(ów) danej metody

$$CV(\hat{f}, \theta) = \frac{1}{n} \sum_{i=1}^n L(y_i, \hat{f}^{-\kappa(i)}(\mathbf{x}_i, \theta)).$$

- W analogiczny sposób możemy wybrać optymalny podzbiór cech.

## Schemat K-fold Cross-Validation (CV)


### Podstawowe własności

- Schemat cross-validation estymuje efektywnie oczekiwany błąd predykcji (oczekiwany błąd testowy), tzn.  $Err$ .
- **Przypadek  $K=n$  (leave-one-out):** estymator jest w przybliżeniu nieobciążony, ale może mieć dużą wariancję. Dodatkowym problemem może być duża złożoność obliczeniowa.
- **Przypadek  $K=5$  lub  $10$ :** mała wariancja, ale możemy mieć większe obciążenie (przeszacowanie błędu predykcji).
- W praktyce warianty 5-fold CV lub 10-fold CV są zalecane jako rozsądny kompromis między obciążeniem i wariancją.

## Metoda bootstrap

### Idea metody bootstrap

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 7



**FIGURE 7.12.** Schematic of the bootstrap process. We wish to assess the statistical accuracy of a quantity  $S(\mathbf{Z})$  computed from our dataset.  $B$  training sets  $\mathbf{Z}^{*b}$ ,  $b = 1, \dots, B$  each of size  $N$  are drawn with replacement from the original dataset. The quantity of interest  $S(\mathbf{Z})$  is computed from each bootstrap training set, and the values  $S(\mathbf{Z}^{*1}), \dots, S(\mathbf{Z}^{*B})$  are used to assess the statistical accuracy of  $S(\mathbf{Z})$ .

## Metoda bootstrap

### Podstawowe zastosowania i warianty metody

- Bootstrap jest uniwersalnym narzędziem wykorzystywanym jako alternatywa dla klasycznych metod wnioskowania statystycznego.
- Typowe zastosowania:
  - estymacja obciążenia, wariancji, błędu predykcji,
  - konstrukcja przedziałów/obszarów ufności i przedziałów/obszarów predykcji,
  - testowanie hipotez statystycznych.

## Metoda bootstrap

### Oznaczenia

- $\mathbf{x}^{*b} = (x_1^{*b}, \dots, x_n^{*b})$   $b$ -ta replikacja próby uczącej,  $b = 1, \dots, B$  (gdzie  $B$  – liczba replikacji).
- $\hat{f}^{*b}(\cdot)$  – model dopasowany na bazie  $b$ -tej replikacji.

### Bootstrapowy estymator błędu predykcji

$$\widehat{Err}_{boot} = \frac{1}{B} \frac{1}{n} \sum_{b=1}^B \sum_{i=1}^n L(y_i, \hat{f}^{*b}(\mathbf{x}_i)).$$



## Metoda bootstrap

### Własności

- Wyznaczając  $\widehat{Err}_{boot}$  bazujemy na replikacjach wyjściowej próby (losowanych ze zwracaniem z jednakowym p-stwem  $\frac{1}{n}$ ).
- W niektórych replikacjach mogą (z dużym p-stwem) wystąpić te same obserwacje, które wykorzystujemy do oceny dokładności.

$$P(\text{i-ta obserwacja znajdzie się w b-tej replikacji}) = \\ = 1 - \left(1 - \frac{1}{n}\right)^n \approx 1 - e^{-1} \approx 0.632.$$

- Aby uwzględnić powtarzające się obserwacje możemy odpowiednio zmodyfikować definicję wyjściowego estymatora.
- Otrzymujemy w ten sposób tzw. estymator **leave-one-out bootstrap**.

## Metoda bootstrap

### Estymator leave-one-out bootstrap

#### Estymator leave-one-out bootstrap

$$\widehat{Err}^{(1)} = \frac{1}{n} \sum_{i=1}^n \frac{1}{|C^{-i}|} \sum_{b \in C^{-i}} L(y_i, \hat{f}^{*b}(\mathbf{x}_i)),$$

gdzie  $C^{-i}$  – zbiór replikacji bootstrapowych, które nie zawierają  $\mathbf{x}_i$ .

- Wadą estymatora  $\widehat{Err}^{(1)}$  może być obciążenie związane z rozmiarem zbioru uczącego.
- W każdej replikacji, średnia liczba różnych przypadków jest rzędu  $0,632 \cdot n$ , czyli otrzymujemy obciążenie podobnego rzędu jak w przypadku metody 2-fold cross-validation.
- Modyfikacje: **estymator '.632'** oraz **estymator '.632+'**.

## Metoda bootstrap

Estymatory '.632' i '.632+'

Estymator '.632'

$$\widehat{Err}^{(.632)} = .368 \cdot \overline{err} + .632 \cdot \widehat{Err}^{(1)}, \text{ gdzie}$$

- $\overline{err}$  – błąd na zbiorze uczącym (training error),
- $\widehat{Err}^{(1)}$  – błąd leave-one-out bootstrap.

- Estymator '.632' został opracowany aby zmniejszyć obciążenie estymatora leave-one-out bootstrap ( $\widehat{Err}^{(1)}$ ).
- Problem: estymator '.632' może być niedokładny, gdy mamy przeuczenie modelu (tzn.  $\overline{err} \approx 0$ ).

Estymator '.632+'

$$\widehat{Err}^{(.632+)} = (1 - \hat{w}) \cdot \overline{err} + \hat{w} \cdot \widehat{Err}^{(1)}, \text{ gdzie}$$

- $\hat{w}$  – współczynnik uwzględniający przeuczenie modelu.

## Różne koszty błędnej klasyfikacji

- Koszty błędnej klasyfikacji zależą często od tego, do jakiej klasy dana obserwacja rzeczywiście należy.
- **Przykład:** Stosując test medyczny, konsekwencje pomyłkowego rozpoznania choroby u osoby zdrowej są zazwyczaj mniej poważne niż w przypadku, gdy nie rozpoznamy choroby u osoby rzeczywiście chorej.
- Aby rozróżnić te dwa rodzaje błędów wprowadzono pojęcia **czułości i specyficzności**.
- W tym celu rozważmy przypadek klasyfikacji binarnej ( $K = 2$ ) i wyróżnijmy jedną z dwóch klas jako tzw. **pozytywną (positive) (+)**, a drugą jako **negatywną (negative) (-)**.
- W zastosowaniach medycznych:
  - 'positive (+)'  $\equiv$  'chory' (dodatni wynik testu),
  - 'negative (-)'  $\equiv$  'zdrowy' (ujemny wynik testu).

## Czułość i specyficzność

Macierz/tablica pomyłek (ang. confusion matrix)

|        |                  | PROGNOZA         |                 |
|--------|------------------|------------------|-----------------|
|        |                  | osoba zdrowa (-) | osoba chora (+) |
| PRAWDA | osoba zdrowa (-) | <b>TN</b>        | <b>FP</b>       |
|        | osoba chora (+)  | <b>FN</b>        | <b>TP</b>       |

- TP - True Positives,
- TN - True Negatives,
- FP - False Positives,
- FN - False Negatives.

$$\text{błąd klasyfikacji} = \frac{FP + FN}{TN + FP + FN + TP} = \frac{FP + FN}{n}.$$

## Czułość i specyficzność

$$\text{czułość} = \frac{TP}{P} = \frac{TP}{TP + FN}$$

$$\text{specyficzność} = \frac{TN}{N} = \frac{TN}{TN + FP} = 1 - \frac{FP}{TN + FP}.$$

### Interpretacja medyczna:

- Czułość (ang. sensitivity) – oszacowanie p-stwa przewidzenia przez test choroby, pod warunkiem, że pacjent jest rzeczywiście chory.
- Specyficzność (ang. specificity) – oszacowanie p-stwa przewidzenia przez test, że pacjent jest zdrowy pod warunkiem, że rzeczywiście jest zdrowy.
- Uwaga: zazwyczaj czułość i specyficzność wyrażamy w procentach (np. czułość 95%, specyficzność 89%).

## Czułość i specyficzność

Przykład: dane PimaIndiansDiabetes,  $n=392$ , model=LR (cutoff=0.5),  
cechy=('pregnant', 'glucose', 'pressure', 'triceps', 'insulin', 'mass', 'pedigree', 'age')

|        |     | prognoza |     |
|--------|-----|----------|-----|
|        |     | neg      | pos |
| prawda | neg | 233      | 29  |
|        | pos | 56       | 74  |

- $TP = 74$ ,  $TN = 233$ ,  $FP = 29$ ,  $FN = 56$ ,
- błąd klasyfikacji =  $(29 + 56)/392 \cdot 100\% \approx 21.7\%$ ,
- czułość =  $74/(74 + 56) \cdot 100\% \approx 56.9\%$ ,
- specyficzność =  $233/(233 + 29) \cdot 100\% \approx 88.9\%$ .

## Czułość i specyficzność

Pozostałe własności

- Inne nazwy:
  - czułość (sensitivity)  $\equiv$  True Positive Rate (TPR), hit rate, recall,
  - specyficzność (specificity)  $\equiv$  True Negative Rate (TNR).
- Czułość i specyficzność są wymaganiami przeciwnymi.
- Zwiększenie czułości prowadzi do zmniejszenia specyficzności i na odwrót.
- Gdyby klasyfikator prognozował wszystkich jako 'chorych' otrzymalibyśmy: czułość = 100% i specyficzność = 0%.
- W praktyce wybieramy klasyfikator, który zapewnia najlepszy kompromis.

## Czułość i specyficzność

### Pozostałe własności

- Inne przykłady niesymetrycznego traktowania błędów
  - scoring kredytowy (dobry/zły klient),
  - systemy rozpoznawania awarii (rzeczywista awaria/fałszywy alarm).
  - akcje marketingowe (klient odpowie/nie odpowie na ofertę),
  - analiza churn/attrition (klient pozostanie/odejdzie).
- Oceniając skuteczność modelu możemy uwzględnić różne koszty błędnej klasyfikacji ( $\Rightarrow$  *cost-sensitive classifier evaluation*).

## Inne kryteria oparte na macierzy pomyłek

- *Precision* lub *Positive Predictive Value (PPV)*

$$PPV = TP / (TP + FP)$$

- *Negative Predictive Value (NPV)*

$$NPV = TN / (TN + FN)$$

- *False Positive Rate (FPR)*

$$FPR = FP / N = FP / (FP + TN) = 1 - \text{Specificity}$$

- *False Negative Rate (FNR)*

$$FNR = FN / (TP + FN) = 1 - \text{TPR}$$

- *False Discovery Rate (FDR)*

$$FDR = FP / (TP + FP) = 1 - PPV$$

- Dokładność klasyfikacji, *accuracy (ACC)*

$$ACC = (TP + TN) / (TP + FP + FN + TN)$$

## Klasyfikator scoringowy

### Idea

- Rozważmy przypadek klasyfikacji binarnej:
  - $\mathcal{G} = \{0, 1\}$ ,
  - 0 – utożsamiamy z klasą *negative* ('-'),
  - 1 – utożsamiamy z klasą *positive* ('+').
- Klasyfikatorem scoringowym (ang. scoring classifier) będziemy nazywali odwzorowanie  $\hat{s} : \mathcal{X} \rightarrow \mathbb{R}$ , które każdej obserwacji  $\mathbf{x}$  przypisuje wartość liczbową  $\hat{s}(\mathbf{x})$ .
- Zwykle stosuje się konwencję: im większa wartość scoringowa tym większe przekonanie, że obserwacja należy do klasy *positive* (+).
- Jako wartość scoringową możemy wykorzystać prognozowane prawdopodobieństwo a posteriori, tzn.  $P(G = "+" | \mathbf{x})$ .
- Wiele popularnych metod klasyfikacji (np. k-NN, tree czy NaiveBayes) możemy stosować jako klasyfikatory scoringowe.

## Klasyfikator scoringowy

### Konstrukcja prognoz

- Ustalając odpowiednią wartość progową (ang. cut-off)  $c$ , możemy łatwo przekształcić prognozowane scoringi w prognozowane etykiety klas.
- Otrzymujemy klasyfikator (regułę decyzyjną)

$$d_c(s) = \begin{cases} 1, & \text{jeżeli } s > c, \\ 0, & \text{jeżeli } s \leq c, \end{cases}$$

gdzie:

- $s$  – scoringi,
- $c$  – wartość progowa (cutoff).
- Możemy porównać dokładność klasyfikatora (w szczególności czułość i specyficzność) dla różnych wartości progowych i wybrać wartość optymalną  $c_{opt}$ .

# Krzywa ROC

## Historia i idea metody

- Krzywa ROC (Receiver Operating Characteristic) – krzywa operacyjno-charakterystyczna odbiornika.
- Wywodzi się z teorii detekcji sygnałów (cel: odróżnienie sygnału od szumu).
- Pierwsze zastosowanie: II Wojna Światowa; analiza sygnałów radarowych w celu zwiększenia wykrywalności samolotów nieprzyjaciela.
- Obecnie krzywa ROC jest standardową metodą, wykorzystywaną m.in. w celu uzyskania sumarycznej informacji o zachowaniu klasyfikatora przy zmieniającej się wartości progowej.

# Krzywa ROC

## Konstrukcja

- Formalnie, krzywą ROC możemy zdefiniować jako:

$$ROC = \{(1 - \text{specyficzność}(c), \text{czułość}(c)), c \in (-\infty, \infty)\}.$$

- Równoważnie:


$$ROC = \{(FPR(c), TPR(c)), c \in (-\infty, \infty)\},$$

gdzie:

- $FPR = FP / (FP + TN)$ ,
- $TPR = TP / (TP + FN)$ .


# Krzywa ROC

## Przykład



# Krzywa ROC


## Przykład: dodanie kolorów dla wartości progowych






## Krzywa ROC

Przykład: porównanie z klasyfikacją losową



## Krzywa ROC

Przykład: Porównanie wyników dla różnych wartości cutoff




| cutoff | 0.1  | 0.2  | 0.3  | 0.4  | 0.5  | 0.6  | 0.7  | 0.8  | 0.9  |
|--------|------|------|------|------|------|------|------|------|------|
| error  | 41.1 | 28.1 | 22.7 | 19.9 | 21.7 | 21.2 | 21.9 | 25.8 | 31.1 |
| sens.  | 97.7 | 90.0 | 80.0 | 67.7 | 56.9 | 51.5 | 43.1 | 26.2 | 8.5  |
| spec.  | 39.7 | 63.0 | 76.0 | 86.3 | 88.9 | 92.4 | 95.4 | 98.1 | 98.9 |

**Pytanie:** Którą wartość progową wybralibyśmy jako optymalną?

## Krzywa ROC


Przykład: Porównanie wyników dla zbioru uczącego i testowego



## Area Under ROC Curve (AUC)

- Krzywą ROC wykorzystujemy do porównania modeli klasyfikacyjnych (np. porównujemy różne algorytmy, parametry lub różne kombinacje cech).
- Jako miarę dokładności często wykorzystuje się pole pod wykresem krzywej ROC (ozn. AUC lub AUROC).
- AUC przyjmuje wartości z przedziału  $[0,1]$ .
- Im większa wartość AUC tym lepszy model.
- Dla klasyfikatora idealnego:  $AUC = 1$ .
- Dla modelu losowego:  $AUC = 0.5$ .
- Interpretacja probabilistyczna: AUC to prawdopodobieństwo, że model predykcyjny przypisze większą wartość scoringową losowemu elementowi z klasy pozytywnej niż losowemu elementowi klasy negatywnej.

## Przykład: Area Under ROC Curve (AUC)



|     | learning set | test set |
|-----|--------------|----------|
| AUC | 0.880        | 0.826    |

# Dziękuję za uwagę!