

Rodziny klasyfikatorów

Metody wzmacniania klasyfikatorów

Adam Zagdański

Wydział Matematyki PWr

Wrocław
15 V 2026

Wprowadzenie
Metoda *bagging*
Metoda *boosting*
Random Forests (las losowe)

Plan prezentacji

- 1 Wprowadzenie
 - Klasyfikatory stabilne i niestabilne
 - Rodziny klasyfikatorów
- 2 Metoda *bagging*
 - Algorytm
 - Przykłady
 - Wady i zalety
- 3 Metoda *boosting*
 - Algorytm AdaBoost
 - Algorytm Arc-x4
 - Porównanie metod bagging i boosting
- 4 Random Forests (las losowe)
 - Algorytm
 - Ranking ważności cech (Variable Importance)

Klasyfikatory stabilne i niestabilne

- **Klasyfikatory niestabilne:** małe zaburzenie zbioru uczącego lub zmiana parametrów algorytmu prowadzi do istotnie różnych rezultatów.
- **Przykłady metod stabilnych**
 - Metoda „K-najbliższych sąsiadów” (K-NN) (dla $K > 1$),
 - Naiwny klasyfikator bayesowski (NB).
- **Przykłady metod niestabilnych**
 - Drzewa klasyfikacyjne (TREE),
 - Sieci neuronowe (NNET).

Klasyfikatory stabilne i niestabilne

- **Uwaga 1:** Formalna definicja klasyfikatora niestabilnego oparta jest na dekompozycji błędu klasyfikacji na obciążenie i wariancję (np. L. Breiman (1998), „*Arcing Classifiers*”, The Ann. Statist.)
- **Uwaga 2:** Metody niestabilne charakteryzują się małym obciążeniem i dużą wariancją!

Klasyfikatory stabilne i niestabilne

Jak poprawić dokładność metod niestabilnych?

- **Metody regularyzacji**

- Zastosowanie bardziej stabilnych estymatorów dla parametrów, np. estymator grzbietowy macierzy kowariancji: $\tilde{\Sigma} = \hat{\Sigma} + \lambda I$. Przykłady: *regularized LDA*, *stabilized LDA*, *Penalized Discriminant Analysis (PDA)*;
- Dodatkowe ograniczenia na wektor współczynników/wag (np. metoda *weight decay* dla sieci neuronowych);

- **Metody oparte na agregacji modeli (klasyfikatory złożone, rodziny klasyfikatorów)**

- *bagging*;
- *boosting*;
- *random subspace*.

Rodziny klasyfikatorów

Motywacja

- Załóżmy, że prognozy uzyskane dla L klasyfikatorów bazowych są niezależne od siebie (w praktyce częściowo osiągamy to dzięki dużej różnorodności klasyfikatorów bazowych).
- Niech ϵ_{MV} oznacza błąd klasyfikacji odpowiadający regule głosowania większości (ang. majority voting, *MV*). Możemy zapisać:

$$\epsilon_{MV} = \sum_{i=\lfloor L/2 \rfloor + 1}^L \binom{L}{i} \epsilon^i (1 - \epsilon)^{L-i}.$$

- Niech $\epsilon < \epsilon_{random}$ dla ϵ_{random} oznaczającego błąd klasyfikatora losowego oraz niech wszystkie klasyfikatory bazowe mają taki sam błąd klasyfikacji ϵ .
- Wówczas błąd klasyfikacji dla reguły głosowania większości ϵ_{MV} monotonicznie maleje do 0, gdy $L \rightarrow \infty$.

Rodziny klasyfikatorów

Motywacja




Fig. 3: Majority Voting. The relationship of error rates of base classifiers and error rates of the ensemble classifier in majority voting. The diagonal line represents the case in which the base classifiers are identical to each other, while the three curve lines represent combining different numbers of base classifiers which are independent of each other.

źródło: Pengyi Yang et al. *A Review of Ensemble Methods in Bioinformatics*, Current Bioinformatics, vol.5, No. 4, pp. 296–308, 2016.

Rodziny (komitety) klasyfikatorów

Definicja (Rodzina klasyfikatorów)


Rodziną (komitetem) klasyfikatorów (voting classification algorithm, ensemble method) nazywamy klasyfikator złożony, który podejmuje decyzje na podstawie głosowania klasyfikatorów składowych.

- **Najprostsza wersja:** zliczanie głosów i wybór klasy, na którą zagłosowało najwięcej klasyfikatorów (jeśli mamy remis w głosowaniu, możemy wybrać losowo jedną z klas, która uzyskała największą liczbę głosów).
- Komitety klasyfikatorów mogą być traktowane jako klasyfikatory probabilistyczne (możemy łatwo wyznaczyć prawdopodobieństwa przynależności do poszczególnych klas).

Trzy rodzaje klasyfikatorów opartych na głosowaniu

- ❶ Wagi przypisane obserwacjom ze zbioru treningowego nie są zmieniane (metody typu P&C, Perturb and Combine).
 - bagging (Breiman (1996)).
- ❷ Wagi przypisane obiektom ze zbioru uczącego zmieniają się iteracyjnie, na podstawie wyników otrzymanych dla poprzednich klasyfikatorów.
 - AdaBoost (Freund and Schapire (1995)),
 - Arc-x4 (Breiman (1996)),
 - LogitBoost (Friedman, 2000).
- ❸ Metody typu random subspace (feature bagging) – agregujemy modele konstruowane na bazie losowo wybranych podzbiorów cech.
 - Random Forest (las losowe) (Breiman and Cutler (2001)).

Trzy rodzaje klasyfikatorów opartych na głosowaniu



Źródło: Pengyi Yang et al. *A Review of Ensemble Methods in Bioinformatics*, Current Bioinformatics, vol.5, No. 4, pp. 296–308, 2016.

Komitety homogeniczne i heterogeniczne

Jak zwiększyć różnorodność (ang. diversity)?

- **Komitety homogeniczne**


- Wykorzystywana jest jedna reguła decyzyjna (np. drzewa klasyfikacyjne), na bazie której poprzez wielokrotne uczenie można uzyskać znaczne zwiększenie dokładności klasyfikacji.
- Przykłady: *bagging*, *boosting*.

- **Komitety heterogeniczne**

- Ich członkami mogą być odległe ideowo reguły decyzyjne (np. sieci neuronowe i drzewa klasyfikacyjne).
- Pozwala to na analizowanie danego problemu jednocześnie na wiele różnych sposobów.

Komitety homogeniczne i heterogeniczne

Jak zwiększyć różnorodność (ang. diversity)?



Metoda bootstrap

Przypomnienie: Idea metody bootstrap

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 7




FIGURE 7.12. Schematic of the bootstrap process. We wish to assess the statistical accuracy of a quantity $S(\mathbf{Z})$ computed from our dataset. B training sets $\mathbf{Z}^{*b}$, $b = 1, \dots, B$ each of size N are drawn with replacement from the original dataset. The quantity of interest $S(\mathbf{Z})$ is computed from each bootstrap training set, and the values $S(\mathbf{Z}^{*1}), \dots, S(\mathbf{Z}^{*B})$ are used to assess the statistical accuracy of $S(\mathbf{Z})$.

(C) 2026, Rodziny klasyfikatorów

13/39

Algorytm metody *bagging*

- bagging = **bootstrap aggregating** (Breiman (1996)).
- Jest przykładem metody typu P&C (Perturb and Combine)

Algorytm (Bagging)


Input

- I - klasyfikator bazowy (np. drzewo klasyfikacyjne),
 - B - liczba replikacji bootstrapowych,
 - L - zbiór uczący.
- 1 Generujemy B -bootstrapowych replikacji zbioru uczącego $\{L^{*1}, \dots, L^{*B}\}$ poprzez losowanie ze zwracaniem z oryginalnego zbioru L ;
 - 2 Dla każdej replikacji konstruujemy odpowiadający jej klasyfikator: $I^{*b} = I(L^{*b})$, $b = 1, \dots, B$;
 - 3 Wyznaczamy klasyfikator zagregowany stosując regułę „głosowania większości” (plurality voting).

Ilustracja działania metody *bagging*

Przykład: dane symulowane (klasyfikacja binarna, $n = 50$, $p = 5$)

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 8



(C) 2026, Rodziny klasyfikatorów

15/39

Ilustracja działania metody *bagging*

Przykład: dane symulowane (klasyfikacja binarna, $n = 50$, $p = 5$)

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 8




FIGURE 8.10. Error curves for the bagging example of Figure 8.9. Shown is the test error of the original tree and bagged trees as a function of the number of bootstrap samples. The orange points correspond to the consensus vote, while the green points average the probabilities.

Czy bagging zawsze pomaga?

Przykład

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 8

- Bagging zwiększa przestrzeń możliwych do uzyskania modeli dla danego klasyfikatora bazowego.
- Główna wada: stosując algorytm bagging, możemy utracić prostą strukturę modelu (tracimy interpretowalność).
- Aby dobrze modelować liniowe granice decyzyjne, zamiast metody bagging możemy zastosować algorytm boosting.



FIGURE 8.12. Data with two features and two classes, separated by a linear boundary. (Left panel:) Decision boundary estimated from bagging the decision rule from a single split, axis-oriented classifier. (Right panel:) Decision boundary from boosting the decision rule of the same classifier. The test error rates are 0.166, and 0.065, respectively. Boosting is described in Chapter 10.

Wady i zalety metody *bagging*

- Bagging przynosi zazwyczaj poprawę dokładności w przypadku metod niestabilnych (takich jak sieci neuronowe lub drzewa klasyfikacyjne).
- Może prowadzić jednak do nieznacznego pogorszenia dokładności w przypadku metod stabilnych (takich jak metoda k-sąsiadów).
- Zastosowanie metody bagging może prowadzić do utraty prostej, np. liniowej, struktury modelu.
- Może to być niepożądane, gdy mamy do czynienia z problemem separowalnym liniowo!

Metoda *boosting*

- ① Podobnie jak w przypadku metody *bagging* wyznaczany jest zbiór klasyfikatorów, na bazie którego konstruujemy klasyfikator złożony;
- ② Kolejne klasyfikatory są jednak konstruowane sekwencyjnie:
 - Wagi przypisywane przypadkom ze zbioru uczącego są modyfikowane na podstawie wyników otrzymanych dla poprzednio skonstruowanych klasyfikatorów;
 - Obserwacjom, które się źle klasyfikują przypisywana jest większa waga;
- ③ Wybrane warianty *boostingu*
 - AdaBoost (Adaptive Boosting), (Schapire & Freund (1995)), (znany także jako metoda Arc-FS),
 - Arcing (Adaptive Resample and Combine), (Breiman (1996)),
 - LogitBoost (Friedman (2001)).

Idea metody AdaBoost

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 10




FIGURE 10.1. Schematic of AdaBoost. Classifiers are trained on weighted versions of the dataset, and then combined to produce a final prediction.

Idea metody AdaBoost

Przykład




Figure 8. The shuttle dataset projected on the three most discriminatory axes. Color/shading denotes the class of instances and the cube sizes correspond to the instance weights. Each picture shows one AdaBoost trial, where progression is from the top left to top right, then middle left, etc.

Metoda Adaptive Boosting (AdaBoost)

Algorytm (AdaBoost)

Input

- L - zbiór uczący (zawierający m elementów),
 - I - klasyfikator bazowy,
 - B - liczba powtórzeń.
- 1 $L^* = L$ (wszystkim obiektom przypisujemy wagi równe 1)
 - 2 Dla $b = 1, \dots, B$ powtarzaj kroki 3-8:
 - 3 $C_b = I(L^*)$
 - 4 $\varepsilon_b = \frac{1}{m} \sum_{x_j \in L^*, C_b(x_j) \neq y_j} \text{waga}(x_j)$ (ważony błąd na zbiorze uczącym)
 - 5 Jeżeli $\varepsilon_b > \frac{1}{2}$, za L^* przyjmujemy replikację bootstrapową zbioru L , z wagami 1 (dla każdego przypadku). Następnie wracamy do kroku 3.
 - 6 $\beta_b = \varepsilon_b / (1 - \varepsilon_b)$
 - 7 Dla każdego $x_j \in L^*$: jeżeli $C_b(x_j) = y_j$ wówczas: $\text{waga}(x_j) = \text{waga}(x_j) \cdot \beta_b$
 - 8 Normalizujemy wagi przypadków, tak aby całkowita waga dla zbioru L^* wynosiła m
 - 9 Konstruuujemy klasyfikator złożony: $C^*(x) = \operatorname{argmax}_{y \in Y} \sum_{b: C_b(x) = y} \log \frac{1}{\beta_b}$

Algorytm AdaBoost

Przykład: dane symulowane (dwie klasy, $n=2000$, $p=10$)

Elements of Statistical Learning (2nd Ed.) ©Hastie, Tibshirani & Friedman 2009 Chap 10




FIGURE 10.2. Simulated data (10.2): test error rate for boosting with stumps, as a function of the number of iterations. Also shown are the test error rate for a single stump, and a 244-node classification tree.

Algorytm AdaBoost – dodatkowe uwagi

- Kroki 6 i 7 są równoważne następującej regule aktualizacji wag: dla każdego x_j dzielimy wagę $weight(x_j)$ przez $2\epsilon_b$ jeżeli $C_b(x_j) \neq y_i$ lub przez $2(1 - \epsilon_b)$ w przeciwnym przypadku.
- Jeżeli $\epsilon_b = 0$ lub $\epsilon_b > 1/2$ ponownie inicjalizujemy wagi i powtarzamy konstrukcję i -tego klasyfikatora.
- Wagi przypisane przypadkom ze zbioru uczącego możemy uwzględnić na dwa sposoby
 - **Reweighting**,
 - **Resampling**.
- Quinlan (1996) pokazał, że dla algorytmu AdaBoost *reweighting* prowadzi do lepszych wyników niż *resampling*.
- **Uwaga:** Jeżeli zbiór uczący zawiera zarówno przypadki o bardzo małych jak i bardzo dużych wagach mogą wystąpić problemy ze stabilnością numeryczną.

Metoda Arc-x4

Algorytm (Arc-x4)

Input

- L - zbiór uczący (zawiera m elementów),
 - I - klasyfikator bazowy,
 - B - liczba powtórzeń.
- 1 Dla $b = 1, \dots, B$ powtarzaj kroki 2 - 4
 - 2 $L^* = L$; obiektowi x przypisujemy wagę $(1 + e(x)^4)$, gdzie $e(x)$ jest sumarycznym błędem klasyfikacji odpowiadającym x , uzyskanym dla wszystkich wcześniejszych klasyfikatorów (tzn. $C_1, \dots, C_{b-1}$)
 - 3 Wagi normalizujemy, aby otrzymać całkowitą wagę równą m
 - 4 $C_b = I(L^*)$
 - 5 Klasyfikator złożony: $C^*(x) = \operatorname{argmax}_{y \in Y} \sum_{b: C_b(x)=y} 1$ (najczęściej wybierana etykieta y).

Metoda Arc-x4 – dodatkowe uwagi

- L.Breiman (1996): „(...) After testing ARC-FS (=AdaBoost) I suspected that its success lay not in its specific form but in its adaptive resampling property, where increasing weight was placed on those cases more frequently misclassified.”
- Skuteczność AdaBoost związana jest przede wszystkim z adaptacyjną modyfikacją wag przypadków niż z końcową agregacją modeli.
- Podobnie jak w przypadku AdaBoost, algorytm ARC-x4 buduje sekwencyjne kolejne klasyfikatory. Waga przypadku jest jednak proporcjonalna do liczby błędów do potęgi $4 + 1$ (błędów popełnionych przez poprzednie klasyfikatory) .
- W odróżnieniu od AdaBoost, w przypadku ARC-x4 modele składowe mają jednakową wagę głosu.

Bagging czy boosting?

Empiryczna analiza porównawcza

Porównanie metod *bagging* i *boosting* dla zestawu danych rzeczywistych:
E. Bauer, R. Kohavi, (1999), „*An Empirical Comparison of voting Classification Algorithms: Bagging, Boosting, and Variants*,” Machine Learning, vol. 36, p. 105-139.

Table 1. Characteristics of the datasets and training set sizes used. The files are sorted by increasing dataset size

Data set	Dataset size	Training set size	Attributes Cont/nominal	Classes
Credit (German)	1,000	300	7/13	2
Image Segmentation (segment)	2,310	500	19/0	7
Hypothyroid	3,163	1,000	7/18	2
Sick-euthyroid	3,163	800	7/18	2
DNA	3,186	500	0/60	3
Chess	3,196	500	0/36	2
LED-24	3,200	500	0/24	10
Waveform-40	5,000	1,000	40/0	3
Satellite image (satimage)	6,435	1,500	36/0	7
Mushroom	8,124	1,000	0/22	2
Nursery	12,960	3,000	0/8	5
Letter	20,000	5,000	16/0	26
Adult	48,842	11,000	6/8	2
Shuttle	58,000	5,000	9/0	7

Bagging czy boosting?

Empiryczna analiza porównawcza

- Wykorzystane klasyfikatory bazowe
 - Naive Bayes,
 - Decision trees,
 - MC4 (MLC++ C4.5),
 - MC4(1) (single root split, decision stump),
 - MC4(1)-disc (dodatkowa dyskretyzacja wszystkich atrybutów).
- Porównywane algorytmy wzmacniania klasyfikatorów
 - Bagging,
 - AdaBoost,
 - Arc-x4.

Bagging czy boosting?

Dekompozycja błędu klasyfikacji (Kong and Dietterich (1995))

$$\text{Error} = \sum_x P(x) (\sigma_x^2 + \text{bias}_x^2 + \text{variance}_x)$$

where


$$\begin{aligned}\sigma_x^2 &\equiv \frac{1}{2} \left(1 - \sum_{y \in Y} P(Y_F = y|x)^2 \right) \\ \text{bias}_x^2 &\equiv \frac{1}{2} \sum_{y \in Y} [P(Y_F = y|x) - P(Y_H = y|x)]^2 \\ \text{variance}_x &\equiv \frac{1}{2} \left(1 - \sum_{y \in Y} P(Y_H = y|x)^2 \right).\end{aligned}$$

- σ^2 (nieredukowalna zmienność dla danego zagadnienia) – dolne ograniczenie oczekiwanego błędu predykcji (= oczekiwany błąd optymalnego klasyfikatora Bayesowskiego),
- bias^2 – mierzy, w jakim stopniu średnia prognoza na bazie danego algorytmu odpowiada rzeczywistej wartości,
- variance – mierzy, w jakim stopniu prognoza na bazie danego algorytmu zmienia się dla różnych zbiorów treningowych.
- Uwaga: W przypadku klasyfikacji kwadratowa funkcja straty nie może być zastosowana!

Bagging czy boosting?

Empiryczna analiza porównawcza

Bagging – podsumowanie wyników




- Bagging okazał się jednostajnie lepszy od metod bazowych dla wszystkich analizowanych danych.
- Dekompozycja na obciążenie i wariancję wykazała, że redukcja błędu klasyfikacji jest związana z **redukcją wariancji**.
 - średnia redukcja wariancji: z 5.7% do 3.5% (względna redukcja = 29%)
 - średnia redukcja obciążenia: z 6.9% do 6.8% (względna redukcja = 2%)

Bagging czy boosting?

Empiryczna analiza porównawcza

Boosting – podsumowanie wyników



- AdaBoost okazał się średnio bardziej skutecznym algorytmem niż najbardziej obiecująca wersja algorytmu *bagging*
- W odróżnieniu od *bagging*'u, *boosting* nie był jednak jednostajnie lepszą metodą dla wszystkich analizowanych danych (dla niektórych danych błąd klasyfikacji wzrósł)
- Redukcja błędu jest związana zarówno z **redukcją obciążenia jak i wariacji**.
 - średnie obciążenie (6.9% → 5.7%, względna redukcja = 32%)
 - średnia wariancja (5.7% → 4.1%, względna redukcja = 16%)

Bagging czy boosting?

Podsumowanie

- 1 Średnia dokładność algorytmów *AdaBoost* i *Arc-x4* jest lepsza w porównaniu do metody *bagging* (podobne wnioski otrzymali Breiman (1996) i Quinlan (1996)).
- 2 *AdaBoost* i *Arc-x4* nie są jednak jednostajnie lepsze niż *bagging* (tzn. lepsze dla każdego z analizowanych zbiorów danych);
- 3 *AdaBoost* i *Arc-x4* redukują zarówno obciążenie jak i wariancję dla drzew klasyfikacyjnych, ale powodują nieznaczny wzrost wariacji w przypadku „naiwnego” klasyfikatora bayesowskiego.

Random Forests (laso losowe)

Idea metody

- Algorytm lasów losowych (Random Forest, RF) zaproponowany przez L. Breimana (2001), jest istotną modyfikacją metody bagging.
- RF wykorzystuje ideę *random subspace*, tzn. agregujemy modele zbudowane na podstawie losowo wybranych podzbiorów cech.
- RF tworzy duży zbiór nieskorelowanych drzew klasyfikacyjnych, a następnie je uśrednia.
- Przed każdym podziałem danego węzła wybieramy losowo m zmiennych (gdzie $m \leq p$) jako kandydatów do zdefiniowania reguły podziału.
- W wielu przypadkach skuteczność losowych lasów jest podobna do metod typu boosting, jednak uważa się je za łatwiejsze do uczenia i dostrajania.

Random Forests (laso losowe)

Algorytm (Random Forests (laso losowe))

Input:

- B - liczba replikacji bootstrapowych (liczba drzew),
- L - zbiór uczący,
- m - liczba losowo wybieranych cech ($m \leq p$),
- ① Dla $b = 1, \dots, B$:
 - (a) Wyznaczamy replikację bootstrapową L^{*b} na bazie zbioru uczącego L .
 - (b) Wykorzystujemy L^{*b} do konstrukcji drzewa klasyfikacyjnego T^b , powtarzając następujące kroki dla każdego węzła:
 - i.) Wybieramy losowo m zmiennych spośród oryginalnych p .
 - ii.) Spośród m zmiennych wybieramy najlepszą oraz odpowiednią wartość progową aby stworzyć optymalną regułę podziału.
 - iii.) Dzielimy węzeł na dwa węzły potomne.
- ② Wynik: zbiór drzew $\{T_b\}_{b=1}^B$.
- ③ Końcowy klasyfikator: $\hat{C}_{RF}^B(x) = \text{głosowanie większości} \{\hat{C}_b(x)\}_{b=1}^B$, gdzie $\hat{C}_b(x)$ to prognoza oparta na T^b .

Random Forests

Dodatkowe uwagi

- Główną ideą lasów losowych jest dalsza redukcji wariancji (obserwowana dla metody bagging) poprzez zmniejszenie korelacji między drzewami.
- Osiągamy to poprzez losowy wybór m zmiennych (spośród p) jako kandydatów do wyznaczenia reguły podziału dla danego węzła.
- Dla klasyfikacji wartość domyślna dla m to $\lfloor \sqrt{p} \rfloor$, jako minimalny rozmiar węzła przyjmujemy 1.
- Dla regresji, wartość domyślna dla m to $\lfloor p/3 \rfloor$ a minimalny rozmiar węzła to 5.

Random Forests (laso losowe)


Ranking ważności cech (Variable Importance)

- Losowe lasy są często używane jako metoda wyboru cech (ang. feature selection), tzn. możemy łatwo wyznaczyć ranking ważności cech (ang. variable importance ranking).
- RF używa obserwacji Out-Of-Bag (OOB) (tzn. te obserwacje, które nie trafiły do danej replikacji) do oceny ważności każdej zmiennej.
- Podczas konstruowania b -tego drzewa, obserwacje OOB są „przepuszczane” przez drzewo i na tej podstawie wyznaczona jest dokładność prognoz.
- Następnie wartości danej zmiennej (dla obserwacji OOB) są losowo permutowane i ponownie obliczana jest dokładność.
- Zmniejszenie dokładności (będące konsekwencją permutowania wartości) jest uśredniane dla wszystkich drzew w lesie i jest używane jako miara ważności danej zmiennej (ang. variable importance).

Random Forests

Variable Importance

Przykład: Variable Importance Plot (VIP) dla danych Pima Indians Diabetes.



Podsumowanie

- ① Rodziny klasyfikatorów (w szczególności konstruowane za pomocą metod *bagging*, *boosting* i *random forest*) przynoszą poprawę skuteczności klasyfikacji poprzez agregację wielu klasyfikatorów bazowych.
- ② **Porównanie: *bagging* vs. *boosting***
 - Rodzina klasyfikatorów skonstruowana w oparciu o algorytm *bagging* najczęściej charakteryzuje się mniejszą wariancją i zazwyczaj nie zmienia istotnie obciążenia klasyfikatora bazowego.
 - Metoda *boosting* charakteryzuje się zwykle mniejszym obciążeniem oraz nieznacznie zwiększoną wariancją w porównaniu do wyjściowego klasyfikatora.
- ③ **Potencjalne wady**
 - Duża złożoność obliczeniowa!
 - Utrata łatwej interpretowalności wyników w przypadku niektórych metod bazowych (np. drzew klasyfikacyjnych).

Na następnym wykładzie

Metoda wektorów nośnych (Support Vector Machines, SVM)

- Przypadek klas liniowo separowalnych.
- Przypadek klas nieseparowalnych liniowo.
- Konstrukcja nieliniowych powierzchni separujących.
- Przypadek k-klas.
- Wady i zalety.