

Sprawozdanie_3

Jakub Okła, album 287337

2026-04-03

Klasyfikacja na podstawie modelu regresji liniowej

Podstawowe informacje na temat analizowanych danych


Model **regresji liniowej** budowany będzie na podstawie zbioru danych **iris** z pakietu *datasets*.

Mamy **3 klasy**(gatunki irysów): *setosa*, *versicolor*, *virginica* oraz **4 zmienne objaśniające**: *Petal.Length*, *Petal.Width*, *Sepal.Length* i *Sepal.Width*.

Podział danych

W celu zaprojektowania regresji liniowej dane zostały losowo podzielone na następujące części: $\frac{2}{3}$ — danych zbiór uczący, $\frac{1}{3}$ — zbiór testowy.

Macierz współczynników



Na podstawie przedstawionych współczynników model wyznacza wartości punktowe dla poszczególnych klas, a następnie przypisuje obserwację do klasy z największą wartością. Z wykresu wynika, że dla klasy **setosa** największe znaczenie ma zmienna **SW**, natomiast dla klasy **virginica** największy dodatni wpływ ma zmienna **PW**.

Predykcje i ocena jakości modelu

Tabela 1: Macierz klasyfikacji dla zbioru uczącego


	setosa	versicolor	virginica
setosa	34	0	0
versicolor	0	30	5
virginica	0	5	26

Dokładność modelu dla danych uczących wynosi **90%**. Nie jest to jednak najlepsza miara jakości modelu, ponieważ model oceniany jest na tych samych danych, na których był trenowany. Może to prowadzić do zawyżenia wyniku i nie pokazuje, jak dobrze model radzi sobie z nowymi obserwacjami.

Tabela 2: Macierz klasyfikacji dla zbioru testowego

	setosa	versicolor	virginica
setosa	16	0	0
versicolor	0	8	7
virginica	0	6	13

Dla zbioru testowego dokładność spada do **74%**. Jest to bardziej wiarygodna ocena jakości modelu, ponieważ zbiór testowy nie był wykorzystywany podczas trenowania modelu. Wynik ten lepiej pokazuje zdolność modelu do klasyfikowania nowych obserwacji.



W macierzy klasyfikacji widoczny jest **efekt maskowania klas**. Model bardzo dobrze rozpoznaje gatunek *setosa*, ale myli część obserwacji należących do klas *versicolor* i *virginica*. Oznacza to, że dobra klasyfikacja jednej klasy może **zawyżać** ogólną dokładność modelu i **ukrywać błędy** popełniane dla pozostałych klas.

Budowa modelu liniowego dla rozszerzonej przestrzeni cech

Model rozszerzony wykorzystuje nie tylko oryginalne zmienne, ale też ich kwadraty oraz iloczyny. Dzięki temu granice decyzyjne mogą być bardziej elastyczne niż w podstawowym modelu liniowym.

Tabela 3: Macierz klasyfikacji dla modelu wielomianowego

	setosa	versicolor	virginica
setosa	14	0	0
versicolor	0	15	1
virginica	0	2	18

Dokładność modelu liniowego dla rozszerzonej przestrzeni cech wynosi **94%**, co przebija dokładność modelu prostego o **20** punktów procentowych. Poprawa wyniku sugeruje, że dodanie składników wielomianowych oraz interakcji między zmiennymi pozwoliło modelowi lepiej uchwycić zależności występujące w danych. Oznacza to, że granice między klasami **nie są w pełni liniowe**, a rozszerzenie przestrzeni cech poprawia zdolność modelu do rozróżniania gatunków.